

UNIVERSIDAD NACIONAL DE ASUNCIÓN

FACULTAD POLITÉCNICA

INGENIERÍA EN INFORMÁTICA



**REPRESENTACIONES LÉXICAS Y BASADAS EN LLM
PARA LA PREDICCIÓN DE RESULTADOS DE
LICITACIONES PÚBLICAS: UN ESTUDIO
COMPARATIVO**

Proyecto Final de Grado

Autores:

Isaac Gabriel Amarilla Benítez

Luis Fernando Caballero Ramoa

San Lorenzo – Paraguay

2026

Abstract

We compare lexical and LLM-based text representations for predicting public tender outcomes from bidding documents in a processed subset of 1,162 road-construction procurements (Paraguay). Under stratified 5-fold cross-validation, TF-IDF with logistic regression yields the strongest ranking (mean ROC AUC 0.814, PR AUC 0.899), while a lightweight cross-chunk transformer over frozen LLM chunk embeddings achieves the best calibration (Brier 0.162) and the most stable behavior under threshold tuning. The study highlights that procurement documents carry early predictive signal and that ranking, calibration, and threshold sensitivity should be assessed separately for monitoring. Artifacts: [doi:10.5281/zenodo.20128768](https://doi.org/10.5281/zenodo.20128768).

Resumen

Este trabajo compara representaciones textuales léxicas y basadas en LLM para predecir resultados de licitaciones públicas a partir de documentos de licitación en un subconjunto procesado de 1.162 contrataciones de construcción vial de Paraguay. Bajo validación cruzada estratificada de cinco pliegues, TF-IDF con regresión logística produce el mejor ordenamiento, con ROC AUC medio de 0,814 y PR AUC de 0,899, mientras que un transformer liviano entre fragmentos, aplicado sobre embeddings congelados de fragmentos de un LLM, logra la mejor calibración, con un puntaje de Brier de 0,162, y el comportamiento más estable ante el ajuste del umbral. El estudio destaca que los documentos de contratación contienen señal predictiva temprana y que el ordenamiento, la calibración y la sensibilidad al umbral deben evaluarse por separado para el monitoreo. Artefactos: doi:10.5281/zenodo.20128768.

Palabras clave: contratación pública, gobierno electrónico, democracia electrónica, documentos de licitación, pliego de bases y condiciones, modelos grandes de lenguaje, predicción de resultados.

Contenidos

Abstract	I
Resumen	II
Contenidos	III
Lista de Figuras	VII
Lista de Tablas	VIII
Glosario	IX
1. Introducción	1
1.1. Planteamiento del problema	3
1.2. Preguntas de investigación	4
1.3. Objetivos	5
1.3.1. Objetivo general	5
1.3.2. Objetivos específicos	5
1.4. Alcance y delimitaciones	6
1.5. Contribuciones	6
1.6. Organización del libro	7
2. Marco teórico	8
2.1. Contratación pública y cadena de suministro en Paraguay	8
2.2. Datos abiertos y Estándar de Datos para las Contrataciones Abiertas	10
2.3. Pliego de Bases y Condiciones	10
2.4. Clasificación supervisada y resultado que se busca predecir	11
2.5. Procesamiento de documentos	12
2.5.1. Extracción de texto desde PDF	12
2.5.2. Tokenización	12
2.5.3. Fragmentación con solapamiento	13
2.6. Representación léxica	13
2.6.1. Modelo de espacio vectorial	13
2.6.2. Regresión logística	14
2.7. Representaciones densas y modelos de lenguaje	14
2.8. Arquitectura transformer	15
2.9. Agregación de fragmentos	16
2.9.1. Promedio	16

2.9.2. Transformer entre fragmentos	16
2.10. Representación documental	17
2.11. Arquitectura del predictor	17
2.12. Líneas base	18
2.13. Entrenamiento y reproducibilidad	19
2.14. Desbalance de clases	19
2.15. Ordenamiento y umbral de decisión	20
2.16. Calibración probabilística	20
2.17. Validación cruzada y reproducibilidad	21
3. Trabajos relacionados y estado del arte	22
3.1. Instituciones y fuentes relacionadas en Paraguay	22
3.1.1. Dirección Nacional de Contrataciones Públicas	22
3.1.2. Sistema de Información de las Contrataciones Públicas	23
3.1.3. Gobierno electrónico y control público	23
3.2. Analítica de contratación pública	23
3.3. Predicción a partir del texto de convocatorias	24
3.4. Clasificación de documentos extensos	25
3.5. Representaciones dispersas frente a densas	26
3.6. Evaluación y calibración en trabajos predictivos	26
3.7. Estado del arte	27
3.7.1. Sistemas predictivos para supervisión pública	27
3.7.2. Modelos para texto extenso	27
3.7.3. Embeddings de modelos grandes y líneas base léxicas	27
3.7.4. Brecha identificada	28
3.8. Posicionamiento del trabajo	28
4. Propuesta de experimentación numérica	30
4.1. Ambiente computacional	30
4.1.1. Hardware	30
4.1.2. Software	31
4.2. Fuente y procedencia de los datos	32
4.2.1. API de la DNCP	32
4.2.2. Conjunto inicial	33
4.3. Conjunto de datos	33
4.4. Tratamiento de la fuga de información	34
4.5. Protocolo de evaluación	35
4.6. Métricas	35
4.7. Recuperación de documentos PBC	36
4.8. Extracción y normalización del texto	36
4.9. Generación de embeddings	37
4.9.1. Codificador congelado	37
4.9.2. Control de memoria	37
4.10. Embudo de construcción del conjunto supervisado	38
4.11. Definición de la instancia y etiqueta	38
4.12. Modelos que se evaluarán	39
4.12.1. Representación documental	39

4.12.2. Arquitectura del predictor	40
4.12.3. Líneas base	40
4.13. Entrenamiento y reproducibilidad	41
4.13.1. Líneas base triviales	42
4.13.2. TF-IDF con regresión logística	42
4.13.3. Promedio con regresión logística	42
4.13.4. Promedio con MLP	42
4.13.5. Transformer entre fragmentos	42
4.14. Partición y protocolo de evaluación	43
4.15. Entrenamiento	43
4.16. Métricas de evaluación	43
4.17. Trazabilidad y reproducibilidad	44
4.18. Amenazas a la validez previstas	44
5. Pruebas experimentales y análisis de resultados computacionales	45
5.1. Comprobaciones previas	45
5.2. Desempeño de ordenamiento	45
5.3. Sensibilidad al umbral	46
5.4. Calibración	46
5.5. Comparación de representaciones	47
5.6. Lectura comparativa por criterio	49
5.6.1. Ranking	49
5.6.2. Desempeño con umbral 0,5	50
5.6.3. Calibración	51
5.7. Análisis de sensibilidad al umbral	51
5.8. Comparación entre hipótesis experimentales	51
5.8.1. Señal textual frente a controles	51
5.8.2. Representación léxica frente a densa	52
5.8.3. Interacciones entre fragmentos	52
5.9. Costo y complejidad experimental	52
5.10. Discusión de resultados	53
5.10.1. Implicaciones para Paraguay	54
5.10.2. Comparación con otros países	55
5.11. Síntesis de hallazgos	55
6. Conclusiones y trabajos futuros	56
6.1. Conclusiones finales	56
6.2. Respuesta a las preguntas de investigación	58
6.3. Aportes del trabajo	59
6.4. Trabajos futuros	59
6.4.1. Ampliación y representatividad del conjunto	59
6.4.2. Validación temporal e institucional	59
6.4.3. Otras categorías de contratación	60
6.4.4. Análisis explicativo del texto	60
6.4.5. Nuevas representaciones y agregadores	60
6.4.6. Calibración y decisión	61
6.4.7. Integración con variables estructuradas	61

6.4.8. Gobernanza y uso responsable	61
6.5. Consideración final	62
Referencias	63

Lista de figuras

5.1. Curvas de precisión-exhaustividad de los modelos comparados.	48
5.2. Curvas de calibración de los modelos comparados.	49
5.3. Sensibilidad de F1 y exactitud balanceada al ajuste del umbral.	50

Lista de tablas

3.1. Posicionamiento frente a trabajos relacionados seleccionados.	29
4.1. Información de hardware respaldada por los artefactos del proyecto.	31
4.2. Componentes principales del ambiente de software versionado.	32
4.3. Embudo de datos desde procesos DNCP hasta el conjunto supervisado. . .	38
4.4. Conteos por estado en etapas principales.	38
5.1. Comparación de modelos mediante validación cruzada de cinco pliegues (media $\pm$ desviación estándar). Un valor menor es mejor para Brier; un valor mayor es mejor para las demás métricas.	47
5.2. Ajuste del umbral en una partición interna de validación y evaluación en el pliegue externo de prueba. Se informan las medias de todos los pliegues.	48

Glosario

Acrónimos

API	<i>Application Programming Interface</i>
AUC	<i>Area Under the Curve</i>
CV	<i>Cross-Validation</i>
DNCP	Dirección Nacional de Contrataciones Públicas
GPU	<i>Graphics Processing Unit</i>
LLM	<i>Large Language Model</i>
MLP	<i>Multilayer Perceptron</i>
OCDE	Organización para la Cooperación y el Desarrollo Económicos
OCDS	<i>Open Contracting Data Standard</i>
OCR	<i>Optical Character Recognition</i>
PBC	Pliego de Bases y Condiciones
PR	<i>Precision-Recall</i>
ROC	<i>Receiver Operating Characteristic</i>
SICP	Sistema de Información de las Contrataciones Públicas
TF-IDF	<i>Term Frequency-Inverse Document Frequency</i>

Términos

Agregación por promedio: operación que resume varios embeddings mediante su media aritmética para obtener una única representación.

Calibración: grado de correspondencia entre las probabilidades predichas y las frecuencias observadas de un resultado.

Clasificación binaria: tarea de asignar cada ejemplo a una de dos clases posibles.

Codificador congelado: modelo preentrenado cuyos parámetros no se actualizan durante el entrenamiento del predictor posterior.

- Detención temprana:** criterio que interrumpe el entrenamiento cuando el desempeño de validación deja de mejorar durante un número prefijado de épocas.
- Embedding:** representación vectorial densa de una unidad textual, producida por un modelo para codificar regularidades de su contenido y contexto.
- Época:** recorrido completo del algoritmo de entrenamiento sobre todos los ejemplos de la partición destinada al ajuste.
- Fragmento:** segmento de tokens en el que se divide un documento para respetar el límite de entrada del codificador.
- Fuga de información:** uso durante el entrenamiento o la selección de información que no estaría disponible en el momento real de la predicción.
- Hiperparámetro:** valor fijado antes del entrenamiento que controla la configuración o el comportamiento de un modelo.
- Logit:** salida numérica de un clasificador antes de transformarla en probabilidad mediante una función como la sigmoide.
- n -grama:** secuencia contigua de n unidades de texto. En este trabajo las unidades son palabras: un unigrama contiene una palabra y un bigrama contiene dos.
- Ordenamiento:** capacidad de asignar puntajes mayores a los ejemplos positivos que a los negativos, independientemente de un umbral fijo.
- Prevalencia:** proporción de ejemplos pertenecientes a la clase positiva dentro de un conjunto de datos.
- Representación densa:** vector numérico en el que la información se distribuye entre un número fijo de componentes, generalmente no nulas.
- Representación dispersa:** vector de alta dimensión en el que la mayoría de los componentes son cero, como una representación TF-IDF.
- Token:** unidad mínima de texto procesada por un tokenizador; puede corresponder a una palabra, parte de ella o un símbolo.
- Transformer:** arquitectura neuronal basada principalmente en mecanismos de atención para modelar relaciones entre elementos de una secuencia.
- Umbral de decisión:** valor de corte aplicado a un puntaje o probabilidad para convertirlo en una predicción de clase.
- Validación cruzada:** procedimiento que divide los datos en varios pliegues y alterna cuáles se usan para entrenamiento y evaluación.

Capítulo 1

Introducción

La contratación pública articula la planificación estatal con la provisión efectiva de bienes, obras y servicios. En Paraguay, la Ley N.º 7021/2022 define la contratación del suministro público como una secuencia ordenada que comprende la identificación de una necesidad, la estimación del valor, la definición de la estrategia de adquisición, la contratación, la ejecución y, cuando corresponde, la liquidación. La misma norma dispone que esas acciones queden registradas en el Sistema de Información de las Contrataciones Públicas (SICP) [1]. Por ello, la contratación pública no constituye un evento aislado, sino un proceso trazable cuyo registro digital puede utilizarse para transparencia, control y análisis.

La reforma introducida por la Ley N.º 7021/2022 busca modernizar las compras del Estado paraguayo, fortalecer la competencia, prevenir conflictos de interés y optimizar los controles mediante mecanismos normativos y tecnológicos [2]. Este marco se relaciona con la política nacional de gobierno electrónico, que incluye portales de servicios, interoperabilidad institucional, datos abiertos y acceso ciudadano a la información [3]. El portal de la Dirección Nacional de Contrataciones Públicas (DNCP) publica información mediante servicios de consulta y archivos históricos; además, adopta el Estándar de Datos para las Contrataciones Abiertas (OCDS) para representar etapas como planificación, convocatoria, adjudicación, contrato e implementación [4, 5].

Dentro de este proceso, el Pliego de Bases y Condiciones (PBC) ocupa una posición particular. Se produce antes de conocerse el resultado y reúne requisitos administrativos, especificaciones técnicas, criterios de evaluación, condiciones de participación, plazos y obligaciones. El estándar OCDS distingue precisamente los documentos de licitación, las especificaciones técnicas y los criterios de evaluación como tipos documentales de la etapa de convocatoria [6]. En consecuencia, el PBC contiene información disponible

antes del resultado final: puede ser analizado sin recurrir a adjudicaciones, contratos ni evaluaciones publicadas después del cierre del proceso.

La disponibilidad previa del documento vuelve pertinente una pregunta predictiva: ¿existen regularidades textuales que permitan estimar si un proceso terminará con un resultado exitoso o no exitoso? Esta pregunta no equivale a determinar causalidad, fraude o ilegalidad. Una predicción puede apoyarse en estructuras documentales, patrones de redacción o características institucionales correlacionadas con el resultado sin que estas constituyan causas del mismo. En este libro, la salida del modelo se entiende como una señal analítica para priorización y estudio, no como una decisión administrativa ni como una imputación sobre una entidad o proveedor.

Los sistemas de apoyo a la supervisión requieren esta distinción. El proyecto VigIA, desarrollado para la Veeduría Distrital de Bogotá, combina modelos predictivos e índices de riesgo con el propósito de asignar mejor los recursos de control; sus autores presentan la herramienta como apoyo a los organismos de supervisión para priorizar investigaciones, no como sustituto de la revisión institucional [7]. La literatura sobre advertencias tempranas formula una idea similar: el valor operativo de la predicción reside en anticipar dónde conviene revisar, siempre que se documenten el objetivo, las limitaciones y los errores posibles [8]. En el contexto paraguayo, esta investigación adopta ese enfoque prudente.

La contratación pública es un proceso central del gobierno electrónico: transforma los presupuestos públicos en contratos, obras y servicios mediante plataformas cada vez más digitales. También es relevante para la democracia electrónica, porque los registros abiertos de contratación amplían la capacidad de los organismos de control, periodistas, empresas y ciudadanos para examinar cómo se asignan los recursos públicos. Estas capacidades se alinean con las agendas de gobierno digital sobre datos abiertos y análisis responsables para la supervisión del sector público. Trabajos recientes en este sector presentan el análisis de contrataciones como una herramienta para la supervisión basada en riesgos [7]. Los documentos de licitación son fundamentales en este contexto porque definen las condiciones administrativas, los requisitos técnicos, las reglas de calificación y las restricciones de ejecución antes de que se conozca el resultado final. Evidencia reciente del ámbito de las contrataciones también muestra que las descripciones de las convocatorias permiten predecir resultados relacionados con la competencia y la eficiencia de costos [9]. Por tanto, la pregunta relevante no es solo si los resultados de las licitaciones pueden predecirse a partir del texto documental, sino también qué representación de ese texto aporta más información para un monitoreo responsable de la contratación pública.

Este trabajo estudia dicha pregunta mediante una comparación directa entre características léxicas dispersas y representaciones densas basadas en LLM. El análisis se concentra

en licitaciones de construcción vial, cuyos documentos suelen ser relativamente estructurados y estandarizados. Los modelos léxicos dispersos continúan siendo líneas base sólidas e interpretables para la clasificación documental [10], y trabajos recientes sobre documentos extensos confirman que las representaciones léxicas o híbridas pueden seguir siendo competitivas, en lugar de quedar uniformemente superadas por arquitecturas transformer [11]. Al mismo tiempo, la investigación sobre embeddings se ha extendido hacia representaciones densas basadas en LLM [12]. En este contexto, el objetivo no es establecer una familia de modelos universalmente superior, sino comprender cuánta señal predictiva puede recuperarse de indicios léxicos, cuánta ya está capturada por embeddings densos congelados y si el modelado explícito de interacciones entre fragmentos aporta valor adicional.

La canalización utiliza un LLM causal preentrenado como codificador congelado para producir embeddings por fragmento a partir de documentos de licitación en español. Se comparan dos estrategias simples de agregación de estos embeddings, basadas en agrupación por promedio, con un transformer liviano que modela las interacciones entre fragmentos. Estos enfoques basados en LLM se evalúan junto con TF-IDF más regresión logística y líneas base triviales. Este diseño permite separar los efectos de la representación de los efectos del modelado posterior.

El estudio ofrece una comparación reproducible entre líneas base léxicas, triviales, de embeddings agregados y de un transformer entre fragmentos, bajo validación cruzada determinista de cinco pliegues. También analiza por separado el desempeño de ordenamiento, la calibración y la sensibilidad al umbral. El resultado central presenta matices: TF-IDF más regresión logística es el modelo con mejor ordenamiento, mientras que el transformer entre fragmentos ofrece la mejor calibración y el comportamiento más estable ante cambios del umbral. Esto aporta evidencia útil para la pregunta más amplia de cómo se distribuye la señal textual en los documentos de contratación pública. Los artefactos asociados están archivados en Zenodo ([doi:10.5281/zenodo.20128768](https://doi.org/10.5281/zenodo.20128768)).

1.1. Planteamiento del problema

El SICP y el portal de datos abiertos permiten recuperar metadatos estructurados, estados y documentos asociados a procesos de contratación. Sin embargo, un PBC es un documento extenso y heterogéneo. Puede contener texto corrido, formularios, cuadros, cláusulas repetidas, anexos y especificaciones propias de una obra. La disponibilidad del archivo no implica que su información sea inmediatamente utilizable por un modelo: primero deben localizarse los documentos, descargarse, extraerse como texto, dividirse en unidades manejables y transformarse en variables numéricas.

La longitud introduce una dificultad adicional. Los transformers convencionales emplean autoatención cuyo costo crece cuadráticamente con la longitud de la secuencia [13]. La literatura de clasificación documental ha abordado esta limitación mediante truncamiento, atención dispersa y esquemas jerárquicos que dividen el documento en fragmentos y luego agregan sus representaciones [14, 15]. En PBC extensos, truncar el comienzo o el final puede omitir secciones relevantes, mientras que procesar todos los tokens de una sola vez puede superar la memoria disponible.

Al mismo tiempo, los documentos de contratación utilizan vocabulario recurrente y fórmulas estandarizadas. Esto favorece modelos léxicos como TF-IDF, capaces de representar unigramas y bigramas de todo el texto sin imponer un límite rígido de contexto. La tensión metodológica es, por tanto, concreta: una representación densa preentrenada puede capturar relaciones semánticas, pero requiere una estrategia de fragmentación y agregación; una representación dispersa puede preservar señales léxicas globales y ser más sencilla, aunque no modele el contexto con la misma riqueza.

El problema experimental consiste en comparar ambas familias bajo particiones equivalentes y múltiples criterios de evaluación. No basta con observar exactitud o F1. Un modelo destinado a ordenar casos puede preferirse por ROC AUC o PR AUC; uno destinado a producir probabilidades puede requerir mejor calibración; y un modelo que toma decisiones binarias puede cambiar sustancialmente al mover el umbral. La investigación separa estas dimensiones para evitar afirmar que una única métrica demuestra superioridad general.

1.2. Preguntas de investigación

El trabajo se organiza alrededor de las siguientes preguntas:

1. ¿Cuánta señal predictiva sobre el resultado de una contratación contiene el PBC publicado al inicio del proceso?
2. ¿Cómo se comparan los embeddings densos producidos por un LLM congelado y la representación léxica TF-IDF al extraer esa señal?
3. ¿El modelado explícito de relaciones entre fragmentos aporta una ventaja frente a promediar los embeddings del mismo codificador?
4. ¿Las conclusiones cambian al distinguir ordenamiento, desempeño a umbral fijo, calibración y sensibilidad al umbral?

5. ¿Qué limitaciones de cobertura y representatividad deben considerarse antes de trasladar los resultados a un escenario operativo paraguayo?

Las preguntas se formulan en términos comparativos y no causales. La investigación no intenta demostrar que ciertas palabras provoquen un resultado, ni que una puntuación predicha constituya evidencia jurídica. Busca medir la información predictiva presente en el documento antes del desenlace y caracterizar el comportamiento de diferentes representaciones.

1.3. Objetivos

1.3.1. Objetivo general

Comparar representaciones léxicas y representaciones densas basadas en modelos grandes de lenguaje para predecir resultados de licitaciones públicas de obras viales en Paraguay a partir de PBC publicados antes del resultado final.

1.3.2. Objetivos específicos

1. Construir un subconjunto supervisado que vincule estados de procesos de contratación de la DNCP con PBC descargados, texto extraído y representaciones documentales.
2. Cuantificar la señal predictiva contenida en los PBC mediante una evaluación externa al entrenamiento y su comparación con referencias triviales.
3. Comparar el desempeño de embeddings densos producidos por un LLM congelado con el de una representación léxica TF-IDF.
4. Determinar si el modelado explícito de relaciones entre fragmentos aporta ventajas frente a la agregación por promedio de los mismos embeddings.
5. Caracterizar las diferencias entre modelos en términos de ordenamiento, desempeño a umbral fijo, calibración y sensibilidad al umbral.
6. Identificar las limitaciones de cobertura documental, extracción, cómputo, prevalencia y transferencia al entorno real.

1.4. Alcance y delimitaciones

El universo de origen corresponde a procesos paraguayos de construcción vial asociados al código de catálogo 72131701. La unidad de análisis es el proceso de contratación emparejado con un PBC. La etiqueta positiva corresponde al estado **complete**; la clase negativa agrupa **unsuccessful**, **cancelled** y su variante ortográfica **canceled**. Esta operacionalización permite un experimento reproducible, pero no agota la noción administrativa o económica de éxito.

El análisis se delimita al subconjunto que completó todas las etapas técnicas: disponibilidad del PDF, extracción de texto y generación de embeddings. No se incluyen procesos sin documento recuperado, PDF escaneados que requieren reconocimiento óptico de caracteres ni documentos que no pudieron codificarse con la infraestructura utilizada. Estas exclusiones condicionan la representatividad y se cuantificarán en el capítulo de propuesta experimental.

La investigación tampoco desarrolla un sistema de decisión autónoma. Una aplicación futura requeriría validación temporal, recalibración con la prevalencia de despliegue, revisión de sesgos entre organismos, definición explícita de costos de error y mecanismos de supervisión humana. La recomendación de la OCDE sobre contratación pública vincula el uso de sistemas electrónicos y datos con transparencia, integridad, acceso y evaluación del desempeño; este marco respalda el uso analítico, pero también exige gobernanza [16].

1.5. Contribuciones

Las contribuciones del trabajo son cuatro. Primero, presenta una canalización reproducible centrada en PBC paraguayos, desde la consulta de procesos hasta la evaluación. Segundo, compara en condiciones homogéneas una representación léxica, dos agregadores de embeddings y un modelo de interacciones entre fragmentos. Tercero, informa métricas de ordenamiento y calibración por separado, evitando reducir la comparación a una sola cifra. Cuarto, documenta el embudo de datos y sus fallos, de modo que la cobertura observada forme parte de la interpretación y no quede oculta como una decisión de preprocesamiento.

1.6. Organización del libro

El Capítulo 2 presentará el marco institucional y conceptual de la contratación pública y de los sistemas digitales que respaldan su registro y publicación, así como los fundamentos de representación textual, transformers, clasificación, calibración y evaluación. El Capítulo 3 revisará investigaciones de contratación pública y clasificación de documentos extensos, con Paraguay como contexto principal y otros países como comparación. El Capítulo 4 describirá la construcción del conjunto de datos, la canalización, los modelos y el protocolo que se empleará. El Capítulo 5 expondrá las pruebas y analizará sus resultados. Finalmente, el Capítulo 6 sintetizará las conclusiones y propondrá trabajos futuros.

Capítulo 2

Marco teórico

Este capítulo presenta los conceptos necesarios para interpretar el problema, los modelos y las métricas. Primero se describe la contratación pública como un proceso administrativo y se explica cómo sus actuaciones se registran y publican mediante sistemas digitales, ubicando al PBC dentro de ese ciclo. Luego se introducen las representaciones léxicas y densas, el procesamiento de documentos extensos y la arquitectura transformer. Finalmente se desarrollan los fundamentos de clasificación binaria, desbalance, calibración y validación experimental.

2.1. Contratación pública y cadena de suministro en Paraguay

La Ley N.º 7021/2022 crea el Sistema Nacional de Suministro Público y regula al Sistema Nacional de Contrataciones Públicas como parte de una cadena integrada [1]. Esta formulación amplía el foco desde el acto de adjudicar hacia una sucesión de actividades: planificación de la necesidad, estimación, estrategia de adquisición, convocatoria, evaluación, contratación, ejecución y cierre. Cada etapa produce datos y documentos con distinto momento de disponibilidad.

La cadena integrada es más amplia que una licitación concreta. Comienza con la identificación y planificación de necesidades, continúa con la programación presupuestaria y la elaboración del Programa Anual de Contrataciones, e incorpora un estudio de mercado para estimar costos, conocer la oferta disponible y definir la estrategia de adquisición. Estas decisiones determinan el procedimiento de selección, los requisitos de participación y los criterios con los que se evaluarán las ofertas, conforme a los artículos 6, 9, 10, 13 y 25–28 de la Ley N.º 7021/2022 [1].

Dentro de la gestión de la contratación, la convocante elabora y aprueba el PBC antes de publicar la convocatoria. Desde ese momento, los potenciales oferentes pueden consultar el documento y solicitar aclaraciones; la convocante puede emitir modificaciones, que pasan a integrar las bases del llamado. Luego se presentan y abren las ofertas técnicas y económicas. Un comité verifica su conformidad con el PBC, analiza los criterios técnicos y económicos y emite un informe que sirve de fundamento para adjudicar, declarar desierto o cancelar el procedimiento. La adjudicación selecciona al oferente con quien se formalizará el contrato, pero todavía no equivale a la ejecución ni al cierre de la contratación. Esta secuencia se encuentra regulada en los artículos 45–55 de la misma ley [1].

Después de la adjudicación se formaliza el contrato y se designa a quien controlará su cumplimiento. Durante la ejecución se registran avances, pagos, garantías, modificaciones e incumplimientos. En obras públicas, además, se realizan mediciones, certificaciones, fiscalización y recepciones parciales o definitivas. El ciclo concluye, según corresponda, con la recepción, la liquidación y la evaluación de si la contratación contribuyó a las metas institucionales, de acuerdo con los artículos 58–83 [1]. Por tanto, el resultado estudiado en este trabajo se ubica dentro de un proceso administrativo más amplio y no representa por sí solo una evaluación integral del contrato ni de la obra.

La temporalidad es central para un problema predictivo. Los datos de planificación y convocatoria están disponibles antes del resultado; los datos de adjudicación y contrato aparecen después. Si el propósito es estimar un desenlace antes de que ocurra, las variables deben limitarse a información accesible en ese momento. Utilizar campos posteriores aumentaría artificialmente el desempeño y constituiría fuga de información. Por ello, esta investigación utiliza texto de PBC y excluye del vector de entrada la adjudicación, la evaluación posterior y el estado final que define la etiqueta.

El SICP es el soporte informático donde se registran y publican actuaciones del proceso paraguayo. La DNCP expone una API de servicios para datos actuales y archivos estáticos para reconstrucción histórica desde 2010 [4]. La propia DNCP advierte que los conjuntos publicados reproducen la información remitida por las entidades convocantes y que la responsabilidad sobre su veracidad recae en ellas [17]. Esta característica importa metodológicamente: un registro abierto es una fuente oficial de publicación, pero no garantiza por sí solo ausencia de errores, campos faltantes o diferencias de calidad entre instituciones.

2.2. Datos abiertos y Estándar de Datos para las Contrataciones Abiertas

El Estándar de Datos para las Contrataciones Abiertas (OCDS) propone un modelo común para divulgar información y documentos durante todo el proceso de contratación. Organiza la información en etapas de licitación, adjudicación, contrato e implementación, y permite registrar sucesivas publicaciones de un mismo proceso [5, 18]. La estandarización facilita combinar fuentes, reconstruir cambios y reutilizar herramientas analíticas; no reemplaza, sin embargo, al sistema transaccional que origina los datos [19].

En OCDS, una publicación o *release* representa información correspondiente a un evento del ciclo. Varias publicaciones pueden compilarse en un registro que resume el proceso. Entidades compradoras, proveedores, valores, períodos, artículos, documentos y estados se expresan mediante estructuras y listas controladas. Paraguay adopta este estándar con extensiones locales y ofrece endpoints de consulta sobre procesos completos [4, 17].

Para este trabajo son relevantes tres niveles de información:

1. **Metadatos del proceso:** identificador de contratación, OCID, estado y clasificación del objeto.
2. **Metadatos documentales:** título, tipo, formato y URL de los adjuntos asociados a la convocatoria.
3. **Contenido no estructurado:** texto interno del PBC descargado, que no está reducido a los campos del esquema.

La clasificación de catálogo 72131701 delimita los procesos de construcción de rutas. El código se utiliza como filtro técnico de la consulta y no como una inferencia posterior. La elección reduce heterogeneidad temática, dado que compara documentos de un mismo ámbito, pero también restringe la validez externa a otras obras, bienes o servicios.

2.3. Pliego de Bases y Condiciones

El PBC comunica a potenciales oferentes las condiciones del procedimiento. OCDS define los documentos de licitación como documentación que describe el objeto y el proceso de presentación de ofertas; separa además las especificaciones técnicas y los criterios de evaluación [6]. En la práctica, un archivo paraguayo puede integrar varias de estas funciones, junto con formularios y anexos.

Desde la perspectiva del procesamiento del lenguaje natural, el PBC presenta varias propiedades:

- **Longitud:** puede superar ampliamente el límite de entrada de un codificador convencional.
- **Estructura semiformateada:** alterna párrafos, títulos, listas y tablas.
- **Redundancia:** reutiliza cláusulas y plantillas institucionales.
- **Especialización:** incluye terminología jurídica, administrativa y de ingeniería vial.
- **Variabilidad:** cambia según convocante, año, modalidad, complejidad y anexos.

Estas propiedades explican por qué no existe una representación obviamente superior. La repetición puede favorecer n-gramas; la equivalencia semántica entre formulaciones puede favorecer embeddings; y la dispersión de información a lo largo del documento puede justificar modelos jerárquicos.

2.4. Clasificación supervisada y resultado que se busca predecir

El estudio busca anticipar el estado con el que cada contratación queda registrada a partir del texto de su PBC. Para ello se utilizan únicamente procesos que cuentan con un documento aprovechable y con uno de los estados finales considerados. Los estados se agrupan en dos resultados:

- Se considera exitoso el proceso registrado como **complete**.
- Se considera no exitoso el proceso registrado como **unsuccessful**, **cancelled** o **canceled**.

Los términos **cancelled** y **canceled** expresan el mismo estado, “cancelado”, con las grafías británica y estadounidense del inglés; ambos aparecen en los datos de origen y por eso se normalizan dentro del mismo grupo. Reducir los estados a estas dos alternativas convierte el problema en una clasificación binaria: para cada PBC, el modelo estima la probabilidad de que el proceso pertenezca al primer grupo.

Los registros con otros estados se excluyen del entrenamiento y de la evaluación. Esta agrupación es una decisión operativa basada en la fuente disponible. Un proceso **complete**

no implica necesariamente máximo valor público, y una cancelación puede responder a causas legítimas; por tanto, la etiqueta no constituye una evaluación integral de éxito, eficiencia o integridad.

Formalmente, cada ejemplo se representa mediante un par (x_i, y_i) , donde x_i es el texto del PBC y $y_i \in \{0, 1\}$ es la etiqueta: se asigna $y_i = 1$ al resultado exitoso y $y_i = 0$ al no exitoso. El modelo aprende una función que produce la probabilidad estimada de pertenecer al primer grupo:

$$f(x_i) = \hat{p}_i \approx P(y_i = 1 \mid x_i). \quad (2.1)$$

Así, $\hat{p}_i$ no expresa una certeza ni una valoración jurídica del proceso, sino la probabilidad que el modelo asigna al estado operacionalizado como exitoso a partir del texto disponible.

2.5. Procesamiento de documentos

2.5.1. Extracción de texto desde PDF

PDF describe la disposición visual de una página y no necesariamente conserva una secuencia textual limpia. La extracción debe reconstruir palabras y líneas a partir de objetos posicionados. El repositorio utiliza **pdfplumber** para texto y contempla **Camelot** para tablas. Los documentos compuestos únicamente por imágenes requieren reconocimiento óptico de caracteres, capacidad que no forma parte de la ejecución documentada. Por eso, tres PDF escaneados no generaron texto y quedaron fuera de etapas posteriores.

Los errores de extracción pueden alterar saltos, orden de columnas, caracteres y tablas. En un modelo léxico, estas alteraciones modifican términos y n-gramas; en un tokenizador subléxico, cambian la segmentación. Documentar las pérdidas evita atribuir al modelo limitaciones originadas en la digitalización.

2.5.2. Tokenización

Un tokenizador transforma texto en identificadores del vocabulario del modelo. Los modelos preentrenados suelen usar unidades subléxicas: una palabra puede corresponder a uno o varios tokens. Esto permite representar vocabulario abierto, pero significa que el número de palabras no coincide con la longitud computacional. La configuración del

proyecto tokeniza sin truncamiento inicial, conserva la secuencia en CPU y transfiere a GPU únicamente microlotes de fragmentos.

2.5.3. Fragmentación con solapamiento

Sea una secuencia de T tokens, un tamaño máximo de fragmento L y un desplazamiento S . Los comienzos se ubican en $0, S, 2S, \dots$ hasta cubrir el documento. Cuando $S < L$, fragmentos consecutivos comparten $L - S$ tokens. En este estudio $L = 4096$ y $S = 2048$, de modo que el solapamiento nominal es del 50 %.

El solapamiento reduce la probabilidad de cortar una relación justo en una frontera, aunque incrementa la cantidad de cómputo y introduce contenido repetido. La cantidad aproximada de fragmentos para $T > L$ es:

$$N \approx 1 + \left\lceil \frac{T - L}{S} \right\rceil. \quad (2.2)$$

La implementación no impone por defecto un máximo documental adicional. En consecuencia, documentos muy extensos producen secuencias de muchos embeddings y demandan más memoria tanto en codificación como en la agregación posterior.

2.6. Representación léxica

2.6.1. Modelo de espacio vectorial

Una representación de bolsa de palabras describe un documento mediante la presencia o frecuencia de términos y omite el orden global. Si el vocabulario contiene V términos, cada documento se transforma en $x \in \mathbb{R}^V$. La matriz resultante es dispersa porque cada documento utiliza solo una fracción del vocabulario.

La frecuencia de término $tf(t, d)$ mide cuántas veces aparece el término t en el documento d . La frecuencia inversa de documento reduce el peso de términos presentes en muchos documentos. Una forma habitual es:

$$idf(t) = \log \left(\frac{M + 1}{df(t) + 1} \right) + 1, \quad (2.3)$$

donde M es la cantidad de documentos y $df(t)$ la cantidad que contiene t . El peso combinado es:

$$tfidf(t, d) = tf(t, d) idf(t). \quad (2.4)$$

La ponderación TF-IDF pertenece a una familia de esquemas de importancia de términos estudiada en recuperación de información; Salton y Buckley mostraron que la elección del esquema de ponderación es decisiva para el desempeño de representaciones de términos individuales [20]. En clasificación, unigramas capturan vocabulario y bigramas preservan patrones locales como expresiones administrativas frecuentes.

2.6.2. Regresión logística

La regresión logística define la probabilidad positiva mediante:

$$\hat{p}(y = 1 \mid x) = \sigma(w^\top x + b), \quad \sigma(z) = \frac{1}{1 + e^{-z}}. \quad (2.5)$$

Los coeficientes w asocian dimensiones léxicas con el logaritmo de las razones de probabilidades. Esta linealidad facilita inspeccionar términos con pesos altos o bajos, aunque la interpretación requiere cautela ante correlaciones, n-gramas redundantes y regularización.

El modelo del proyecto limita el vocabulario a 50.000 características, incluye unigramas y bigramas, descarta términos con frecuencia documental inferior a cinco y usa pesos balanceados por clase. La frecuencia documental cuenta en cuántos documentos distintos aparece un término, con independencia de la cantidad de veces que se repita dentro de cada uno. El umbral de cinco se fijó como un criterio conservador de filtrado: elimina términos presentes únicamente en unos pocos documentos, más susceptibles a corresponder a errores de extracción, identificadores únicos o asociaciones espurias, pero conserva expresiones recurrentes incluso cuando aparecen en una proporción pequeña del corpus. En cada pliegue, con aproximadamente 930 documentos de entrenamiento, este requisito representa cerca del 0,54 % y constituye, por tanto, un filtro poco restrictivo. El valor se estableció como un hiperparámetro del diseño experimental y no se optimizó sobre los pliegues externos de evaluación. Los pesos balanceados modifican la contribución de cada clase a la función de pérdida, sin cambiar la prevalencia real del conjunto de evaluación.

2.7. Representaciones densas y modelos de lenguaje

Una representación densa asigna el texto a un vector de dimensión fija cuyo contenido se aprende durante el preentrenamiento. A diferencia de TF-IDF, las dimensiones no

corresponden directamente a términos. BERT demostró que representaciones bidireccionales preentrenadas podían adaptarse a múltiples tareas con pocas capas específicas [21]. Trabajos posteriores extendieron el uso de modelos grandes para producir embeddings generales mediante aprendizaje contrastivo o instrucciones [12, 22].

El proyecto utiliza `openai/gpt-oss-20b`, un modelo causal de pesos abiertos, como codificador congelado [23]. Para cada fragmento se extrae el estado oculto del último token válido. Al congelar el codificador, sus parámetros no se actualizan con las etiquetas; el aprendizaje supervisado ocurre únicamente en el agregador o clasificador posterior. Esto reduce el costo de entrenamiento repetido y separa la representación preentrenada del efecto del clasificador.

Un embedding útil no garantiza automáticamente el mejor resultado para todos los dominios. La calidad depende del idioma, el tipo documental, el objetivo de preentrenamiento, el método de pooling y la correspondencia entre las tareas de origen y destino. Por ello, el valor de la representación debe medirse empíricamente frente a líneas base apropiadas.

2.8. Arquitectura transformer

El transformer reemplaza recurrencia por atención y capas prealimentadas [13]. A partir de una secuencia de entrada, el mecanismo construye tres matrices: las consultas Q , que representan la información buscada por cada posición; las claves K , contra las cuales se comparan las consultas; y los valores V , cuyo contenido se combina para producir la salida. Si d_k es la dimensión de cada clave, la atención de producto punto escalado se expresa como:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^\top}{\sqrt{d_k}} \right) V. \quad (2.6)$$

El producto $QK^\top$ contiene los puntajes de similitud entre consultas y claves. La división por $\sqrt{d_k}$ evita que su magnitud crezca excesivamente al aumentar la dimensión. La función *softmax*, aplicada sobre los puntajes de cada consulta, los transforma en pesos no negativos cuya suma es uno. La multiplicación posterior por V produce, para cada posición, una combinación ponderada de los valores.

La atención multicabeza proyecta las entradas en h subespacios, calcula atenciones paralelas y concatena sus resultados. Para la cabeza i :

$$\text{head}_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V), \quad (2.7)$$

donde W_i^Q , W_i^K y W_i^V son matrices de proyección aprendidas. Las salidas de las h cabezas se combinan mediante:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(\text{head}_1, \dots, \text{head}_h)W^O. \quad (2.8)$$

La matriz aprendida W^O proyecta la concatenación a la dimensión de salida del bloque. Cada cabeza puede enfatizar relaciones diferentes. Sin embargo, la matriz $QK^\top$ tiene tamaño cuadrático respecto de la longitud. Longformer reduce este costo combinando ventanas locales y atención global dispersa [14]. Otra familia de soluciones adopta una jerarquía: codifica fragmentos por separado y modela luego la secuencia de representaciones. Estudios comparativos muestran que la posibilidad de procesar más texto suele ser beneficiosa, aunque el método óptimo depende del dominio y la distribución de longitudes [15, 24].

2.9. Agregación de fragmentos

2.9.1. Promedio

Dados embeddings $e_1, \dots, e_N$, el promedio documental es:

$$\bar{e} = \frac{1}{N} \sum_{i=1}^N e_i. \quad (2.9)$$

El método es económico e invariante al orden. Esta última propiedad es también su limitación: no distingue qué fragmento apareció primero ni modela relaciones entre secciones. Aun así, líneas base de pooling simple han demostrado ser competitivas en múltiples tareas, por lo que omitirlas puede exagerar el valor de arquitecturas más complejas [25].

2.9.2. Transformer entre fragmentos

El predictor principal proyecta cada $e_i \in \mathbb{R}^{2880}$ a $d_{\text{model}} = 128$, inserta un vector [CLS] entrenable y aplica una capa de codificador con cuatro cabezas, dimensión interna 512 y dropout 0,3. El vector final [CLS] alimenta una cabeza multicapa. A diferencia del promedio, este mecanismo puede asignar pesos contextuales y modelar interacciones; a diferencia de aplicar el LLM completo durante cada pliegue, reutiliza embeddings congelados.

Las máscaras de relleno distinguen fragmentos reales de posiciones añadidas para formar lotes. Sin ellas, el modelo podría atender a valores de relleno y aprender artefactos asociados a la longitud. La arquitectura implementada utiliza normalización previa y activación GELU, conforme a la capa `TransformerEncoderLayer` disponible en PyTorch.

2.10. Representación documental

Cada documento PBC se convierte primero de PDF a texto mediante la canalización de extracción previa. El texto resultante se tokeniza y divide en fragmentos superpuestos. En la implementación actual, cada fragmento tiene una longitud de 4096 tokens y un desplazamiento de 2048 tokens. Se utiliza el modelo de lenguaje causal preentrenado `openai/gpt-oss-20b` como codificador documental congelado [23]. Este modelo se seleccionó como un LLM práctico de pesos abiertos para extraer representaciones densas de textos de contratación en español y, a la vez, mantener reproducible la canalización experimental. Congelar el codificador también evita ajustar un modelo grande sobre un conjunto de datos modesto y permite que la comparación se concentre en cuánta señal existe en las representaciones preentrenadas y cómo se agrega posteriormente, en consonancia con trabajos recientes sobre embeddings textuales basados en LLM [12]. Los fragmentos se procesan en microlotes para reducir la presión sobre la memoria de la GPU.

Para cada fragmento, el sistema extrae la representación oculta asociada al último token válido. La salida correspondiente a un documento de contratación es, por tanto, una secuencia de embeddings de fragmentos:

$$\mathbf{E} = [\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_N], \quad \mathbf{e}_i \in \mathbb{R}^{d_{in}},$$

donde N es la cantidad de fragmentos del documento y d_{in} está determinado por el tamaño oculto del modelo preentrenado. Esta configuración permite comparar dos estrategias de representación basadas en LLM: un vector documental simple obtenido mediante el promedio de los fragmentos y un modelo secuencial que aprende las interacciones entre ellos.

2.11. Arquitectura del predictor

El clasificador principal, `TenderSuccessPredictor`, es un transformer liviano aplicado sobre los embeddings de los fragmentos. Sea $\mathbf{E} \in \mathbb{R}^{N \times d_{in}}$ la secuencia de fragmentos de un documento. El modelo aplica:

1. Una proyección lineal de d_{in} a una dimensión latente entrenable d_{model} .
2. La inserción de un token aprendido [CLS] al comienzo de la secuencia.
3. Un codificador transformer sobre la secuencia completa de vectores de fragmentos.
4. Una pequeña cabeza de clasificación multicapa sobre la representación final de [CLS].

En los experimentos actuales, los hiperparámetros posteriores son: $d_{model} = 128$, $n_{heads} = 4$, dimensión de la red prealimentada = 512, dropout = 0,3 y una capa de codificación. Se emplean máscaras de relleno para agrupar de forma segura documentos con diferentes cantidades de fragmentos.

El modelo produce un único logit por documento. Una transformación sigmoide convierte este logit en una probabilidad de éxito:

$$\hat{p}(y = 1 \mid \mathbf{E}) = \sigma(z).$$

El entrenamiento utiliza entropía cruzada binaria con logits.

2.12. Líneas base

Para interpretar los resultados basados en LLM, se evalúan tres clases de líneas base.

En primer lugar, se emplean dos referencias triviales: un clasificador de clase mayoritaria y un clasificador aleatorio cuya tasa positiva coincide con la prevalencia empírica. Estas líneas base establecen la región esperada sin capacidad predictiva, donde ROC AUC debería situarse cerca de 0,5 y PR AUC cerca de la prevalencia positiva.

En segundo lugar, se utiliza una línea base léxica con características TF-IDF de hasta 50.000 unigramas y bigramas, frecuencia documental mínima de 5 y un clasificador de regresión logística con pesos de clase balanceados. Se utiliza TF-IDF en lugar de embeddings densos estáticos como Word2Vec porque proporciona una referencia sólida e interpretable de bolsa de palabras que sigue siendo competitiva en documentos extensos [10, 11]. Además, permite aislar la comparación con representaciones congeladas de LLM sin añadir otra etapa entrenable de embeddings bajo supervisión limitada. Las líneas base lineales de bolsa de palabras son referencias habituales en clasificación de textos [10], y la evidencia reciente sobre documentos extensos indica que las representaciones léxicas aún son competitivas en algunos escenarios [11].

En tercer lugar, se definen dos líneas base intermedias basadas en LLM que utilizan los mismos embeddings preentrenados de fragmentos que el sistema principal, pero sustituyen el transformer entre fragmentos por una agregación documental más simple. En la primera variante, se promedian los embeddings de los fragmentos y se suministran a una regresión logística. En la segunda, la misma representación promedio alimenta un pequeño perceptrón multicapa con una capa oculta. Estas líneas base aíslan el valor de la representación del valor aportado por el modelado explícito de las interacciones entre fragmentos.

2.13. Entrenamiento y reproducibilidad

El entrenamiento utiliza AdamW, una tasa de aprendizaje de 10^{-4} , decaimiento de pesos de 0,01, lotes de tamaño 8 y hasta 50 épocas. Dentro de cada ronda de validación cruzada, una época corresponde a un recorrido completo por la porción de entrenamiento de esa ronda. Después de cada época se calcula la pérdida de validación sobre la porción reservada; si no mejora durante cinco épocas consecutivas, el entrenamiento se detiene y se restaura el mejor punto de control. La reproducibilidad se controla mediante semillas fijas, comportamiento determinista de cuDNN, cargadores de datos con semilla y reinicios independientes del estado aleatorio al comienzo de cada pliegue.

2.14. Desbalance de clases

Un conjunto está desbalanceado cuando las clases tienen frecuencias distintas. La exactitud simple puede ser engañosa: un clasificador que predice siempre la mayoría obtiene una exactitud igual a su prevalencia sin separar casos. La exactitud balanceada promedia la sensibilidad de cada clase:

$$BA = \frac{1}{2} \left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP} \right). \quad (2.10)$$

El puntaje F1 combina precisión y exhaustividad de la clase positiva:

$$F1 = 2 \frac{Precision \cdot Recall}{Precision + Recall}. \quad (2.11)$$

F1 depende de cuál clase se declara positiva y del umbral. En este estudio la clase positiva es además la mayoritaria del subconjunto procesado, por lo que PR AUC debe compararse con la prevalencia y no con cero. Richardson et al. subrayan que ROC y

PR responden de manera distinta al balance y que su interpretación debe ajustarse a la pregunta de evaluación [26].

2.15. Ordenamiento y umbral de decisión

ROC AUC estima la probabilidad de que un ejemplo positivo reciba un puntaje mayor que uno negativo. No requiere fijar un umbral. PR AUC resume precisión y exhaustividad al variar el umbral, y su referencia sin habilidad se relaciona con la prevalencia positiva. Ambas evalúan ordenamiento; no garantizan probabilidades calibradas.

Para obtener una clase se aplica un umbral τ :

$$\hat{y} = \mathbb{I}(\hat{p} \geq \tau). \quad (2.12)$$

El valor 0,5 es convencional, pero no universalmente óptimo. La selección debe realizarse con datos distintos del conjunto donde se informa el resultado, pues elegir τ sobre el pliegue de prueba sobreajustaría la métrica. El protocolo usa una partición interna de validación y aplica el umbral elegido al pliegue externo sin modificarlo.

2.16. Calibración probabilística

Un clasificador está calibrado si, entre casos con probabilidad predicha cercana a p , la frecuencia observada del evento es aproximadamente p . Guo et al. mostraron que redes modernas pueden lograr buena exactitud y, al mismo tiempo, producir confianzas mal calibradas [27]. Por ello, ordenamiento y calibración son propiedades distintas.

El puntaje de Brier binario es:

$$BS = \frac{1}{M} \sum_{i=1}^M (\hat{p}_i - y_i)^2. \quad (2.13)$$

La pérdida logarítmica es:

$$LL = -\frac{1}{M} \sum_{i=1}^M [y_i \log \hat{p}_i + (1 - y_i) \log(1 - \hat{p}_i)]. \quad (2.14)$$

Ambas son reglas propias: favorecen probabilidades honestas bajo sus supuestos. Sin embargo, el Brier combina componentes de confiabilidad y resolución; un valor menor

no debe interpretarse como medida pura de calibración sin considerar discriminación y curvas de confiabilidad [28]. En consecuencia, este estudio acompaña los puntajes con diagramas de calibración.

2.17. Validación cruzada y reproducibilidad

La validación cruzada de K pliegues divide los datos en K subconjuntos. En cada ronda se entrena con $K - 1$ y se evalúa con el restante. La estratificación conserva aproximadamente la proporción de clases. Al agregar predicciones externas de todas las rondas, cada ejemplo es evaluado por un modelo que no lo utilizó para ajustarse.

El código fija semilla global y semillas independientes por pliegue, activa comportamiento determinista de cuDNN, inicializa cargadores de datos con generadores controlados y restaura el mejor punto de control mediante detención temprana. AdamW desacopla el decaimiento de pesos del paso adaptativo de optimización [29]. MLflow registra parámetros, métricas y artefactos; la trazabilidad permite verificar que comparaciones distintas utilizaron las mismas particiones y reglas de etiqueta.

La reproducibilidad no elimina toda variación. Diferencias de hardware, bibliotecas, kernels o implementaciones pueden producir cambios numéricos. El propósito de las medidas adoptadas es reducir fuentes evitables y hacer explícita la configuración, no prometer identidad absoluta bajo cualquier plataforma.

Capítulo 3

Trabajos relacionados y estado del arte

En este capítulo se revisarán trabajos vinculados con la apertura y el análisis de contrataciones públicas, la predicción de resultados a partir de datos administrativos y texto, y la clasificación de documentos extensos. Paraguay constituye el contexto central; los estudios de otros países se utilizarán para comparar objetivos, fuentes y métodos, sin asumir que sus patrones se transfieren automáticamente al SICP.

3.1. Instituciones y fuentes relacionadas en Paraguay

3.1.1. Dirección Nacional de Contrataciones Públicas

La DNCP administra el portal de contrataciones y publica datos derivados de la información remitida por organismos y entidades del Estado. Su portal ofrece servicios de procesos, descargas históricas, diccionarios y documentación para desarrolladores [17]. La institución adoptó OCDS para divulgar información de planificación, convocatoria, adjudicación, contratos y modificaciones mediante una API y archivos estáticos [4].

La Ley N.º 7021/2022 asigna al registro digital un papel estructural dentro de la cadena de suministro. La reforma incorpora principios de eficiencia, competencia, transparencia, integridad y valor por dinero, y se acompaña de reglamentaciones sobre comunicación de procedimientos, ofertas electrónicas y seguimiento contractual [2, 30]. Para esta investigación, la DNCP es simultáneamente la fuente de metadatos, estados y documentos de convocatoria.

La plataforma de ofertas electrónicas ilustra la digitalización progresiva del ciclo: permite presentar y abrir ofertas mediante el SICP cuando corresponde, con el objetivo institucional de agilizar procedimientos y optimizar el trabajo de convocantes y proveedores [31]. Aunque el presente estudio no utiliza ofertas como entrada, este proceso confirma que una proporción creciente de evidencia administrativa se origina y conserva digitalmente.

3.1.2. Sistema de Información de las Contrataciones Públicas

El SICP concentra la publicación operativa de los procedimientos. Para análisis masivos, la capa de datos abiertos evita depender únicamente de interfaces destinadas a consulta humana. El endpoint utilizado por el proyecto devuelve registros con una publicación compilada, de la cual se extraen el identificador del tender, el OCID y los identificadores de adjudicación. La consulta filtra por estado y código de clasificación.

El proyecto no descarga un conjunto tabular cerrado y luego le atribuye documentos por semejanza. Conserva el `tenderId` como clave de unión entre la respuesta de la API, el PBC, el texto y el archivo de embeddings. Este diseño reduce errores de emparejamiento y permite auditar el recorrido de cada ejemplo.

3.1.3. Gobierno electrónico y control público

El Ministerio de Tecnologías de la Información y Comunicación ubica el portal único de datos abiertos, la interoperabilidad y el acceso a información entre las líneas de gobierno electrónico de Paraguay [3]. La Contraloría General de la República mantiene además un portal de rendición de cuentas cuyo propósito declarado es fomentar transparencia, eficiencia y participación ciudadana [32]. Estas iniciativas muestran que el análisis de contratación forma parte de un ecosistema de datos estatales más amplio.

La existencia de datos abiertos permite desarrollar indicadores y modelos fuera de la institución publicadora. No obstante, las decisiones de control permanecen sujetas a competencias legales, verificación documental y debido proceso. Una puntuación de aprendizaje automático no reemplaza estos procedimientos.

3.2. Analítica de contratación pública

La analítica de contratación puede orientarse a descripción, detección de anomalías, estimación de competencia, pronóstico de demoras, sobre costos, quejas o estados finales. Estas tareas difieren en la variable objetivo y en el momento de predicción. Un modelo que

utiliza información contractual posterior no es comparable con otro que opera únicamente durante la convocatoria.

En el contexto paraguayo, Kehler, Paciello y Pane aplicaron un bosque de aislamiento sobre datos estructurados de contrataciones publicados conforme a OCDS para asignar puntajes de anomalía a los procesos [33]. Al contrastar el modelo con un conjunto local de procesos que presentaban protestas resueltas a favor del protestante o denuncias ciudadanas, más del 45 % de los casos potencialmente anómalos fueron clasificados como tales. Este antecedente demuestra la viabilidad de utilizar los datos abiertos de la DNCP para priorizar revisiones mediante aprendizaje no supervisado. Su objetivo y su entrada difieren de los del presente trabajo: analiza anomalías en campos estructurados de distintas etapas, mientras que esta investigación predice un estado final a partir del texto del PBC disponible antes del resultado.

Los indicadores de riesgo basados en reglas suelen codificar señales definidas por especialistas: único oferente, plazos inusuales, concentración de adjudicaciones o modificaciones. Los modelos supervisados, en cambio, aprenden relaciones a partir de ejemplos etiquetados. Ambos enfoques pueden complementarse. VigIA combina índices de riesgo con modelos de aprendizaje automático para anticipar sobrecostos y demoras en Bogotá, priorizando casos para supervisión [7]. Sus variables más importantes incluyen valor, tiempos contractuales, antigüedad del proveedor y sector; son metadatos estructurados, no texto completo de la convocatoria.

Gallego, Rivero y Martínez desarrollaron un modelo de advertencia temprana sobre irregularidades en contratación, enfatizando la prevención y la asignación limitada de recursos de control [8]. Aldana, Falcón-Cortés y Larralde propusieron para México un ensamble de bosques aleatorios orientado a identificar contratos asociados a corrupción; encontraron que variables sobre relaciones entre compradores y proveedores podían ser más informativas que rasgos individuales del contrato [34]. Estos trabajos muestran el potencial de los datos administrativos, pero responden a etiquetas y marcos institucionales distintos al estado final utilizado en Paraguay.

3.3. Predicción a partir del texto de convocatorias

El antecedente más cercano por tipo de entrada es el trabajo de Acikalin et al., que estudió si las descripciones de convocatorias públicas permitían predecir resultados asociados con competencia y costo-efectividad [9]. Sus experimentos aportan evidencia de que el lenguaje publicado antes del resultado contiene señal predictiva. La unidad textual, el país, las etiquetas y la extensión documental difieren del presente estudio, por lo que

la contribución no se replica de forma directa: se traslada la pregunta general a PBC completos de construcción vial paraguaya.

Una descripción breve y un PBC no son equivalentes. La primera suele condensar el objeto; el segundo incluye condiciones, criterios y anexos. Esta riqueza puede aportar señal adicional, pero también ruido y costo computacional. Por ello, el presente trabajo compara una representación capaz de considerar el vocabulario global con estrategias jerárquicas sobre fragmentos.

3.4. Clasificación de documentos extensos

Dai et al. compararon transformers de atención dispersa con enfoques jerárquicos en cuatro conjuntos de clasificación de documentos extensos. Sus resultados mostraron beneficios al procesar mayor cantidad de texto y señalaron que decisiones como tamaño de ventana, atención global y estrategia de división afectan el desempeño [15]. El trabajo sustenta la necesidad de tratar la fragmentación como una decisión metodológica y no como un detalle de implementación.

Mamakas et al. estudiaron documentos jurídicos que superaban incluso los límites de modelos de atención dispersa. Compararon extensiones de Longformer, codificadores jurídicos jerárquicos y representaciones TF-IDF; observaron una relación entre desempeño y costo, y confirmaron que las líneas base dispersas conservaban utilidad [24]. Los PBC comparten con documentos jurídicos su extensión, estructura formal y lenguaje especializado, aunque su finalidad institucional es diferente.

Tuteja y González-Jucá evaluaron transformers y estrategias de selección de párrafos sobre seis conjuntos jurídicos con mediana superior a mil palabras, incluyendo una línea base TF-IDF [35]. Lu et al. investigaron modelos de espacio de estados como alternativa a la atención para clasificación extensa [36]. Han et al. señalaron que la variación de longitud puede afectar la generalización y propusieron kernels sensibles a longitud [37]. En conjunto, la literatura reciente no establece un único método dominante para todos los documentos extensos; recomienda evaluar líneas base, cobertura de texto, eficiencia y robustez entre longitudes.

3.5. Representaciones dispersas frente a densas

Las representaciones TF-IDF continúan siendo referencias relevantes porque procesan documentos completos, son eficientes y ofrecen coeficientes inspeccionables. Wang y Manning mostraron que líneas base lineales con unigramas y bigramas podían ser muy competitivas en clasificación textual [10]. Shen et al. demostraron que mecanismos simples de pooling sobre embeddings también podían competir con redes más complejas en múltiples conjuntos [25]. Estas observaciones justifican incluir tanto TF-IDF como promedio de embeddings.

Las representaciones densas preentrenadas buscan capturar similitud y contexto más allá de coincidencias exactas. E5 utiliza preentrenamiento contrastivo débilmente supervisado para producir vectores transferibles a recuperación y clasificación [38]; su variante multilingüe extiende la cobertura a varios idiomas [22]. Wang et al. exploraron el uso de LLM para mejorar embeddings mediante datos sintéticos y entrenamiento contrastivo [12]. Esta línea respalda la hipótesis de que un modelo grande congelado puede aportar información útil incluso sin ajuste completo.

Sin embargo, la comparación debe distinguir la calidad del embedding de la del agregador. Si se cambia simultáneamente codificador, longitud y cabeza, no puede atribuirse la diferencia a un componente. El diseño de este trabajo mantiene fijos los embeddings por fragmento y compara promedio más regresión logística, promedio más MLP y transformer entre fragmentos.

3.6. Evaluación y calibración en trabajos predictivos

Los trabajos de contratación suelen priorizar métricas de detección o ranking, porque la capacidad de ordenar casos puede apoyar inspecciones. Para un uso probabilístico, la calibración es igualmente importante. Guo et al. documentaron que redes con buen desempeño de clasificación podían estar mal calibradas y evaluaron métodos de posprocesamiento como escalamiento de temperatura [27]. Silva Filho et al. revisaron métodos y métricas de calibración, destacando que el puntaje de Brier combina más de un aspecto de calidad predictiva [28].

En contratación pública, una probabilidad mal calibrada puede llevar a interpretar incorrectamente una diferencia de puntajes como diferencia de riesgo absoluto. El presente estudio no propone desplegar sus probabilidades, pero informa Brier, pérdida logarítmica y curvas de calibración para caracterizar esta dimensión desde la etapa experimental.

3.7. Estado del arte

El estado del arte relevante puede sintetizarse en tres corrientes convergentes.

3.7.1. Sistemas predictivos para supervisión pública

La primera corriente utiliza datos de contratación para anticipar ineficiencias, irregularidades o resultados. Los sistemas más maduros combinan modelos con conocimiento institucional, índices de riesgo y participación de analistas. VigIA es representativo porque fue diseñado con una agencia de supervisión y seleccionó variables buscando conservar explicabilidad [7]. Los trabajos de México y otros países incorporan relaciones en redes de compradores y proveedores, mostrando que la estructura del mercado puede ser más informativa que un contrato aislado [34].

El límite de esta corriente para el presente problema es temporal y documental. Muchos modelos utilizan datos disponibles durante ejecución o después de adjudicar. Aquí se busca una señal estrictamente anterior, basada en el PBC. Esta restricción reduce variables, pero hace más realista una advertencia temprana durante la convocatoria.

3.7.2. Modelos para texto extenso

La segunda corriente reemplaza el truncamiento por mecanismos capaces de cubrir documentos largos. Longformer reduce el crecimiento de la atención mediante ventanas locales y posiciones globales [14]; los modelos jerárquicos codifican fragmentos y agregan representaciones; modelos de espacio de estados ofrecen otra vía de complejidad favorable [36]. Evaluaciones amplias concluyen que cubrir más texto ayuda, pero también que la estrategia de fragmentación, la ubicación de la evidencia y la longitud condicionan los resultados [15, 37].

El transformer entre fragmentos de este trabajo pertenece a la familia jerárquica. Su aporte no es proponer un nuevo mecanismo general de atención, sino evaluar si una capa liviana sobre embeddings congelados mejora frente a agregaciones más simples en PBC paraguayos.

3.7.3. Embeddings de modelos grandes y líneas base léxicas

La tercera corriente desarrolla embeddings reutilizables a partir de modelos preentrenados. Los avances contrastivos y multilingües han mejorado la transferencia [38, 22], mientras que LLM de mayor escala abren la posibilidad de extraer representaciones densas

sin ajustar todos sus parámetros [12]. No obstante, la literatura de documentos extensos sigue encontrando escenarios donde TF-IDF o soluciones híbridas son competitivas [24, 35].

El estado del arte no permite asumir que mayor escala implica automáticamente mejor desempeño. La evaluación adecuada requiere comparar contra referencias dispersas, separar ranking de calibración y considerar el costo de procesar documentos completos.

3.7.4. Brecha identificada

La revisión no identifica, entre las fuentes consultadas, una comparación publicada que reúna simultáneamente: PBC completos de Paraguay, predicción del estado final con información disponible antes del resultado, TF-IDF, embeddings congelados de un LLM, agregación por promedio, modelado entre fragmentos y análisis conjunto de ranking, calibración y umbrales. Esta ausencia no demuestra inexistencia absoluta de trabajos no indexados; delimita la brecha respecto del corpus revisado.

El presente estudio cubre esa brecha empírica. Su contribución se concentra en el contexto paraguayo y en la comparación controlada de representaciones. Los resultados de Colombia, México, Turquía o conjuntos jurídicos internacionales se utilizan para formular expectativas y criterios de evaluación, no para validar externamente el modelo paraguayo.

3.8. Posicionamiento del trabajo

La Tabla 3.1 resume diferencias entre antecedentes seleccionados. La columna “momento” indica cuándo están disponibles las variables principales respecto del desenlace.

TABLA 3.1: Posicionamiento frente a trabajos relacionados seleccionados.

Trabajo	Contexto	Entrada principal	Objetivo	Momento
Acikalin et al. [9]	Turquía	Descripción de convocatoria	Competencia y costo-efectividad	Antes del resultado
VigIA [7]	Colombia	Metadatos e índices	Sobrecostos, demoras e irregularidades	Mixto
Aldana et al. [34]	México	Contratos y relaciones	Identificación de corrupción	Posterior/mixto
Dai et al. [15]	Multidominio	Documentos extensos	Clasificación documental	No aplica
Este trabajo	Paraguay	PBC completos	Estado final operacionalizado	Antes del resultado

Esta comparación evidencia que la similitud metodológica no equivale a igualdad institucional. Las definiciones de resultado, las normas, la calidad de datos y las prevalencias varían por país. Cualquier transferencia futura deberá repetir validación, calibración y análisis de cobertura con datos del destino.

Capítulo 4

Propuesta de experimentación numérica

En este capítulo se describirá el diseño experimental empleado para comparar representaciones textuales en la predicción de resultados de licitaciones públicas paraguayas. Primero se presentarán el ambiente computacional y la procedencia de los datos. Luego se detallarán la descarga de PBC, la extracción de texto, la generación de embeddings, la definición de la etiqueta y los modelos. Finalmente se establecerán la partición, las métricas y las reglas de reproducibilidad que se utilizarán para evaluar cada alternativa.

La descripción se fundamenta en el código versionado del proyecto y en el embudo de artefactos observado. Cuando un detalle de infraestructura no quedó preservado en el repositorio, se indicará expresamente en vez de reconstruirlo mediante suposiciones.

4.1. Ambiente computacional

4.1.1. Hardware

La generación de embeddings se ejecutó en una instancia de cómputo acelerado en la nube, provista por RunPod y equipada con una GPU NVIDIA H200 compatible con CUDA. El proveedor se consigna como información de trazabilidad, pero no constituye un requisito de reproducción: una infraestructura equivalente puede utilizarse si ofrece los recursos y el entorno de software necesarios. El código selecciona una GPU cuando está disponible, utiliza `bfloat16` en ese caso y conserva los tokens en CPU hasta transferir cada microlote. La evidencia de ejecución registra 671 fallos `OutOfMemoryError`. La variante y la memoria exacta de la GPU, así como el modelo de procesador y la memoria

RAM de la instancia, no se encuentran preservados en los artefactos disponibles; por ello, no se atribuyen especificaciones adicionales no verificables.

Para reproducir el experimento será necesario registrar, además del código, el modelo de GPU, versión del controlador, versión de CUDA, memoria disponible y sistema operativo. Estos datos son relevantes porque determinan el tamaño de microlote que puede procesarse y la probabilidad de fallos en documentos extensos.

TABLA 4.1: Información de hardware respaldada por los artefactos del proyecto.

Componente	Evidencia disponible
Acelerador	GPU NVIDIA H200 compatible con CUDA
Entorno de ejecución	Instancia de cómputo acelerado en la nube provista por RunPod
Precisión del LLM	<code>bfloat16</code> cuando CUDA está disponible
Gestión de memoria	Microlotes CPU-GPU, caché KV desactivada y reintentos reduciendo el microlote
Configuración restante	Variante y memoria exacta de la GPU, procesador y memoria RAM no preservados; deben registrarse en una reproducción
Almacenamiento de artefactos	DigitalOcean Spaces mediante API compatible con S3

4.1.2. Software

El proyecto requiere Python 3.10 o superior y declara sus dependencias en `pyproject.toml`; `uv.lock` conserva resoluciones concretas por plataforma. La Tabla 4.2 presenta componentes principales observados en el archivo de bloqueo actual. Las versiones efectivamente usadas en la corrida original deben verificarse contra el entorno archivado si se dispone de él, porque el archivo puede actualizarse después de una ejecución.

TABLA 4.2: Componentes principales del ambiente de software versionado.

Componente	Uso	Versión resuelta observada
Python	ETL y entrenamiento	$\geq 3,10$
PyTorch	Embeddings y redes	2.11.0
Transformers	Carga del LLM/tokenizador	5.4.0
scikit-learn	TF-IDF, CV y métricas	1.7.2/1.8.0 según plataforma
MLflow	Seguimiento experimental	3.10.1
pdfplumber	Extracción de texto PDF	0.11.9
Camelot	Extracción de tablas	1.0.9
pandas	Manipulación tabular	2.3.3

4.2. Fuente y procedencia de los datos

4.2.1. API de la DNCP

Los procesos provienen del servicio de datos abiertos de la DNCP. El script `fetch_ids_by_status.py` consulta el endpoint:

<https://www.contrataciones.gov.py/datos/api/v3/doc/search/processes>

La consulta utiliza `items_per_page=100`, el código de clasificación 72131701, el estado de la licitación y el número de página. El endpoint forma parte de la publicación paraguaya basada en Open Contracting [4, 17]. Se recorrieron las páginas disponibles para `unsuccessful` y `cancelled`; cada respuesta se normalizó añadiendo el estado utilizado en la consulta.

De cada registro se recuperaron, cuando estaban disponibles, el OCID, el `tender.id` y los identificadores de adjudicaciones. Si no aparecía `tender.id`, el código utilizó el OCID como alternativa. El identificador de tender se mantuvo como clave para unir etapas posteriores.

4.2.2. Conjunto inicial

El conjunto inicial reunió tres fuentes almacenadas en DigitalOcean Spaces:

1. `procurements.json`, con 10.000 procesos materializados como **complete** desde una instantánea previa de la DNCP;
2. `ids_unsuccessful.json`, con 257 procesos recuperados de las tres páginas disponibles;
3. `ids_cancelled.json`, con 371 procesos recuperados de las cuatro páginas disponibles.

La unión produjo 10.628 filas. El orden de combinación fue no exitosos, cancelados y completos. Ante identificadores duplicados, la primera capa conservó prioridad y las siguientes rellenaron campos ausentes. El mismo orden definió la cola de descarga, con el propósito de procesar primero la clase minoritaria.

4.3. Conjunto de datos

La instantánea de metadatos utilizada en este trabajo se construyó a partir de registros de contratación pública publicados por la Dirección Nacional de Contrataciones Públicas (DNCP) de Paraguay y recuperados mediante el endpoint oficial de datos abiertos `v3/doc/search/processes`. El conjunto inicial contiene 10.628 contrataciones de construcción vial bajo el código de catálogo 72131701: 10.000 procesos completados materializados por una canalización previa de extracción de la DNCP y 628 procesos adicionales no exitosos recolectados según su estado. Para reducir el desbalance de clases, la recuperación y el procesamiento priorizaron las contrataciones no exitosas antes que las completadas.

El subconjunto supervisado es menor porque se requieren varios pasos de filtrado. La mayor reducción ocurre antes del procesamiento textual: solo se recuperaron 1.845 PDF de PBC, principalmente porque los límites de solicitudes de la DNCP impidieron realizar una búsqueda y descarga exhaustivas dentro del tiempo disponible. Luego, la canalización extrajo texto de 1.842 PDF y generó embeddings congelados del LLM para 1.162 documentos. Los tres fallos de extracción correspondieron a documentos escaneados no compatibles con el extractor sin OCR, mientras que la mayoría de los fallos de generación de embeddings fueron errores por falta de memoria en la GPU, después de una única

ejecución limitada por el costo de infraestructura. Por ello, las conclusiones se aplican a este subconjunto procesado y no automáticamente a toda la población de contrataciones.

La distribución de clases del subconjunto procesado presenta un desbalance moderado: 844 contrataciones (72,63 %) están etiquetadas como exitosas (**complete**) y 318 (27,37 %) como no exitosas (**unsuccessful/cancelled/canceled**). La longitud media representada es de 7,46 fragmentos por contratación, con una desviación estándar de 13,52, una mediana de 3 fragmentos y un máximo de 245. Estos valores indican una distribución de longitudes muy asimétrica, con numerosos documentos cortos y una cantidad menor de documentos considerablemente más largos. La dimensión de los embeddings heredada del LLM base congelado es 2880.

El subconjunto procesado también está menos desbalanceado que la población general de contrataciones. En la instantánea completa, los resultados exitosos son mucho más frecuentes: aproximadamente 10.000 contrataciones exitosas frente a unas 650 no exitosas. Por consiguiente, las métricas dependientes del umbral y las interpretaciones sensibles a la prevalencia deben considerarse válidas para el subconjunto procesado, no como puntos operativos directamente desplegables.

4.4. Tratamiento de la fuga de información

El modelo opera exclusivamente con información disponible en el momento de la inferencia. Todas las entradas se derivan de documentos de licitación producidos y publicados durante la etapa de convocatoria, antes de que se conozca el resultado final de la contratación. Esto hace que la configuración predictiva sea operativamente realista y reduce sustancialmente el riesgo de fuga directa a partir de contenido explícito sobre el estado final.

En consecuencia, la principal amenaza restante para la validez no es una fuga evidente y posterior de la variable objetivo, sino las correlaciones predictivas indirectas y la representatividad limitada. Los documentos de licitación pueden codificar regularidades estructurales, institucionales o estilísticas que predicen el resultado sin ser causales. Estas regularidades son legítimas para generar señales predictivas tempranas porque están disponibles en el momento de la decisión, pero no deben interpretarse como causas directas del éxito o fracaso de una contratación.

4.5. Protocolo de evaluación

El modelo se evalúa mediante validación cruzada estratificada de cinco pliegues. El subconjunto procesado de 1.162 ejemplos se divide en cinco pliegues que preservan las etiquetas, de modo que cada ronda utiliza aproximadamente cuatro quintas partes de los datos para ajustar el modelo y una quinta parte como partición de evaluación fuera de pliegue. En términos concretos, cada ronda entrena con unas 930 contrataciones y evalúa aproximadamente 232 que no se utilizaron para ajustar el modelo de esa ronda.

La estratificación es importante porque la clase positiva no está balanceada: cerca del 72,6% del subconjunto procesado corresponde a resultados exitosos. Conservar esta prevalencia entre pliegues reduce variaciones evitables en F1, exactitud balanceada y PR AUC. Los valores finales informados son la media y la desviación estándar de los cinco pliegues reservados. Para el análisis de sensibilidad al umbral, los cuatro pliegues de entrenamiento de cada ronda se dividen nuevamente en una porción interna de entrenamiento y otra de validación; el umbral que maximiza F1 en la validación interna se aplica después al pliegue de evaluación externo de esa ronda.

4.6. Métricas

La evaluación utiliza las siguientes métricas:

- **ROC AUC**, para medir la calidad del ordenamiento con independencia del umbral de decisión.
- **PR AUC** (precisión promedio), para evaluar el ordenamiento con atención explícita a la clase positiva.
- **Puntaje F1**, con un umbral de probabilidad de 0,5.
- **Exactitud balanceada**, también con un umbral de 0,5.
- **Puntaje de Brier**, para medir la calidad de la calibración probabilística.
- **Pérdida logarítmica**, como regla de puntuación propia sobre las probabilidades predichas.

La elección de métricas ante el desbalance depende del objetivo operativo: los resúmenes basados en PR enfatizan la recuperación de la clase positiva, mientras que ROC AUC y PR AUC responden de manera distinta a la prevalencia y deben interpretarse en contexto

[26]. Debido a que PR AUC puede inducir a error cuando la clase positiva es frecuente, se interpreta junto con la prevalencia positiva π en los pliegues reservados. La implementación también registra `positive_prevalence` y `pr_auc_excess_over_prevalence`; esta última se define como PR AUC menos π . La cantidad ofrece una estimación compacta de cuánto mejora el modelo sobre la frecuencia de la clase positiva, utilizada habitualmente como referencia al discutir el comportamiento PR sin capacidad predictiva en contextos desbalanceados.

4.7. Recuperación de documentos PBC

Para cada proceso, `merge_and_download_pbcs.py` consultará la información documental asociada e intentará localizar un PBC o carta de invitación. La ejecución documentada aceptó PDF como artefacto final. El código inspecciona título, URL y formato; también contiene rutas auxiliares para archivos comprimidos o documentos de oficina, pero el conjunto final observado está compuesto por PDF.

Los archivos se almacenan bajo la clave lógica:

`outcome-predictor/pbcs/pdf/{tenderId}.pdf`

El proceso es reanudable: antes de descargar, puede comprobar si el objeto existe. El conjunto JSON enriquecido conserva indicadores de descarga, clave remota y, cuando se registró, motivo de omisión o error. Una reconciliación final compara las filas con el listado real de objetos en Spaces para evitar que el JSON declare un PDF inexistente.

Se obtuvieron 1.845 PDF. Esta cifra representa los archivos recuperados por la canalización, no todos los PBC existentes en la DNCP. Para 42 procesos se conservó un motivo de fallo; 8.741 filas no contienen evidencia de intento o causa final y se documentan como no procesadas dentro del tiempo disponible, principalmente por limitación de solicitudes. Esta diferencia exige evitar tasas de disponibilidad calculadas como si toda la población hubiese sido consultada exhaustivamente.

4.8. Extracción y normalización del texto

Los PDF descargados se procesaron con `PDFReader`. La etapa utiliza `pdfplumber` para texto y puede utilizar Camelot en modos *lattice* y *stream* para tablas. Cada resultado se almacenó en:

`outcome-predictor/pbcs/txt/{tenderId}.txt`

De 1.845 PDF se obtuvieron 1.842 textos. Los tres fallos correspondieron a documentos escaneados para los que el extractor no incorporaba OCR. No se imputó texto vacío ni se reemplazaron esos documentos por contenido de otra fuente; quedaron excluidos.

La extracción puede conservar ruido de paginación o alterar tablas. El experimento tratará el texto obtenido como entrada efectiva del modelo y no como transcripción perfecta del PBC. Una extensión con OCR deberá evaluarse por separado porque cambiaría la población incluida y la calidad de la entrada.

4.9. Generación de embeddings

4.9.1. Codificador congelado

El script `embed_pbcs.py` cargará `openai/gpt-oss-20b` mediante Hugging Face Transformers y congelará todos sus parámetros. La configuración seleccionará `bfloat16` en CUDA, desactivará la caché de claves y valores y utilizará el backbone que devuelve el último estado oculto.

La secuencia completa se tokenizará sin truncamiento. Se dividirá en fragmentos de 4096 tokens con desplazamiento de 2048. Cada fragmento se completará hasta la longitud máxima para formar microlotes. El embedding corresponderá al estado oculto del último token válido, no al relleno.

4.9.2. Control de memoria

El tamaño inicial del microlote será cuatro. Ante un error de memoria CUDA, el código vaciará la caché, reducirá el tamaño por mitades y reintentará hasta llegar a uno. Si el error persiste, se registrará y el documento quedará sin embedding. Este procedimiento evita que un fallo detenga toda la colección, aunque induce una selección técnica por longitud y demanda de memoria.

Cada archivo `.pt` conserva `tender_id`, matriz de embeddings, identificador del modelo, longitud, desplazamiento, tamaño de microlote y eventual etiqueta. Se produjeron 1.162 archivos. Entre los 680 textos sin embedding se observaron 671 errores de memoria y nueve `ValueError`.

4.10. Embudo de construcción del conjunto supervisado

La Tabla 4.3 presenta el recorrido completo. Los conteos provienen de objetos observados y del JSON consolidado.

TABLA 4.3: Embudo de datos desde procesos DNCP hasta el conjunto supervisado.

Etapas	Universo	Resultado válido	Pérdida
Procesos unificados	10.628	10.628	0
PBC PDF recuperados	10.628	1.845	8.783
Texto extraído	1.845	1.842	3
Embeddings generados	1.842	1.162	680
Ejemplos supervisados	1.162	1.162	0

La Tabla 4.4 desagrega etapas por estado. La priorización elevó la proporción de no exitosos respecto de la instantánea completa.

TABLA 4.4: Conteos por estado en etapas principales.

Estado	Inicial	PDF	Texto	Embedding
complete	10.000	1.273	1.270	844
unsuccessful	257	246	246	204
cancelled	371	326	326	114
Total	10.628	1.845	1.842	1.162

La pérdida no es aleatoria. Se priorizaron estados minoritarios y los errores de embedding afectaron principalmente documentos costosos. Por ello, el subconjunto final no debe presentarse como muestra representativa del universo paraguayo. El protocolo medirá desempeño interno sobre los 1.162 casos procesados.

4.11. Definición de la instancia y etiqueta

El estudio busca anticipar el estado con el que cada contratación queda registrada a partir del texto de su PBC. Para ello se utilizan únicamente procesos que cuentan con un documento aprovechable y con uno de los estados finales considerados. Los estados se agrupan en dos resultados:

- Se considera exitoso el proceso registrado como **complete**.

- Se considera no exitoso el proceso registrado como `unsuccessful`, `cancelled` o `canceled`.

Los términos `cancelled` y `canceled` expresan el mismo estado, “cancelado”, con las grafías británica y estadounidense del inglés; ambos aparecen en los datos de origen y por eso se normalizan dentro del mismo grupo. Reducir los estados a estas dos alternativas convierte el problema en una clasificación binaria: para cada PBC, el modelo estima la probabilidad de que el proceso pertenezca al primer grupo.

Los registros con otros estados se excluyen del entrenamiento y de la evaluación. Esta agrupación es una decisión operativa basada en la fuente disponible. Un proceso `complete` no implica necesariamente máximo valor público, y una cancelación puede responder a causas legítimas; por tanto, la etiqueta no constituye una evaluación integral de éxito, eficiencia o integridad.

El mapeo se implementa en `src/data/procurement_target.py` y se alinea mediante `tenderId`. Registros sin uno de los estados admitidos se excluirán. La etiqueta no se extraerá del PBC y no se suministrará al codificador.

4.12. Modelos que se evaluarán

4.12.1. Representación documental

Cada documento PBC se convierte primero de PDF a texto mediante la canalización de extracción previa. El texto resultante se tokeniza y divide en fragmentos superpuestos. En la implementación actual, cada fragmento tiene una longitud de 4096 tokens y un desplazamiento de 2048 tokens. Se utiliza el modelo de lenguaje causal preentrenado `openai/gpt-oss-20b` como codificador documental congelado [23]. Este modelo se seleccionó como un LLM práctico de pesos abiertos para extraer representaciones densas de textos de contratación en español y, a la vez, mantener reproducible la canalización experimental. Congelar el codificador también evita ajustar un modelo grande sobre un conjunto de datos modesto y permite que la comparación se concentre en cuánta señal existe en las representaciones preentrenadas y cómo se agrega posteriormente, en consonancia con trabajos recientes sobre embeddings textuales basados en LLM [12]. Los fragmentos se procesan en microlotes para reducir la presión sobre la memoria de la GPU.

Para cada fragmento, el sistema extrae la representación oculta asociada al último token válido. La salida correspondiente a un documento de contratación es, por tanto, una

secuencia de embeddings de fragmentos:

$$\mathbf{E} = [\mathbf{e}_1, \mathbf{e}_2, \dots, \mathbf{e}_N], \quad \mathbf{e}_i \in \mathbb{R}^{d_{in}},$$

donde N es la cantidad de fragmentos del documento y d_{in} está determinado por el tamaño oculto del modelo preentrenado. Esta configuración permite comparar dos estrategias de representación basadas en LLM: un vector documental simple obtenido mediante el promedio de los fragmentos y un modelo secuencial que aprende las interacciones entre ellos.

4.12.2. Arquitectura del predictor

El clasificador principal, **TenderSuccessPredictor**, es un transformer liviano aplicado sobre los embeddings de los fragmentos. Sea $\mathbf{E} \in \mathbb{R}^{N \times d_{in}}$ la secuencia de fragmentos de un documento. El modelo aplica:

1. Una proyección lineal de d_{in} a una dimensión latente entrenable d_{model} .
2. La inserción de un token aprendido [CLS] al comienzo de la secuencia.
3. Un codificador transformer sobre la secuencia completa de vectores de fragmentos.
4. Una pequeña cabeza de clasificación multicapa sobre la representación final de [CLS].

En los experimentos actuales, los hiperparámetros posteriores son: $d_{model} = 128$, $n_{heads} = 4$, dimensión de la red prealimentada = 512, dropout = 0,3 y una capa de codificación. Se emplean máscaras de relleno para agrupar de forma segura documentos con diferentes cantidades de fragmentos.

El modelo produce un único logit por documento. Una transformación sigmoide convierte este logit en una probabilidad de éxito:

$$\hat{p}(y = 1 \mid \mathbf{E}) = \sigma(z).$$

El entrenamiento utiliza entropía cruzada binaria con logits.

4.12.3. Líneas base

Para interpretar los resultados basados en LLM, se evalúan tres clases de líneas base.

En primer lugar, se emplean dos referencias triviales: un clasificador de clase mayoritaria y un clasificador aleatorio cuya tasa positiva coincide con la prevalencia empírica. Estas líneas base establecen la región esperada sin capacidad predictiva, donde ROC AUC debería situarse cerca de 0,5 y PR AUC cerca de la prevalencia positiva.

En segundo lugar, se utiliza una línea base léxica con características TF-IDF de hasta 50.000 unigramas y bigramas, frecuencia documental mínima de 5 y un clasificador de regresión logística con pesos de clase balanceados. Se utiliza TF-IDF en lugar de embeddings densos estáticos como Word2Vec porque proporciona una referencia sólida e interpretable de bolsa de palabras que sigue siendo competitiva en documentos extensos [10, 11]. Además, permite aislar la comparación con representaciones congeladas de LLM sin añadir otra etapa entrenable de embeddings bajo supervisión limitada. Las líneas base lineales de bolsa de palabras son referencias habituales en clasificación de textos [10], y la evidencia reciente sobre documentos extensos indica que las representaciones léxicas aún son competitivas en algunos escenarios [11].

En tercer lugar, se definen dos líneas base intermedias basadas en LLM que utilizan los mismos embeddings preentrenados de fragmentos que el sistema principal, pero sustituyen el transformer entre fragmentos por una agregación documental más simple. En la primera variante, se promedian los embeddings de los fragmentos y se suministran a una regresión logística. En la segunda, la misma representación promedio alimenta un pequeño perceptrón multicapa con una capa oculta. Estas líneas base aíslan el valor de la representación del valor aportado por el modelado explícito de las interacciones entre fragmentos.

4.13. Entrenamiento y reproducibilidad

El entrenamiento utiliza AdamW, una tasa de aprendizaje de 10^{-4} , decaimiento de pesos de 0,01, lotes de tamaño 8 y hasta 50 épocas. Dentro de cada ronda de validación cruzada, una época corresponde a un recorrido completo por la porción de entrenamiento de esa ronda. Después de cada época se calcula la pérdida de validación sobre la porción reservada; si no mejora durante cinco épocas consecutivas, el entrenamiento se detiene y se restaura el mejor punto de control. La reproducibilidad se controla mediante semillas fijas, comportamiento determinista de cuDNN, cargadores de datos con semilla y reinicios independientes del estado aleatorio al comienzo de cada pliegue.

4.13.1. Líneas base triviales

Se incluirá un clasificador de clase mayoritaria y uno aleatorio cuya tasa positiva coincida con la prevalencia. Servirán como control del pipeline: ROC AUC deberá situarse cerca de 0,5 y PR AUC cerca de la prevalencia, dentro de la variación esperable.

4.13.2. TF-IDF con regresión logística

El vectorizador se ajustará exclusivamente con textos de entrenamiento de cada pliegue. Se usarán 50.000 características como máximo, unigramas y bigramas, y frecuencia documental mínima de cinco. La regresión logística utilizará `class_weight=balanced`. Transformar el pliegue externo con un vocabulario aprendido solo en entrenamiento evitará fuga por frecuencia documental.

4.13.3. Promedio con regresión logística

Se calculará el promedio de embeddings por documento y se ajustará una regresión logística. Este modelo aislará el contenido de la representación congelada sin introducir una red secuencial.

4.13.4. Promedio con MLP

El mismo promedio alimentará una red con una capa oculta. En el análisis de sensibilidad se utilizó dimensión oculta 256, ReLU, dropout 0,2, AdamW, lotes de 64 y detención temprana. La comparación con regresión logística permitirá observar si una transformación no lineal del promedio aporta valor.

4.13.5. Transformer entre fragmentos

La matriz variable de embeddings se rellenará dentro de cada lote y se acompañará con una máscara. La arquitectura proyectará de 2880 a 128 dimensiones, añadirá [CLS], utilizará cuatro cabezas, dimensión prealimentada 512, dropout 0,3 y una capa. La cabeza final producirá un logit.

4.14. Partición y protocolo de evaluación

Se utilizará validación cruzada estratificada de cinco pliegues con semilla 42. Cada pliegue conservará aproximadamente la prevalencia. Los modelos comparados emplearán los mismos índices externos. El vectorizador y los clasificadores se ajustarán nuevamente en cada ronda.

Para las métricas a umbral fijo se utilizará $\tau = 0,5$. Para el experimento de sensibilidad, los cuatro pliegues externos de entrenamiento se dividirán en entrenamiento interno y validación interna, con una proporción de validación de 0,2. Se seleccionará el umbral que maximice F1 en la partición interna; ante empates se preferirá el más cercano a 0,5 y luego el menor. El umbral se aplicará una sola vez al pliegue externo.

Este anidamiento separará selección y evaluación. No se utilizará el pliegue externo para elegir hiperparámetros, vocabulario o umbral.

4.15. Entrenamiento

El transformer se entrenará con AdamW, tasa 10^{-4} , decaimiento 0,01, lotes de ocho y hasta 50 épocas. Después de cada época se calculará la pérdida de validación. Si no mejora durante cinco épocas consecutivas, se detendrá el entrenamiento y se restaurará el mejor estado.

La pérdida será entropía cruzada binaria con logits. El uso directo de logits evita aplicar sigmoide antes de una función que implementa de forma estable ambas operaciones. Durante evaluación, la sigmoide transformará logits en probabilidades.

4.16. Métricas de evaluación

Se informarán ROC AUC, PR AUC, F1, exactitud balanceada, Brier y pérdida logarítmica. ROC AUC y PR AUC evaluarán ranking; F1 y exactitud balanceada dependerán del umbral; Brier y pérdida logarítmica evaluarán probabilidades. También se registrará la prevalencia positiva y $PR AUC - \pi$.

Las curvas de precisión-exhaustividad se construirán agregando predicciones externas. Las curvas de calibración agruparán probabilidades y compararán predicción media con frecuencia observada. Dado el tamaño limitado, los puntos de bins extremos se interpretarán con cautela.

4.17. Trazabilidad y reproducibilidad

La semilla global será 42 y cada pliegue recibirá una semilla derivada independiente. El código configurará cuDNN determinista, generadores de **DataLoader** y reinicios de estados aleatorios. MLflow conservará hiperparámetros y métricas. Los objetos pesados residirán en Spaces y los metadatos de seguimiento, por defecto, en SQLite local.

Los artefactos públicos archivados en Zenodo incluyen el código y los 1.162 archivos **.pt** de embeddings congelados empleados en los experimentos (doi:10.5281/zenodo.20128768). El paquete de embeddings incorpora un manifiesto con el identificador de cada archivo, sus dimensiones y su suma de verificación SHA-256, además de metadatos agregados y documentación de uso. Esto permite reproducir el entrenamiento y la evaluación de los modelos basados en LLM sin volver a ejecutar la costosa etapa de codificación documental.

El depósito excluye credenciales y los datos fuente locales. Por tanto, reproducir los experimentos a partir de los embeddings publicados no requiere acceso a la infraestructura original, pero reconstruir toda la canalización desde los PDF exige obtener legítimamente los documentos desde la DNCP y disponer del modelo base. Esta distinción delimita el grado de reproducibilidad alcanzado.

4.18. Amenazas a la validez previstas

Se considerarán cuatro grupos:

1. **Validez de constructo:** el estado final es una aproximación operacional al éxito.
2. **Validez interna:** podrían existir duplicados documentales, regularidades institucionales o señales indirectas; el protocolo evita datos posteriores, pero no convierte correlaciones en causalidad.
3. **Validez externa:** el subconjunto está filtrado por disponibilidad y cómputo, y se limita a construcción vial paraguaya.
4. **Validez de conclusión:** cinco pliegues sobre 1.162 ejemplos producen incertidumbre; diferencias pequeñas no deben presentarse como dominancia universal sin pruebas adicionales.

Estas amenazas guiarán la interpretación del capítulo de resultados y evitarán extrapolar los umbrales del subconjunto a la distribución completa.

Capítulo 5

Pruebas experimentales y análisis de resultados computacionales

Este capítulo presenta los resultados obtenidos mediante las particiones y modelos definidos anteriormente. El análisis se organiza en cuatro bloques: controles sin capacidad predictiva, comparación de ranking, comportamiento dependiente del umbral y calidad probabilística. Luego se estudia el efecto de la representación y se discuten los resultados en relación con el contexto paraguayo y los antecedentes.

5.1. Comprobaciones previas

Antes de comparar modelos se verificó que todos operaran sobre los mismos 1.162 identificadores y la misma regla de etiqueta. La prevalencia positiva fue aproximadamente 0,726. Por ello, una PR AUC cercana a 0,726 no expresa una mejora sustantiva sobre puntuaciones aleatorias; debe compararse con esa referencia. La ROC AUC de los controles se mantuvo cerca de 0,5, lo que es consistente con un ordenamiento sin habilidad.

Los resultados triviales también sirven para detectar errores. Una ROC AUC muy distinta de 0,5 en el clasificador mayoritario o una PR AUC incompatible con la prevalencia habría requerido revisar etiquetas, particiones o cálculo de métricas. No se observó ese patrón.

5.2. Desempeño de ordenamiento

La Tabla 5.1 resume la comparación de modelos. Las líneas base triviales se comportan como se esperaba: ROC AUC permanece en el nivel del azar y PR AUC se mantiene cerca

de la prevalencia positiva de aproximadamente 0,726. Esto proporciona una referencia útil sin capacidad predictiva y respalda la consistencia interna de la evaluación.

Entre los modelos no triviales, TF-IDF más regresión logística obtiene las mejores métricas de ordenamiento, con ROC AUC medio de 0,814 y PR AUC medio de 0,899. El transformer entre fragmentos aplicado a embeddings de LLM alcanza ROC AUC de 0,755 y PR AUC de 0,886. Las líneas base con embeddings promediados se mantienen próximas: el MLP con promedio alcanza ROC AUC de 0,763 y PR AUC de 0,894, mientras que la regresión logística con promedio alcanza ROC AUC de 0,758 y PR AUC de 0,881. La Fig. 5.1 coincide con este panorama: TF-IDF define en general la mejor frontera entre precisión y exhaustividad, mientras que ambas alternativas basadas en LLM permanecen claramente por encima de la prevalencia. Los documentos contienen señal predictiva, pero el mejor ordenamiento en la configuración actual proviene de representaciones léxicas y no densas.

5.3. Sensibilidad al umbral

El comportamiento dependiente del umbral revela un patrón diferente. Con el umbral predeterminado de 0,5, el transformer entre fragmentos alcanza el mayor F1 (0,858 en la evaluación original de cinco pliegues). Sin embargo, el experimento específico muestra que no todos los modelos reaccionan de igual manera a la optimización del umbral. Para TF-IDF más regresión logística, seleccionar en validación el umbral que maximiza F1 incrementa el F1 del pliegue de prueba en 0,103 en promedio, pero no mejora la exactitud balanceada media. La regresión logística con promedio presenta una mejora modesta de F1 (+0,014) y una disminución media de exactitud balanceada (−0,049). En contraste, el transformer cambia poco con el ajuste (media de $\Delta F1 = +0,002$ y media de Δ de exactitud balanceada = +0,002), lo que indica que el umbral predeterminado ya está cerca de un punto operativo estable. El MLP con promedio ocupa una posición intermedia: su F1 apenas cambia, pero su exactitud balanceada mejora en promedio al ajustar el umbral. La Fig. 5.3 resume visualmente el contraste y deja claro que la optimización beneficia principalmente el F1 del modelo léxico, no a todos los modelos de manera uniforme.

5.4. Calibración

La calibración presenta una historia diferente al ordenamiento. El transformer entre fragmentos consigue el mejor puntaje de Brier (0,162), seguido por el MLP con promedio

TABLA 5.1: Comparación de modelos mediante validación cruzada de cinco pliegues (media $\pm$ desviación estándar). Un valor menor es mejor para Brier; un valor mayor es mejor para las demás métricas.

Métrica	Valor
Mayoría: ROC AUC / PR AUC	0.500 / 0.726
Aleatorio: ROC AUC / PR AUC	0.493 / 0.724
TF-IDF + Reg. Log.: ROC AUC / PR AUC	0.814 / 0.899
TF-IDF + Reg. Log.: F1 / Exact. Bal. / Brier	0.790 / 0.728 / 0.179
Promedio + Reg. Log.: ROC AUC / PR AUC	0.758 / 0.881
Promedio + Reg. Log.: F1 / Exact. Bal. / Brier	0.843 / 0.704 / 0.201
Promedio + MLP: ROC AUC / PR AUC	0.763 / 0.894
Promedio + MLP: F1 / Exact. Bal. / Brier	0.849 / 0.604 / 0.165
Transformer entre fragmentos: ROC AUC / PR AUC	0.755 / 0.886
Transformer entre fragmentos: F1 / Exact. Bal. / Brier	0.858 / 0.636 / 0.162

(0,165); TF-IDF más regresión logística obtiene un resultado inferior (0,179) y la regresión logística con promedio es considerablemente peor (0,201). Este patrón indica que las características léxicas pueden ser muy eficaces para ordenar ejemplos, mientras que las representaciones densas basadas en LLM proporcionan probabilidades más confiables. La Fig. 5.2 concuerda con esta interpretación: entre las tres familias más informativas, el transformer permanece más próximo a la diagonal en gran parte del intervalo de probabilidades, mientras que TF-IDF es mejor en ordenamiento que en calibración. Esto importa porque la selección de modelos para monitorear contrataciones puede depender no solo del ordenamiento, sino también de si las probabilidades permiten sustentar la priorización posterior o una puntuación de riesgo [28].

5.5. Comparación de representaciones

La comparación entre embeddings promediados y el transformer entre fragmentos es informativa por sí misma. Si el valor principal de la representación del LLM proviniera únicamente de las interacciones entre fragmentos, cabría esperar que el transformer dominara las líneas base con promedio. Esto no sucede. El MLP con promedio supera ligeramente al transformer en ROC AUC y PR AUC, mientras que la regresión logística con promedio logra una exactitud balanceada considerablemente mayor. Los resultados sugieren que gran parte de la información predictiva ya está codificada en los propios embeddings congelados y que el modelado explícito entre fragmentos ofrece ganancias limitadas en la configuración actual. La principal ventaja del transformer parece ser la calibración y la estabilidad del umbral, no un ordenamiento claramente superior.

TABLA 5.2: Ajuste del umbral en una partición interna de validación y evaluación en el pliegue externo de prueba. Se informan las medias de todos los pliegues.

Métrica	Valor
TF-IDF + Reg. Log.: $\Delta F1 / \Delta$ Exact. Bal.	+0,103/ - 0,008
Promedio + Reg. Log.: $\Delta F1 / \Delta$ Exact. Bal.	+0,014/ - 0,049
Promedio + MLP: $\Delta F1 / \Delta$ Exact. Bal.	+0,002/ + 0,053
Transformer entre fragmentos: $\Delta F1 /$ Δ Exact. Bal.	+0,002/ + 0,002




FIGURA 5.1: Curvas comparativas de precisión-exhaustividad a partir de predicciones agregadas fuera de pliegue para la línea base léxica más sólida (TF-IDF + regresión logística), la mejor línea base densa con promedio (Promedio + MLP) y el transformer entre fragmentos. La línea horizontal discontinua marca la prevalencia positiva ($\pi \approx 0,726$). TF-IDF muestra en general el mejor compromiso entre precisión y exhaustividad, mientras que ambos modelos basados en LLM permanecen sustancialmente por encima de la referencia sin capacidad predictiva.




FIGURA 5.2: Curvas comparativas de calibración a partir de predicciones agregadas fuera de pliegue para TF-IDF + regresión logística, Promedio + MLP y el transformer entre fragmentos. La diagonal representa la calibración perfecta. El ordenamiento y la calibración no coinciden: el transformer se mantiene más próximo a una señal probabilística útil y calibrada, mientras que TF-IDF es más sólido como modelo de ordenamiento que como estimador de probabilidades.

5.6. Lectura comparativa por criterio

5.6.1. Ranking

TF-IDF más regresión logística alcanzó ROC AUC 0,814 y PR AUC 0,899, los mayores valores medios informados. La diferencia con los modelos densos indica que, en el subconjunto procesado, el vocabulario y los bigramas contienen una señal especialmente útil para ordenar procesos exitosos y no exitosos.

Este resultado es compatible con la naturaleza de los PBC. Al pertenecer todos a construcción vial, las variaciones léxicas pueden reflejar plantillas, requisitos o estilos institucionales dentro de un dominio relativamente homogéneo. La explicación es una hipótesis interpretativa, no una atribución causal: el experimento no identifica qué cláusulas producen un desenlace.

El transformer entre fragmentos no superó al promedio con MLP en ranking. Por tanto, los resultados no apoyan la afirmación de que modelar explícitamente relaciones entre




FIGURA 5.3: Cambio medio en F1 y exactitud balanceada del pliegue de prueba después de sustituir el umbral predeterminado de 0,5 por el umbral que maximiza F1 en una partición interna de validación. El ajuste mejora considerablemente el F1 de TF-IDF + regresión logística, presenta efectos mixtos en los modelos con promedio y apenas modifica el transformer entre fragmentos, lo que indica una mayor estabilidad del punto operativo.

fragmentos sea necesario para extraer la mayor parte de la señal densa en esta configuración.

5.6.2. Desempeño con umbral 0,5

El mayor F1 a umbral fijo correspondió al transformer entre fragmentos, con 0,858. Sin embargo, su exactitud balanceada fue 0,636, inferior a la regresión logística con promedio y a TF-IDF. La diferencia revela el efecto de una clase positiva frecuente: un modelo puede obtener F1 alto favoreciendo predicciones positivas y, al mismo tiempo, distinguir peor la clase negativa.

La exactitud balanceada de 0,728 de TF-IDF fue la mayor de la tabla principal. Como promedia la sensibilidad de ambas clases, ofrece una lectura complementaria al F1. Ninguna de las dos métricas debe interpretarse sin especificar la clase positiva y el umbral.

5.6.3. Calibración

El transformer obtuvo el menor Brier, 0,162, seguido por el MLP con promedio, 0,165. TF-IDF, pese a su mejor ranking, obtuvo 0,179. Esta divergencia es esperable: una transformación monótona puede conservar el orden de los ejemplos y cambiar la correspondencia entre puntajes y probabilidades.

La curva de calibración permite observar el comportamiento por intervalos, pero sus puntos no poseen igual cantidad de datos ni intervalos de confianza en la figura actual. La conclusión se restringe a que el transformer produjo la mejor combinación observada bajo Brier y la curva agregada; no se afirma calibración perfecta ni transferencia automática a otra prevalencia.

5.7. Análisis de sensibilidad al umbral

La selección interna del umbral modificó principalmente el F1 de TF-IDF: el incremento medio fue 0,103. Su exactitud balanceada no aumentó en promedio. Esto muestra que maximizar una métrica en validación no garantiza mejorar otra; el objetivo de selección determina el punto operativo.

Para el transformer, las variaciones medias de F1 y exactitud balanceada fueron 0,002. El resultado sugiere estabilidad alrededor de 0,5 en estas particiones. No demuestra que 0,5 vaya a mantenerse como umbral adecuado si cambia la prevalencia de positivos, el costo relativo de falsos positivos y negativos o la institución de origen.

La regresión logística con promedio mejoró ligeramente F1 y redujo exactitud balanceada. El MLP con promedio mantuvo F1 y mejoró exactitud balanceada. Estos patrones justifican presentar deltas por modelo en lugar de una recomendación general de “ajustar siempre” el umbral.

5.8. Comparación entre hipótesis experimentales

5.8.1. Señal textual frente a controles

Todos los modelos no triviales superaron a los controles en ROC AUC y PR AUC. Esta evidencia responde afirmativamente, dentro del subconjunto, a la primera pregunta: los PBC contienen señal predictiva sobre la etiqueta operacionalizada.

La evidencia no permite conocer cuánto proviene de contenido técnico, fórmulas administrativas, organismo convocante o año. Un análisis de ablación por secciones y una validación agrupada por institución serían necesarios para separar estas fuentes.

5.8.2. Representación léxica frente a densa

La representación léxica fue superior en ranking, mientras que las densas fueron competitivas y dos de ellas obtuvieron menor Brier. No existe un ganador único para todos los criterios. La selección dependerá del uso: priorización ordenada, clasificación binaria o puntuación probabilística.

Este hallazgo coincide con trabajos de documentos extensos que recomiendan mantener líneas base TF-IDF y evaluar costo además de desempeño [24, 35]. El resultado local es particularmente relevante porque el LLM utilizado tiene una escala muy superior a la regresión logística, pero esa escala no produjo el mayor AUC.

5.8.3. Interacciones entre fragmentos

El transformer mejoró calibración respecto de los otros agregadores, pero no ranking. La hipótesis de que las interacciones entre fragmentos aportarían una ventaja general no queda respaldada. Una explicación posible es que el embedding de cada fragmento ya condense suficiente información y el conjunto sea pequeño para aprender interacciones adicionales. Otra posibilidad es que el último token válido no sea el pooling óptimo. Ambas explicaciones requieren experimentos y se formulan como líneas futuras, no como hechos demostrados.

5.9. Costo y complejidad experimental

La comparación de desempeño debe considerar el costo de obtener cada entrada. TF-IDF utiliza el texto extraído y se ajusta con operaciones dispersas. Los modelos densos requieren ejecutar una vez un LLM de 20 mil millones de parámetros sobre fragmentos de hasta 4096 tokens. Esa etapa produjo la principal pérdida técnica del embudo: 680 documentos sin embedding, 671 de ellos por memoria.

Después de generar embeddings, el entrenamiento de agregadores es comparativamente liviano y puede reutilizar los archivos .pt. Sin embargo, una evaluación de extremo a extremo debe contabilizar la codificación inicial y la selección que induce. El mejor Brier

del transformer se obtuvo sobre documentos que sí pudieron codificarse; no hay evidencia de su desempeño en los 680 excluidos.

5.10. Discusión de resultados

El hallazgo principal no es que una representación domine universalmente a las demás, sino que diferentes representaciones parecen capturar distintos aspectos de la tarea. TF-IDF más regresión logística ofrece el mejor ordenamiento, lo que sugiere que la señal léxica es muy informativa en este dominio. Esto es plausible porque los documentos de licitación suelen contener fórmulas administrativas repetidas, requisitos estandarizados, terminología específica y expresiones procedimentales que pueden correlacionarse fuertemente con los resultados posteriores. En este contexto, características léxicas dispersas pueden recuperar gran parte de la señal predictiva mediante un modelo lineal relativamente simple.

Esto no debe interpretarse como evidencia contraria a las representaciones basadas en LLM. Todos los modelos no triviales de esta familia permanecen claramente por encima de las líneas base y los embeddings promediados se mantienen próximos al transformer. Ello indica que los embeddings congelados de los fragmentos ya codifican información densa útil. En otras palabras, buena parte del valor del LLM puede residir en la propia representación, más que en la complejidad del mecanismo posterior de agregación.

La comparación entre el promedio y el transformer resulta especialmente informativa. Si las interacciones detalladas entre fragmentos fueran la principal fuente de capacidad predictiva, el transformer debería dominar claramente las líneas base agregadas. Eso no ocurre en los experimentos actuales. El MLP con promedio se aproxima al transformer en ordenamiento y la regresión logística con promedio incluso lo supera en exactitud balanceada. Esto sugiere que el modelado explícito de interacciones aún no proporciona una ventaja clara de ordenamiento bajo el régimen de datos y la señal de supervisión actuales.

No obstante, el transformer conserva una ventaja importante: la calibración y la estabilidad del umbral. Obtiene el mejor puntaje de Brier y muestra muy poca sensibilidad al ajuste del umbral, mientras que TF-IDF más regresión logística se beneficia considerablemente de dicho ajuste en F1. Desde una perspectiva aplicada, esto importa porque el modelo preferido para ordenar no necesariamente es el mismo que se prefiere para priorizar mediante probabilidades o para lograr un comportamiento estable en producción. La naturaleza relativamente estandarizada de los documentos de construcción vial también puede contribuir al buen desempeño de las líneas base léxicas.

Parte de la señal predictiva puede reflejar la complejidad documental, las prácticas institucionales de redacción, la estandarización de procedimientos u otras regularidades textuales latentes. Estas señales son legítimas para la predicción temprana porque están disponibles cuando se emite el documento, antes de conocerse el resultado. Sin embargo, no deben interpretarse como causas de los resultados de una contratación.

En conjunto, la comparación resulta informativa incluso sin un único ganador dominante. Para aplicaciones de gobierno y democracia electrónicos, este es precisamente el punto: los sistemas de monitoreo de contrataciones requieren más que un puntaje alto de ordenamiento. También necesitan probabilidades calibradas, líneas base transparentes y umbrales cuyo comportamiento pueda explicarse antes de utilizarlos para priorizar la atención humana. Los resultados muestran que los modelos léxicos son muy competitivos, que los embeddings congelados de LLM ya capturan gran parte de la señal densa útil y que la principal ventaja comparativa del transformer reside en su calibración y estabilidad ante el umbral, no en su desempeño bruto de ordenamiento.

5.10.1. Implicaciones para Paraguay

El resultado más inmediato es metodológico: en PBC paraguayos de construcción vial, una línea base léxica bien configurada debe preceder a modelos más costosos. Esto no implica descartar LLM. Indica que cualquier propuesta basada en ellos debe demostrar una ventaja vinculada al objetivo operativo, como calibración, transferencia o análisis semántico, y no apoyarse únicamente en su complejidad.

Un sistema de apoyo a la DNCP o a un organismo de control podría usar ranking para ordenar expedientes y revisión humana para interpretar causas. Antes de ello sería necesario validar sobre períodos posteriores, incluir organismos no vistos, recuperar PBC faltantes y definir el evento que realmente se desea anticipar. La etiqueta **complete** frente a estados no exitosos es útil para investigación, pero una política pública puede requerir objetivos más específicos.

La Ley N.º 7021/2022 enfatiza eficiencia, competencia, transparencia e integridad [2]. Una predicción de estado no mide por sí sola esos principios. Cualquier integración institucional debería mantener separadas la señal estadística, la evaluación normativa y la decisión administrativa.

5.10.2. Comparación con otros países

Acikalin et al. encontraron señal predictiva en descripciones de convocatorias [9]; este estudio encuentra señal en PBC paraguayos completos. La coincidencia apoya la idea general de que el lenguaje disponible durante la convocatoria permite anticipar desenlaces, pero no permite equiparar variables objetivo ni magnitudes.

VigIA utiliza metadatos e índices orientados a sobrecostos, demoras e irregularidades en Colombia [7]. El presente trabajo usa texto y un estado final más amplio. Los enfoques podrían complementarse en el futuro, pero su unión requeriría un conjunto paraguayo donde ambos tipos de variables estén disponibles en el mismo momento.

Los modelos mexicanos centrados en corrupción usan información relacional de compradores y proveedores [34]. Como el presente experimento no incorpora redes, no puede evaluar esa dimensión. La comparación confirma que “analítica de contratación” comprende tareas heterogéneas y que las métricas solo son comparables cuando coinciden etiqueta, momento y población.

5.11. Síntesis de hallazgos

Los hallazgos pueden resumirse de la siguiente forma:

1. Los modelos no triviales ordenaron mejor que referencias sin habilidad, lo que evidencia señal textual en el subconjunto.
2. TF-IDF más regresión logística logró el mejor ranking y la mayor exactitud balanceada de la tabla principal.
3. El transformer entre fragmentos logró el mejor Brier y el mayor F1 a umbral 0,5.
4. El promedio de embeddings permaneció cerca del transformer, por lo que no se observó una ventaja general del modelado entre fragmentos.
5. La optimización de umbral benefició métricas y modelos de manera desigual.
6. La pérdida de documentos durante recuperación y embedding limita la extrapolación al universo de la DNCP.

Estas conclusiones se restringen a la evidencia observada y servirán de base para el capítulo final.

Capítulo 6

Conclusiones y trabajos futuros

Este trabajo abordó la predicción de resultados de licitaciones públicas de construcción vial en Paraguay a partir del texto de PBC disponible durante la convocatoria. Para ello construyó un conjunto supervisado mediante datos abiertos de la DNCP, comparó representaciones léxicas y densas, y evaluó por separado ranking, clasificación a umbral fijo, calibración y sensibilidad al umbral.

6.1. Conclusiones finales

La primera conclusión es que los documentos procesados contienen señal predictiva sobre la etiqueta operacionalizada. Los modelos TF-IDF, promedio de embeddings y transformer entre fragmentos superaron a las referencias triviales en métricas de ranking. Esta evidencia se limita al subconjunto de 1.162 procesos que completó descarga, extracción y generación de embeddings.

La segunda conclusión es que la representación más compleja no dominó todos los criterios. TF-IDF más regresión logística produjo el mejor ROC AUC y PR AUC, además de la mayor exactitud balanceada de la comparación principal. El resultado confirma la importancia de incluir líneas base léxicas en documentos estandarizados y extensos.

La tercera conclusión es que los modelos densos aportaron una ventaja diferente. El transformer entre fragmentos obtuvo el menor puntaje de Brier y el mayor F1 con umbral 0,5. El MLP con embeddings promediados se mantuvo próximo en ranking y calibración. Por tanto, buena parte de la información útil ya estaba presente en las representaciones congeladas, mientras que las interacciones entre fragmentos no produjeron una mejora general de ranking.

La cuarta conclusión es que el umbral forma parte del modelo operativo. La selección interna mejoró considerablemente el F1 de TF-IDF, pero no su exactitud balanceada. El transformer cambió poco. Estos resultados muestran que un umbral optimizado para una métrica no debe trasladarse a otra finalidad ni a una población con prevalencia diferente.

La quinta conclusión se refiere a la cobertura. El universo inicial fue de 10.628 procesos, pero solo 1.845 PBC se recuperaron y 1.162 documentos generaron embeddings. La priorización de estados no exitosos y los fallos de memoria alteraron la composición. Por esta razón, las métricas caracterizan el subconjunto procesado, no toda la contratación pública paraguaya.

Varias limitaciones deben matizar la interpretación de los resultados. En primer lugar, el conjunto supervisado es un subconjunto procesado y no una muestra representativa de toda la población de contrataciones. La inclusión exigía disponibilidad documental, extracción exitosa del texto, generación exitosa de embeddings y uno de los dos estados finales definidos. Como el filtrado se debió principalmente a restricciones de tiempo y presupuesto de procesamiento, las conclusiones deben entenderse como aplicables al subconjunto procesado.

En segundo lugar, el subconjunto procesado presenta menos desbalance que la población real. Los datos experimentales contienen alrededor de 73 % de ejemplos positivos, mientras que la población general está mucho más inclinada hacia resultados exitosos, con aproximadamente 94 % de positivos. Esta diferencia importa porque las métricas dependientes del umbral y las interpretaciones sensibles a la prevalencia no son invariantes al balance de clases. Los puntos operativos informados no deben considerarse directamente despleables sin recalibrarlos en el entorno objetivo.

En tercer lugar, la falta de transferibilidad del umbral es una preocupación práctica. Los umbrales optimizados en validación mejoran algunas métricas de la muestra actual, especialmente para TF-IDF más regresión logística, pero pueden cambiar bajo otras prevalencias, contextos institucionales o supuestos sobre el costo de los errores. Por tanto, el ajuste debe interpretarse como una herramienta de análisis para este conjunto y no como una prescripción universal.

En cuarto lugar, la principal preocupación residual no es una fuga directa de información sobre el resultado final. Como los documentos se producen durante la convocatoria, tal fuga parece poco probable. Los riesgos más relevantes son las correlaciones predictivas indirectas, el aprendizaje de atajos, la representatividad limitada y el desajuste de distribución. Por ejemplo, los modelos podrían aprovechar regularidades institucionales o estilísticas predictivas en este conjunto, pero menos estables entre organismos,

períodos o categorías de contratación. Los hallazgos también pueden ser específicos de la construcción vial y no transferirse sin cambios a otras categorías.

Este trabajo presentó un estudio comparativo de representaciones léxicas y basadas en LLM para predecir resultados de contrataciones públicas a partir de documentos de licitación. Los resultados muestran que estos documentos contienen una señal predictiva considerable, pero también que el modelo con mejor ordenamiento en la configuración actual es una línea base léxica clásica: TF-IDF más regresión logística. Al mismo tiempo, el transformer entre fragmentos sobre embeddings de LLM alcanza la mejor calibración y la mayor estabilidad ante cambios del umbral.

La comparación también indica que gran parte de la señal densa útil ya está presente en los embeddings congelados, dado que las líneas base con promedio se mantienen próximas al transformer. Esto sugiere que el modelado explícito de interacciones entre fragmentos no ofrece actualmente una ventaja clara de ordenamiento, aunque todavía puede aportar valor práctico mediante probabilidades más confiables y un comportamiento de decisión más estable. Los trabajos futuros deberían evaluar otros dominios de contratación y otros codificadores congelados.

La principal contribución del estudio es esta comparación empírica e interpretativa. Demuestra que las características léxicas capturan gran parte de la señal predictiva del dominio, que las representaciones densas preentrenadas continúan siendo útiles y que la calidad del ordenamiento, la calibración y la sensibilidad al umbral deben analizarse por separado. Estos hallazgos conectan la evaluación de aprendizaje automático con las necesidades de la gobernanza pública digital: antes de que las herramientas predictivas puedan respaldar la transparencia, la rendición de cuentas o la supervisión ciudadana de las contrataciones, sus señales, limitaciones y comportamiento operativo deben hacerse explícitos.

6.2. Respuesta a las preguntas de investigación

1. **Señal textual:** sí, dentro del subconjunto procesado, porque todos los modelos no triviales superaron a los controles en ranking.
2. **Léxico frente a denso:** TF-IDF fue superior en ranking; las representaciones densas fueron competitivas y ofrecieron mejores valores de Brier en dos configuraciones.
3. **Interacciones entre fragmentos:** no se observó una ventaja general. El transformer destacó en calibración y estabilidad, no en AUC.

4. **Separación de criterios:** las conclusiones cambiaron según ranking, umbral y calibración, por lo que informar una sola métrica habría ocultado diferencias relevantes.
5. **Transferencia:** la cobertura incompleta, la prevalencia inducida y la especialización en construcción vial impiden tratar los resultados como directamente desplegables.

6.3. Aportes del trabajo

El trabajo deja una canalización auditable que conserva identificadores entre la API de la DNCP, los PBC, el texto y los embeddings. Documenta además los fallos del embudo, condición necesaria para interpretar la selección de datos. En el plano experimental, ofrece una comparación controlada entre cuatro familias no triviales y controles sin habilidad. En el plano aplicado, vincula la evaluación con necesidades de transparencia y supervisión sin confundir predicción con causalidad o decisión jurídica.

6.4. Trabajos futuros

6.4.1. Ampliación y representatividad del conjunto

Una primera línea consistirá en completar la recuperación de PBC para reducir el sesgo por tiempo y límites de solicitudes. El proceso deberá respetar las políticas del servicio, utilizar reanudación y registrar motivos de fallo para cada tender. También será necesario incorporar OCR y medir su calidad sobre documentos escaneados.

Los 680 textos sin embedding podrán reprocesarse con más memoria, fragmentos menores, cuantización o un codificador más eficiente. La comparación deberá informar resultados tanto sobre la intersección común como sobre la población ampliada, para no confundir una mejora de modelo con un cambio de casos incluidos.

6.4.2. Validación temporal e institucional

La validación cruzada aleatoria estratificada estima desempeño dentro de la distribución procesada. Una evaluación temporal entrenará con años anteriores y probará en posteriores, reproduciendo mejor un despliegue. Otra evaluación agrupará por organismo convocante para determinar si el modelo generaliza a instituciones no vistas y cuánto depende de plantillas específicas.

Estas particiones podrán reducir el desempeño; precisamente por ello aportarán evidencia sobre robustez. También deberán impedir que versiones casi idénticas de una plantilla aparezcan simultáneamente en entrenamiento y prueba.

6.4.3. Otras categorías de contratación

El código 72131701 delimita construcción vial. Trabajos futuros incorporarán otras obras, bienes y servicios. La ampliación permitirá evaluar si la fortaleza de TF-IDF se debe a estandarización sectorial y si los embeddings densos transfieren mejor entre dominios.

No se mezclará inicialmente toda la contratación en una sola partición. Se informarán resultados por categoría y se analizarán diferencias de prevalencia, longitud y calidad documental.

6.4.4. Análisis explicativo del texto

La regresión logística permite inspeccionar coeficientes, pero los términos más ponderados pueden actuar como sustitutos de institución, fecha o plantilla. Se requerirán análisis de estabilidad por pliegue, eliminación de encabezados, agrupación por organismo y revisión cualitativa de n-gramas antes de atribuir significado sustantivo.

Para modelos densos podrán utilizarse ablaciones por secciones, atención agregada o métodos de perturbación. Tales explicaciones deberán validarse y presentarse como evidencia del comportamiento del modelo, no como causas del resultado administrativo.

6.4.5. Nuevas representaciones y agregadores

Se evaluarán codificadores multilingües especializados en embeddings, modelos de atención dispersa, pooling atento y modelos de espacio de estados. La literatura muestra que estas alternativas responden de forma distinta a longitud y fragmentación [14, 15, 36].

También podrá compararse el último token válido con promedio interno, token especial o pooling aprendido. Para aislar efectos, cada experimento mantendrá constantes las particiones y la cabeza cuando cambie el codificador, y mantendrá fijo el codificador cuando cambie el agregador.

6.4.6. Calibración y decisión

Una aplicación probabilística requerirá calibración sobre datos independientes. Podrán evaluarse escalamiento de temperatura, calibración sigmoide e isotónica, respetando una partición exclusiva para ajustar el calibrador [27, 28]. La calidad se medirá por período, organismo y grupo de longitud.

La elección de umbral deberá basarse en costos definidos con usuarios institucionales. Si un falso negativo implica omitir un expediente relevante y un falso positivo consume tiempo de revisión, ambos costos deben expresarse y someterse a análisis de sensibilidad. El umbral no será tratado como propiedad permanente del modelo.

6.4.7. Integración con variables estructuradas

El PBC puede combinarse con metadatos disponibles durante la convocatoria: organismo, modalidad, monto estimado, plazos o clasificación. Trabajos como VigIA muestran el valor de variables estructuradas para supervisión [7]. Un modelo multimodal permitirá medir cuánto aporta el texto después de controlar esos factores.

La integración deberá aplicar una regla temporal estricta. Campos publicados después del resultado se excluirán o se utilizarán únicamente en análisis retrospectivo claramente separado.

6.4.8. Gobernanza y uso responsable

Antes de un piloto institucional se elaborará una ficha de modelo con población objetivo, datos, métricas, fallos conocidos, frecuencia de actualización y responsables. Se establecerá revisión humana, registro de decisiones y mecanismos para impugnar interpretaciones. La recomendación de la OCDE vincula contratación electrónica con transparencia, integridad, acceso y evaluación, principios que deberán guiar cualquier uso [16].

La herramienta no deberá etiquetar corrupción, ilegalidad o responsabilidad sin evidencia y proceso competente. Su rol potencial será ordenar o señalar casos para análisis. El beneficio deberá medirse mediante una evaluación prospectiva: tiempo ahorrado, cobertura de revisión y calidad de hallazgos frente al procedimiento habitual.

6.5. Consideración final

Los PBC paraguayos contienen información aprovechable para análisis predictivo, pero su uso responsable exige conservar el contexto institucional, la temporalidad y las limitaciones de cobertura. La comparación demuestra que métodos simples y complejos pueden sobresalir en dimensiones diferentes. El siguiente paso no consiste únicamente en aumentar la escala del modelo, sino en ampliar y validar los datos, definir una finalidad pública concreta y asegurar que la señal estadística permanezca subordinada a la revisión y a las garantías del proceso de contratación.

Bibliografía

- [1] Congreso de la Nación Paraguaya. *Ley N.º 7021/2022 de Suministro y Contrataciones Públicas*. Biblioteca y Archivo Central del Congreso de la Nación. 2022. URL: <https://www.bacn.gov.py/leyes-paraguayas/11220/ley-n-70212022-de-suministro-y-contrataciones-publica> (visitado 23-07-2026).
- [2] Dirección Nacional de Contrataciones Públicas. *Ley 7021 de Suministro y Contrataciones Públicas*. 2026. URL: <https://www.contrataciones.gov.py/dncp/ley-7021/ley-7021-de-suministro-y-contrataciones-publicas/> (visitado 23-07-2026).
- [3] Ministerio de Tecnologías de la Información y Comunicación. *Gobierno electrónico*. 2026. URL: <https://mitic.gov.py/gobierno-electronico/> (visitado 23-07-2026).
- [4] Dirección Nacional de Contrataciones Públicas. *Open Contracting*. 2026. URL: <https://www.contrataciones.gov.py/datos/open-contracting-info> (visitado 23-07-2026).
- [5] Open Contracting Partnership. *How the Open Contracting Data Standard Works*. 2026. URL: <https://standard.open-contracting.org/latest/en/primer/how/> (visitado 23-07-2026).
- [6] Open Contracting Partnership. *OCDS Codelists*. 2026. URL: <https://standard.open-contracting.org/latest/en/schema/codelists/> (visitado 23-07-2026).
- [7] Andrés Salazar, Juan F. Pérez y Jorge Gallego. «VigIA: Prioritizing Public Procurement Oversight With Machine Learning Models and Risk Indices». En: *Data & Policy* 6 (2024), e75. DOI: 10.1017/dap.2024.83. URL: <https://doi.org/10.1017/dap.2024.83>.
- [8] Jorge Gallego, Rivero Gonzalo y Juan Martínez. «Preventing Rather Than Punishing: An Early Warning Model of Malfeasance in Public Procurement». En: *International Journal of Forecasting* 37.3 (2021), págs. 360-377. DOI: 10.1016/j.ijforecast.2020.06.006.

- [9] U. U. Acikalin et al. «How You Describe Procurement Calls Matters: Predicting Outcome of Public Procurement Using Call Descriptions». En: *Natural Language Engineering* (2024).
- [10] Sida Wang y Christopher D. Manning. «Baselines and Bigrams: Simple, Good Sentiment and Topic Classification». En: *Proc. 50th Annu. Meeting Assoc. Comput. Linguist. (ACL)*. 2012, págs. 90-94.
- [11] R. A. Alva Principe, N. Chiarini y M. Viviani. «Long Document Classification in the Transformer Era: A Survey on Challenges, Advances and Open Issues». En: *WIREs Data Mining and Knowledge Discovery* 15.2 (2025), e70019.
- [12] Liang Wang et al. «Improving Text Embeddings With Large Language Models». En: *Proc. 62nd Annu. Meeting Assoc. Comput. Linguist. (ACL)*. 2024, págs. 12089-12117.
- [13] Ashish Vaswani et al. «Attention Is All You Need». En: *Advances in Neural Information Processing Systems*. Vol. 30. 2017. URL: https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html.
- [14] Iz Beltagy, Matthew E. Peters y Arman Cohan. *Longformer: The Long-Document Transformer*. arXiv:2004.05150. 2020. DOI: 10.48550/arXiv.2004.05150. URL: <https://arxiv.org/abs/2004.05150>.
- [15] Xiang Dai et al. «Revisiting Transformer-based Models for Long Document Classification». En: *Findings of the Association for Computational Linguistics: EMNLP 2022*. 2022, págs. 7212-7230. DOI: 10.18653/v1/2022.findings-emnlp.534. URL: <https://aclanthology.org/2022.findings-emnlp.534/>.
- [16] Organisation for Economic Co-operation and Development. *Recommendation of the Council on Public Procurement*. OECD Legal Instruments. 2015. URL: <https://legalinstruments.oecd.org/public/doc/131/131.en.pdf> (visitado 23-07-2026).
- [17] Dirección Nacional de Contrataciones Públicas. *Datos abiertos de contrataciones públicas*. 2026. URL: <https://www.contrataciones.gov.py/datos/data> (visitado 23-07-2026).
- [18] Open Contracting Partnership. *OCDS Schema Reference*. 2026. URL: <https://standard.open-contracting.org/latest/en/schema/reference/> (visitado 23-07-2026).
- [19] Open Contracting Partnership. *Open Contracting Data Standard*. 2026. URL: <https://www.open-contracting.org/data-standard/> (visitado 23-07-2026).
- [20] Gerard Salton y Christopher Buckley. «Term-Weighting Approaches in Automatic Text Retrieval». En: *Information Processing & Management* 24.5 (1988), págs. 513-523. DOI: 10.1016/0306-4573(88)90021-0.

- [21] Jacob Devlin et al. «BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding». En: *Proceedings of NAACL-HLT*. 2019, págs. 4171-4186. DOI: 10.18653/v1/N19-1423. URL: <https://aclanthology.org/N19-1423/>.
- [22] Liang Wang et al. *Multilingual E5 Text Embeddings: A Technical Report*. arXiv:2402.05672. 2024. DOI: 10.48550/arXiv.2402.05672. URL: <https://arxiv.org/abs/2402.05672>.
- [23] S. Agarwal et al. *gpt-oss-120b & gpt-oss-20b Model Card*. arXiv:2508.10925. 2025.
- [24] Dimitris Mamakas et al. «Processing Long Legal Documents with Pre-trained Transformers: Modding LegalBERT and Longformer». En: *Proceedings of the Natural Legal Language Processing Workshop 2022*. 2022, págs. 130-142. DOI: 10.18653/v1/2022.nllp-1.11. URL: <https://aclanthology.org/2022.nllp-1.11/>.
- [25] Dinghan Shen et al. *Baseline Needs More Love: On Simple Word-Embedding-Based Models and Associated Pooling Mechanisms*. arXiv:1805.09843. 2018. URL: <https://arxiv.org/abs/1805.09843>.
- [26] Eve Richardson et al. «The Receiver Operating Characteristic Curve Accurately Assesses Imbalanced Datasets». En: *Patterns* (2024).
- [27] Chuan Guo et al. «On Calibration of Modern Neural Networks». En: *Proceedings of the 34th International Conference on Machine Learning*. Vol. 70. 2017, págs. 1321-1330. URL: <https://proceedings.mlr.press/v70/guo17a.html>.
- [28] Telmo Silva Filho et al. «Classifier Calibration: A Survey on How to Assess and Improve Predicted Class Probabilities». En: *Machine Learning* 112 (2023), págs. 3211-3260.
- [29] Ilya Loshchilov y Frank Hutter. «Decoupled Weight Decay Regularization». En: *International Conference on Learning Representations*. 2019. URL: <https://openreview.net/forum?id=Bkg6RiCqY7>.
- [30] Dirección Nacional de Contrataciones Públicas. *Reglamentaciones de la Ley 7021/2022*. 2026. URL: <https://www.contrataciones.gov.py/dncp/ley-7021/reglamentaciones-2/> (visitado 23-07-2026).
- [31] Dirección Nacional de Contrataciones Públicas. *Guía de ofertas electrónicas para proveedores*. 2026. URL: <https://www.contrataciones.gov.py/dncp/guia-ofertas-electronicas/guia-ofertas-electronicas-proveedores/> (visitado 23-07-2026).
- [32] Contraloría General de la República del Paraguay. *Portal de datos abiertos*. 2026. URL: <https://datos.contraloria.gov.py/> (visitado 23-07-2026).

- [33] Elisabeth Kehler, Julio Paciello y Juan Pane. «Anomaly Detection in Public Procurements Using the Open Contracting Data Standard». En: *Proceedings of the 13th Alberto Mendelzon International Workshop on Foundations of Data Management*. Vol. 2369. CEUR Workshop Proceedings. 2019, págs. 89-95. URL: <https://ceur-ws.org/Vol-2369/short09.pdf>.
- [34] Andrés Aldana, Andrea Falcón-Cortés y Hernán Larralde. *A Machine Learning Model to Identify Corruption in México's Public Procurement Contracts*. arXiv:2211.01478. 2022. DOI: 10.48550/arXiv.2211.01478. URL: <https://arxiv.org/abs/2211.01478>.
- [35] Mohit Tuteja y Daniel González Juclà. «Long Text Classification Using Transformers with Paragraph Selection Strategies». En: *Proceedings of the Natural Language Processing Workshop 2023*. 2023, págs. 17-24. DOI: 10.18653/v1/2023.nllp-1.3. URL: <https://aclanthology.org/2023.nllp-1.3/>.
- [36] Peng Lu et al. «Efficient Classification of Long Documents with State-Space Models». En: *Proceedings of EMNLP 2023*. 2023, págs. 6559-6565. DOI: 10.18653/v1/2023.emnlp-main.404. URL: <https://aclanthology.org/2023.emnlp-main.404/>.
- [37] Guangzeng Han, Jack Tsao y Xiaolei Huang. «Length-Aware Multi-Kernel Transformer for Long Document Classification». En: *Proceedings of the 13th Joint Conference on Lexical and Computational Semantics*. 2024, págs. 278-290. DOI: 10.18653/v1/2024.starsem-1.22. URL: <https://aclanthology.org/2024.starsem-1.22/>.
- [38] Liang Wang et al. *Text Embeddings by Weakly-Supervised Contrastive Pre-training*. arXiv:2212.03533. 2022. URL: <https://arxiv.org/abs/2212.03533>.