UNIVERSIDAD NACIONAL DE ASUNCIÓN

FACULTAD POLITÉCNICA

INGENIERÍA EN INFORMÁTICA



REPRESENTACIONES LÉXICAS Y BASADAS EN LLM PARA LA PREDICCIÓN DE RESULTADOS DE LICITACIONES PÚBLICAS: UN ESTUDIO COMPARATIVO

Proyecto Final de Grado

Autores:

Isaac Gabriel Amarilla Benítez

Luis Fernando Caballero Ramoa

San Lorenzo – Paraguay

2026

Resumen

En Paraguay, una vía habitual de ejecución del presupuesto público es la contratación de bienes, servicios y obras mediante procedimientos competitivos. Esos procedimientos se desarrollan por etapas que incluyen la convocatoria, la evaluación, la adjudicación, el contrato y el cierre, y dejan registro de las reglas bajo las cuales el mercado puede participar. El documento que concentra esas reglas al comienzo del proceso es el Pliego de Bases y Condiciones (PBC): reúne requisitos administrativos, especificaciones técnicas y criterios de evaluación antes de que se conozcan la adjudicación, el contrato o el desenlace final. En este trabajo se investiga si, a partir del contenido de esos pliegos, es posible obtener información suficiente para estimar de forma temprana si un proceso tenderá a concluir con un resultado exitoso o fallido. La pregunta se formula en el marco institucional paraguayo: la Ley N.º 7021/2022 organiza la contratación como una cadena administrativa registrada en el Sistema de Información de las Contrataciones Públicas, y la Dirección Nacional de Contrataciones Públicas divulga metadatos y documentos mediante datos abiertos y el Estándar de Datos para las Contrataciones Abiertas. Por publicarse antes del resultado, el PBC ofrece una señal disponible de forma temprana, sin recurrir a información posterior que constituiría fuga.

El trabajo no busca demostrar causalidad, fraude o ilegalidad. La salida de un modelo se entiende como una señal analítica para priorización y estudio, no como una decisión administrativa ni como una imputación sobre una entidad o un proveedor. Las preguntas de investigación indagan cuánta señal predictiva contiene el PBC; cómo se comparan una representación léxica TF–IDF y embeddings densos producidos por un modelo grande de lenguaje congelado; si el modelado explícito de relaciones entre fragmentos aporta ventaja frente a promediar esos embeddings; si las conclusiones cambian al distinguir ordenamiento, desempeño a umbral fijo, calibración y sensibilidad al umbral; y qué limitaciones de cobertura impiden trasladar los resultados a un escenario operativo.

El marco teórico sitúa al PBC dentro del ciclo de suministro público y desarrolla los fundamentos de representación textual, fragmentación de documentos extensos, arquitectura transformer, clasificación binaria y calibración. Los trabajos relacionados contrastan la analítica de contratación basada en datos estructurados, los sistemas de supervisión con advertencias tempranas, la predicción a partir de descripciones de convocatorias y la literatura sobre clasificación de documentos largos, donde las líneas base léxicas siguen siendo competitivas.

El experimento se delimita a contrataciones de construcción vial. De 10.628 procesos iniciales se recuperaron 1.845 PBC y se generaron embeddings para 1.162 documentos, con

844 casos etiquetados como exitosos (`complete`) y 318 como no exitosos (`unsuccessful`, `cancelled` o `canceled`). Cada documento se tokeniza y se divide en fragmentos de 4.096 tokens con desplazamiento de 2.048. Un modelo de lenguaje causal de pesos abiertos se usa como codificador congelado. Se comparan TF–IDF con regresión logística, el promedio de embeddings con regresión logística y con un perceptrón multicapa, un transformer liviano entre fragmentos, y controles de mayoría y aleatorio. La evaluación emplea validación cruzada estratificada de 5 pliegues e informa ROC AUC, PR AUC, F1, exactitud balanceada, puntaje de Brier y pérdida logarítmica.

Los PBC procesados contienen señal predictiva: todos los modelos no triviales superan a los controles. TF–IDF obtiene el mejor ordenamiento, con ROC AUC medio de 0,814 y PR AUC de 0,899, además de la mayor exactitud balanceada. El transformer logra la mejor calibración, con un puntaje de Brier de 0,162, y el comportamiento más estable al ajustar el umbral; su F1 a umbral 0,5 es el más alto, aunque no lidera el ranking. Las variantes con embeddings promediados se mantienen próximas al transformer, lo que indica que gran parte de la información densa ya está en la representación congelada.

Estas métricas caracterizan el subconjunto procesado, no toda la contratación paraguaya. La cobertura documental es incompleta, la prevalencia experimental, del 72,6 % de positivos, difiere de la poblacional y el umbral no se transfiere automáticamente. El aporte de este trabajo es una canalización auditable, una comparación controlada entre familias de modelos y una evaluación que separa criterios en lugar de reducirlos a una sola cifra. Los trabajos futuros incluyen completar la recuperación de documentos, incorporar reconocimiento óptico de caracteres, validar en el tiempo y por organismo, ampliar otras categorías de contratación y subordinar cualquier uso a gobernanza institucional.

Palabras clave: contratación pública, gobierno electrónico, democracia electrónica, documentos de licitación, pliego de bases y condiciones, modelos grandes de lenguaje, predicción de resultados.

Abstract

In Paraguay, a common means of executing the public budget is the procurement of goods, services, and works through competitive procedures. Those procedures unfold in stages that include the call for tenders, evaluation, award, contract, and closure, and leave a record of the rules under which the market may participate. The document that concentrates those rules at the beginning of the process is the bidding document or Pliego de Bases y Condiciones (PBC): it gathers administrative requirements, technical specifications, and evaluation criteria before the award, the contract, or the final outcome are known. This work investigates whether, from the content of those bidding documents, it is possible to obtain enough information to estimate early whether a process is likely to conclude with a successful or unsuccessful outcome. The question is posed within the Paraguayan institutional framework: Law No. 7021/2022 organizes procurement as an administrative chain recorded in the Public Procurement Information System, and the National Directorate of Public Procurement releases metadata and documents through open data and the Open Contracting Data Standard. Because it is published before the outcome, the PBC provides an early available signal, without resorting to later information that would constitute leakage.

The work does not seek to demonstrate causality, fraud, or illegality. The output of a model is understood as an analytical signal for prioritization and study, not as an administrative decision or as an imputation against an entity or a supplier. The research questions inquire how much predictive signal the PBC contains; how a lexical TF–IDF representation and dense embeddings produced by a frozen large language model compare; whether explicitly modeling relations among chunks improves on averaging those embeddings; whether conclusions change when ranking, fixed-threshold performance, calibration, and threshold sensitivity are distinguished; and which coverage limitations preclude transferring the results to an operational setting.

The theoretical framework places the PBC within the public-supply cycle and develops the foundations of text representation, long-document chunking, the transformer architecture, binary classification, and calibration. Related work contrasts procurement analytics based on structured data, oversight systems with early warnings, prediction from call descriptions, and the literature on long-document classification, where lexical baselines remain competitive.

The experiment is limited to road-construction procurements. From 10,628 initial processes, 1,845 PBCs were retrieved and embeddings were generated for 1,162 documents, with 844 cases labeled successful (`complete`) and 318 unsuccessful (`unsuccessful`, `cancelled`,

or `canceled`). Each document is tokenized and split into chunks of 4,096 tokens with a stride of 2,048. An open-weight causal language model is used as a frozen encoder. The comparison includes TF–IDF with logistic regression, mean embeddings with logistic regression and with a multilayer perceptron, a lightweight cross-chunk transformer, and majority and random controls. Evaluation uses stratified 5-fold cross-validation and reports ROC AUC, PR AUC, F1, balanced accuracy, Brier score, and log loss.

The processed PBCs contain predictive signal: every non-trivial model outperforms the controls. TF–IDF yields the strongest ranking, with mean ROC AUC 0.814 and PR AUC 0.899, as well as the highest balanced accuracy. The transformer achieves the best calibration, with a Brier score of 0.162, and the most stable behavior under threshold tuning; its F1 at threshold 0.5 is the highest, although it does not lead the ranking. Mean-embedding variants remain close to the transformer, indicating that much of the dense information is already present in the frozen representation.

These metrics characterize the processed subset, not Paraguayan procurement as a whole. Document coverage is incomplete, the experimental prevalence of 72.6% positive cases differs from the population prevalence, and the threshold does not transfer automatically. The contribution of this work is an auditable pipeline, a controlled comparison across model families, and an evaluation that separates criteria rather than reducing them to a single figure. Future work includes completing document retrieval, incorporating optical character recognition, validating over time and across agencies, extending to other procurement categories, and subordinating any use to institutional governance.

Keywords: public procurement, electronic government, electronic democracy, bidding documents, bidding terms and conditions, large language models, outcome prediction.

Índice general

Resumen I

Abstract III

Contenidos V

Lista de Figuras VIII

Lista de Tablas IX

Glosario X

1. Introducción 1
- 1.1. Planteamiento del problema . . . 3
- 1.2. Preguntas de investigación . . . 5
- 1.3. Objetivos . . . 5
  - 1.3.1. Objetivo general . . . 5
  - 1.3.2. Objetivos específicos . . . 5
- 1.4. Alcance y delimitaciones . . . 6
- 1.5. Contribuciones . . . 7
- 1.6. Organización del libro . . . 7

2. Marco teórico 8
- 2.1. Marco institucional de la contratación pública . . . 8
  - 2.1.1. Cadena de suministro y temporalidad . . . 8
  - 2.1.2. Datos abiertos y Estándar de Datos para las Contrataciones Abiertas 10
  - 2.1.3. El PBC como objeto de análisis . . . 11
- 2.2. Clasificación supervisada y resultado que se busca predecir . . . 11
- 2.3. Del PDF a fragmentos . . . 12
  - 2.3.1. Extracción de texto desde PDF . . . 12
  - 2.3.2. Tokenización y fragmentación . . . 13
- 2.4. Representación léxica . . . 13
  - 2.4.1. Espacio vectorial y ponderación TF–IDF . . . 14
  - 2.4.2. Regresión logística sobre características léxicas . . . 14
- 2.5. Representación densa y modelado de documentos . . . 15
  - 2.5.1. Codificador congelado . . . 15
  - 2.5.2. Atención y arquitectura transformer . . . 16
  - 2.5.3. Agregación de fragmentos . . . 17

2.6. Evaluación predictiva . . . 18
2.6.1. Desbalance, umbral y ordenamiento . . . 18
2.6.2. Calibración probabilística . . . 19
2.6.3. Validación cruzada y reproducibilidad . . . 20

3. Trabajos relacionados **21**
3.1. Antecedentes fundacionales: representaciones simples y calibración (2012–2018) . . . 21
3.2. Datos abiertos y advertencias tempranas en contratación (2019–2021) . . . 22
3.3. Documentos extensos, relaciones y embeddings transferibles (2020–2022) . . . 22
3.4. Consolidación de métodos para textos largos (2023) . . . 23
3.5. Predicción textual y modelos recientes (2024–2026) . . . 24
3.6. Síntesis cronológica de los antecedentes . . . 25
3.7. Oportunidad de la propuesta . . . 26

4. Propuesta de experimentación numérica **28**
4.1. Fuente y procedencia de los datos . . . 28
4.1.1. API de la DNCP . . . 28
4.1.2. Conjunto inicial . . . 29
4.2. Conjunto de datos . . . 29
4.3. Tratamiento de la fuga de información . . . 30
4.4. Protocolo de evaluación . . . 31
4.5. Métricas . . . 31
4.6. Recuperación de documentos PBC . . . 32
4.7. Extracción y normalización del texto . . . 33
4.8. Generación de embeddings . . . 33
4.8.1. Codificador congelado . . . 33
4.8.2. Control de memoria . . . 33
4.9. Embudo de construcción del conjunto supervisado . . . 34
4.10. Definición de la instancia y etiqueta . . . 35
4.11. Modelos que se evaluarán . . . 35
4.11.1. Representación documental . . . 35
4.11.2. Arquitectura del predictor . . . 36
4.11.3. Líneas base . . . 37
4.12. Entrenamiento y reproducibilidad . . . 38
4.12.1. Líneas base triviales . . . 38
4.12.2. TF–IDF con regresión logística . . . 38
4.12.3. Promedio con regresión logística . . . 38
4.12.4. Promedio con MLP . . . 38
4.12.5. Transformer entre fragmentos . . . 39
4.13. Ambiente de software . . . 39
4.14. Partición y protocolo de evaluación . . . 39
4.15. Entrenamiento . . . 40
4.16. Métricas de evaluación . . . 40
4.17. Trazabilidad y reproducibilidad . . . 40
4.18. Amenazas a la validez previstas . . . 41

5. Pruebas experimentales y análisis de resultados computacionales 42
5.1. Ambiente de ejecución . . . 42
5.2. Hiperparámetros utilizados . . . 43
5.3. Comprobaciones previas . . . 44
5.4. Desempeño de ordenamiento . . . 45
5.5. Sensibilidad al umbral . . . 45
5.6. Calibración . . . 46
5.7. Comparación de representaciones . . . 46
5.8. Lectura comparativa por criterio . . . 46
5.8.1. Ranking . . . 46
5.8.2. Desempeño con umbral 0,5 . . . 47
5.8.3. Calibración . . . 48
5.9. Análisis de sensibilidad al umbral . . . 49
5.10. Comparación entre hipótesis experimentales . . . 50
5.10.1. Señal textual frente a controles . . . 50
5.10.2. Representación léxica frente a densa . . . 51
5.10.3. Interacciones entre fragmentos . . . 51
5.11. Costo y complejidad experimental . . . 51
5.12. Discusión de resultados . . . 52
5.12.1. Implicaciones para Paraguay . . . 53
5.12.2. Comparación con otros países . . . 53
5.13. Síntesis de hallazgos . . . 54

6. Conclusiones y trabajos futuros 55
6.1. Conclusiones finales . . . 55
6.2. Respuesta a las preguntas de investigación . . . 57
6.3. Aportes del trabajo . . . 58
6.4. Trabajos futuros . . . 58
6.4.1. Ampliación y representatividad del conjunto . . . 58
6.4.2. Validación temporal e institucional . . . 58
6.4.3. Otras categorías de contratación . . . 59
6.4.4. Análisis explicativo del texto . . . 59
6.4.5. Nuevas representaciones y agregadores . . . 59
6.4.6. Calibración y decisión . . . 60
6.4.7. Integración con variables estructuradas . . . 60
6.4.8. Gobernanza y uso responsable . . . 60
6.5. Consideración final . . . 61

Referencias 62

Índice de figuras

5.1. Curvas de precisión-exhaustividad de los modelos comparados. 48
5.2. Curvas de calibración de los modelos comparados. 49
5.3. Sensibilidad de F1 y exactitud balanceada al ajuste del umbral. 50

Índice de tablas

3.1. Evolución de trabajos relacionados seleccionados. 25

4.1. Embudo de datos desde procesos DNCP hasta el conjunto supervisado. . . 34
4.2. Conteos por estado en etapas principales. 34
4.3. Componentes principales del ambiente de software versionado. 39

5.1. Información de hardware respaldada por los artefactos del proyecto. 43
5.2. Hiperparámetros de representación y codificación documental. 43
5.3. Hiperparámetros de los modelos evaluados. 44
5.4. Comparación de modelos mediante validación cruzada de 5 pliegues (media ± desviación estándar). Un valor menor es mejor para Brier; un valor mayor es mejor para las demás métricas. 47
5.5. Ajuste del umbral en una partición interna de validación y evaluación en el pliegue externo de prueba. Se informan las medias de todos los pliegues. 47

Glosario

Acrónimos

API *Application Programming Interface*
AUC *Area Under the Curve*
CV *Cross-Validation*
DNCP Dirección Nacional de Contrataciones Públicas
GPU *Graphics Processing Unit*
LLM *Large Language Model*
MLP *Multilayer Perceptron*
OCDE Organización para la Cooperación y el Desarrollo Económicos
OCDS *Open Contracting Data Standard*
OCR *Optical Character Recognition*
PBC Pliego de Bases y Condiciones
PR *Precision–Recall*
ROC *Receiver Operating Characteristic*
SICP Sistema de Información de las Contrataciones Públicas
TF–IDF *Term Frequency–Inverse Document Frequency*

Términos

Agregación por promedio: operación que resume varios embeddings mediante su media aritmética para obtener una única representación.

Calibración: grado de correspondencia entre las probabilidades predichas y las frecuencias observadas de un resultado.

Clasificación binaria: tarea de asignar cada ejemplo a una de dos clases posibles.

Codificador congelado: modelo preentrenado cuyos parámetros no se actualizan durante el entrenamiento del predictor posterior.

Detención temprana: criterio que interrumpe el entrenamiento cuando el desempeño de validación deja de mejorar durante un número prefijado de épocas.

Embedding: representación vectorial densa de una unidad textual, producida por un modelo para codificar regularidades de su contenido y contexto.

Época: recorrido completo del algoritmo de entrenamiento sobre todos los ejemplos de la partición destinada al ajuste.

Fragmento: segmento de tokens en el que se divide un documento para respetar el límite de entrada del codificador.

Fuga de información: uso durante el entrenamiento o la selección de información que no estaría disponible en el momento real de la predicción.

Hiperparámetro: valor fijado antes del entrenamiento que controla la configuración o el comportamiento de un modelo.

Logit: salida numérica de un clasificador antes de transformarla en probabilidad mediante una función como la sigmoide.

n-grama: secuencia contigua de n unidades de texto. En este trabajo las unidades son palabras: un unigrama contiene una palabra y un bigrama contiene dos.

Ordenamiento: capacidad de asignar puntajes mayores a los ejemplos positivos que a los negativos, independientemente de un umbral fijo.

Prevalencia: proporción de ejemplos pertenecientes a la clase positiva dentro de un conjunto de datos.

Representación densa: vector numérico en el que la información se distribuye entre un número fijo de componentes, generalmente no nulas.

Representación dispersa: vector de alta dimensión en el que la mayoría de los componentes son cero, como una representación TF–IDF.

Token: unidad mínima de texto procesada por un tokenizador; puede corresponder a una palabra, parte de ella o un símbolo.

Transformer: arquitectura neuronal basada principalmente en mecanismos de atención para modelar relaciones entre elementos de una secuencia.

Umbral de decisión: valor de corte aplicado a un puntaje o probabilidad para convertirlo en una predicción de clase.

Validación cruzada: procedimiento que divide los datos en varios pliegues y alterna cuáles se usan para entrenamiento y evaluación.

Capítulo 1

Introducción

La contratación pública articula la planificación estatal con la provisión efectiva de bienes, obras y servicios. En Paraguay, la Ley N.º 7021/2022 define la contratación del suministro público como una secuencia ordenada que comprende la identificación de una necesidad, la estimación del valor, la definición de la estrategia de adquisición, la contratación, la ejecución y, cuando corresponde, la liquidación. La misma norma dispone que esas acciones queden registradas en el Sistema de Información de las Contrataciones Públicas (SICP) (Congreso de la Nación Paraguaya, 2022). Por ello, la contratación pública no constituye un evento aislado, sino un proceso trazable cuyo registro digital puede utilizarse para transparencia, control y análisis.

La reforma introducida por la Ley N.º 7021/2022 busca modernizar las compras del Estado paraguayo, fortalecer la competencia, prevenir conflictos de interés y optimizar los controles mediante mecanismos normativos y tecnológicos (Dirección Nacional de Contrataciones Públicas, 2026b). Este marco se relaciona con la política nacional de gobierno electrónico, que incluye portales de servicios, interoperabilidad institucional, datos abiertos y acceso ciudadano a la información (Ministerio de Tecnologías de la Información y Comunicación, 2026). El portal de la Dirección Nacional de Contrataciones Públicas (DNCP) publica información mediante servicios de consulta y archivos históricos; además, adopta el Estándar de Datos para las Contrataciones Abiertas (OCDS) para representar etapas como planificación, convocatoria, adjudicación, contrato e implementación (Dirección Nacional de Contrataciones Públicas, 2026c; Open Contracting Partnership, 2026a).

Dentro de este proceso, el Pliego de Bases y Condiciones (PBC) ocupa una posición particular. Se produce antes de conocerse el resultado y reúne requisitos administrativos, especificaciones técnicas, criterios de evaluación, condiciones de participación, plazos y obligaciones. El estándar OCDS distingue precisamente los documentos de licitación,

las especificaciones técnicas y los criterios de evaluación como tipos documentales de la etapa de convocatoria (Open Contracting Partnership, 2026b). En consecuencia, el PBC contiene información disponible antes del resultado final: puede ser analizado sin recurrir a adjudicaciones, contratos ni evaluaciones publicadas después del cierre del proceso.

La disponibilidad previa del documento vuelve pertinente una pregunta predictiva: ¿existen regularidades textuales que permitan estimar si un proceso terminará con un resultado exitoso o no exitoso? Esta pregunta no equivale a determinar causalidad, fraude o ilegalidad. Una predicción puede apoyarse en estructuras documentales, patrones de redacción o características institucionales correlacionadas con el resultado sin que estas constituyan causas del mismo. En este trabajo, la salida del modelo se entiende como una señal analítica para priorización y estudio, no como una decisión administrativa ni como una imputación sobre una entidad o proveedor.

Los sistemas de apoyo a la supervisión requieren esta distinción. El proyecto VigIA, desarrollado para la Veeduría Distrital de Bogotá, combina modelos predictivos e índices de riesgo con el propósito de asignar mejor los recursos de control; sus autores presentan la herramienta como apoyo a los organismos de supervisión para priorizar investigaciones, no como sustituto de la revisión institucional (Salazar et al., 2024). La literatura sobre advertencias tempranas formula una idea similar: el valor operativo de la predicción reside en anticipar dónde conviene revisar, siempre que se documenten el objetivo, las limitaciones y los errores posibles (Gallego et al., 2021). En el contexto paraguayo, esta investigación adopta ese enfoque prudente.

La contratación pública es un proceso central del gobierno electrónico: transforma los presupuestos públicos en contratos, obras y servicios mediante plataformas cada vez más digitales. También es relevante para la democracia electrónica, porque los registros abiertos de contratación amplían la capacidad de los organismos de control, periodistas, empresas y ciudadanos para examinar cómo se asignan los recursos públicos. Estas capacidades se alinean con las agendas de gobierno digital sobre datos abiertos y análisis responsables para la supervisión del sector público. Trabajos recientes en este sector presentan el análisis de contrataciones como una herramienta para la supervisión basada en riesgos (Salazar et al., 2024). Los documentos de licitación son fundamentales en este contexto porque definen las condiciones administrativas, los requisitos técnicos, las reglas de calificación y las restricciones de ejecución antes de que se conozca el resultado final. Evidencia reciente del ámbito de las contrataciones también muestra que las descripciones de las convocatorias permiten predecir resultados relacionados con la competencia y la eficiencia de costos (Acikalin et al., 2024). Por tanto, la pregunta relevante no es solo si los resultados de las licitaciones pueden predecirse a partir del texto documental,

sino también qué representación de ese texto aporta más información para un monitoreo responsable de la contratación pública.

Este trabajo estudia dicha pregunta mediante una comparación directa entre características léxicas dispersas y representaciones densas basadas en LLM. El análisis se concentra en licitaciones de construcción vial, cuyos documentos suelen ser relativamente estructurados y estandarizados. Los modelos léxicos dispersos continúan siendo líneas base sólidas e interpretables para la clasificación documental (S. Wang & Manning, 2012), y trabajos recientes sobre documentos extensos confirman que las representaciones léxicas o híbridas pueden seguir siendo competitivas, en lugar de quedar uniformemente superadas por arquitecturas transformer (Alva Principe et al., 2025). Al mismo tiempo, la investigación sobre embeddings se ha extendido hacia representaciones densas basadas en LLM (L. Wang et al., 2024a). En este contexto, el objetivo no es establecer una familia de modelos universalmente superior, sino comprender cuánta señal predictiva puede recuperarse de indicios léxicos, cuánta ya está capturada por embeddings densos congelados y si el modelado explícito de interacciones entre fragmentos aporta valor adicional.

La canalización utiliza un LLM causal preentrenado como codificador congelado para producir embeddings por fragmento a partir de documentos de licitación en español. Se comparan dos estrategias simples de agregación de estos embeddings, basadas en agrupación por promedio, con un transformer liviano que modela las interacciones entre fragmentos. Estos enfoques basados en LLM se evalúan junto con TF–IDF más regresión logística y líneas base triviales. Este diseño permite separar los efectos de la representación de los efectos del modelado posterior.

El estudio ofrece una comparación reproducible entre líneas base léxicas, triviales, de embeddings agregados y de un transformer entre fragmentos, bajo validación cruzada determinista de 5 pliegues. También analiza por separado el desempeño de ordenamiento, la calibración y la sensibilidad al umbral. El resultado central presenta matices: TF–IDF más regresión logística es el modelo con mejor ordenamiento, mientras que el transformer entre fragmentos ofrece la mejor calibración y el comportamiento más estable ante cambios del umbral. Esto aporta evidencia útil para la pregunta más amplia de cómo se distribuye la señal textual en los documentos de contratación pública. Los artefactos asociados están archivados en Zenodo (doi:10.5281/zenodo.20128768).

1.1. Planteamiento del problema

El SICP y el portal de datos abiertos permiten recuperar metadatos estructurados, estados y documentos asociados a procesos de contratación. Sin embargo, un PBC es un

documento extenso y heterogéneo. Puede contener texto corrido, formularios, cuadros, cláusulas repetidas, anexos y especificaciones propias de una obra. La disponibilidad del archivo no implica que su información sea inmediatamente utilizable por un modelo: primero deben localizarse los documentos, descargarse, extraerse como texto, dividirse en unidades manejables y transformarse en variables numéricas.

La longitud introduce una dificultad adicional. Los transformers convencionales emplean autoatención cuyo costo crece cuadráticamente con la longitud de la secuencia (Vaswani et al., 2017). La literatura de clasificación documental ha abordado esta limitación mediante truncamiento, atención dispersa y esquemas jerárquicos que dividen el documento en fragmentos y luego agregan sus representaciones (Beltagy et al., 2020; Dai et al., 2022). En PBC extensos, truncar el comienzo o el final puede omitir secciones relevantes, mientras que procesar todos los tokens de una sola vez puede superar la memoria disponible.

Al mismo tiempo, los documentos de contratación utilizan vocabulario recurrente y fórmulas estandarizadas. Esto favorece modelos léxicos como TF–IDF, capaces de representar unigramas y bigramas de todo el texto sin imponer un límite rígido de contexto. La tensión metodológica es, por tanto, concreta: una representación densa preentrenada puede capturar relaciones semánticas, pero requiere una estrategia de fragmentación y agregación; una representación dispersa puede preservar señales léxicas globales y ser más sencilla, aunque no modele el contexto con la misma riqueza.

El problema experimental consiste en comparar ambas familias bajo particiones equivalentes y múltiples criterios de evaluación. No basta con observar exactitud o F1[1]. Un modelo destinado a ordenar casos puede preferirse por ROC AUC[2] o PR AUC[3]; uno destinado a producir probabilidades puede requerir mejor calibración; y un modelo que toma decisiones binarias puede cambiar sustancialmente al mover el umbral. La investigación separa estas dimensiones para evitar afirmar que una única métrica demuestra superioridad general.

[1] F1 combina dos cosas: de lo que el modelo marca como positivo, cuánto acierta; y de todos los positivos reales, cuántos encuentra. Lo usamos cuando hace falta una decisión sí/no según un umbral: el valor de corte a partir del cual un puntaje o una probabilidad se interpreta como positivo.

[2] ROC AUC mide, sin fijar ese umbral, qué tan bien el modelo pone por delante los casos positivos frente a los negativos. Lo usamos para comparar la capacidad de ordenar o priorizar casos.

[3] PR AUC también evalúa el ordenamiento sin fijar el umbral, pero se concentra en el desempeño sobre la clase positiva. Lo usamos junto con ROC AUC porque en datos desbalanceados un buen ordenamiento general no siempre implica buen desempeño sobre esa clase.

1.2. Preguntas de investigación

El trabajo se organiza alrededor de las siguientes preguntas:

1. ¿Cuánta señal predictiva sobre el resultado de una contratación contiene el PBC publicado al inicio del proceso?
2. ¿Cómo se comparan los embeddings densos producidos por un LLM congelado y la representación léxica TF–IDF al extraer esa señal?
3. ¿El modelado explícito de relaciones entre fragmentos aporta una ventaja frente a promediar los embeddings del mismo codificador?
4. ¿Las conclusiones cambian al distinguir ordenamiento, desempeño a umbral fijo, calibración y sensibilidad al umbral?
5. ¿Qué limitaciones de cobertura y representatividad deben considerarse antes de trasladar los resultados a un escenario operativo paraguayo?

Las preguntas se formulan en términos comparativos y no causales. La investigación no intenta demostrar que ciertas palabras provoquen un resultado, ni que una puntuación predicha constituya evidencia jurídica. Busca medir la información predictiva presente en el documento antes del desenlace y caracterizar el comportamiento de diferentes representaciones.

1.3. Objetivos

1.3.1. Objetivo general

Comparar representaciones léxicas y representaciones densas basadas en modelos grandes de lenguaje para predecir resultados de licitaciones públicas de obras viales en Paraguay a partir de PBC publicados antes del resultado final.

1.3.2. Objetivos específicos

1. Construir un subconjunto supervisado que vincule estados de procesos de contratación de la DNCP con PBC descargados, texto extraído y representaciones documentales.

2. Cuantificar la señal predictiva contenida en los PBC mediante una evaluación externa al entrenamiento y su comparación con referencias triviales.

3. Comparar el desempeño de embeddings densos producidos por un LLM congelado con el de una representación léxica TF–IDF.

4. Determinar si el modelado explícito de relaciones entre fragmentos aporta ventajas frente a la agregación por promedio de los mismos embeddings.

5. Caracterizar las diferencias entre modelos en términos de ordenamiento, desempeño a umbral fijo, calibración y sensibilidad al umbral.

6. Identificar las limitaciones de cobertura documental, extracción, cómputo, prevalencia y transferencia al entorno real.

1.4. Alcance y delimitaciones

El universo de origen corresponde a procesos paraguayos de construcción vial asociados al código de catálogo `72131701`. La unidad de análisis es el proceso de contratación emparejado con un PBC. La etiqueta positiva corresponde al estado `complete`; la clase negativa agrupa `unsuccessful`, `cancelled` y su variante ortográfica `canceled`. Esta operacionalización permite un experimento reproducible, pero no agota la noción administrativa o económica de éxito.

El análisis se delimita al subconjunto que completó todas las etapas técnicas: disponibilidad del PDF, extracción de texto y generación de embeddings. No se incluyen procesos sin documento recuperado, PDF escaneados que requieren reconocimiento óptico de caracteres ni documentos que no pudieron codificarse con la infraestructura utilizada. Estas exclusiones condicionan la representatividad y se cuantificarán en el capítulo de propuesta experimental.

La investigación tampoco desarrolla un sistema de decisión autónoma. Una aplicación futura requeriría validación temporal, recalibración con la prevalencia de despliegue, revisión de sesgos entre organismos, definición explícita de costos de error y mecanismos de supervisión humana. La recomendación de la OCDE sobre contratación pública vincula el uso de sistemas electrónicos y datos con transparencia, integridad, acceso y evaluación del desempeño; este marco respalda el uso analítico, pero también exige gobernanza (Organisation for Economic Co-operation and Development, 2015).

1.5. Contribuciones

Las contribuciones del trabajo son 4. Primero, presenta una canalización reproducible centrada en PBC paraguayos, desde la consulta de procesos hasta la evaluación. Segundo, compara en condiciones homogéneas una representación léxica, dos agregadores de embeddings y un modelo de interacciones entre fragmentos. Tercero, informa métricas de ordenamiento y calibración por separado, evitando reducir la comparación a una sola cifra. Cuarto, documenta el embudo de datos y sus fallos, de modo que la cobertura observada forme parte de la interpretación y no quede oculta como una decisión de preprocesamiento.

1.6. Organización del libro

El Capítulo 2 presentará el marco institucional y conceptual de la contratación pública y de los sistemas digitales que respaldan su registro y publicación, así como los fundamentos de representación textual, transformers, clasificación, calibración y evaluación. El Capítulo 3 recorrerá cronológicamente la evolución de la analítica de contratación y del procesamiento de documentos extensos, y concluirá con la oportunidad y el aporte de la propuesta. El Capítulo 4 describirá la construcción del conjunto de datos, la canalización, los modelos y el protocolo que se empleará. El Capítulo 5 expondrá las pruebas y analizará sus resultados. Finalmente, el Capítulo 6 sintetizará las conclusiones y propondrá trabajos futuros.

Capítulo 2

Marco teórico

Este capítulo presenta los conceptos necesarios para interpretar el problema, los modelos y las métricas. Primero se describe el marco institucional de la contratación pública y se sitúa al PBC dentro de ese ciclo. Luego se define el resultado que se busca predecir. A continuación se recorre la canalización: del PDF a fragmentos, de los fragmentos a representaciones léxicas o densas, y de estas a una decisión evaluable. Finalmente se presentan las métricas, la calibración y la validación experimental.

2.1. Marco institucional de la contratación pública

La contratación pública paraguaya determina qué información existe, en qué momento se publica y qué documento puede usarse sin fuga. Esta sección reúne la cadena administrativa, el estándar de datos abiertos y las propiedades del PBC como objeto de análisis.

2.1.1. Cadena de suministro y temporalidad

La Ley N.º 7021/2022 crea el Sistema Nacional de Suministro Público y regula al Sistema Nacional de Contrataciones Públicas como parte de una cadena integrada (Congreso de la Nación Paraguaya, 2022). Esta formulación amplía el foco desde el acto de adjudicar hacia una sucesión de actividades: planificación de la necesidad, estimación, estrategia de adquisición, convocatoria, evaluación, contratación, ejecución y cierre. Cada etapa produce datos y documentos con distinto momento de disponibilidad.

La cadena integrada es más amplia que una licitación concreta. Comienza con la identificación y planificación de necesidades, continúa con la programación presupuestaria y la

elaboración del Programa Anual de Contrataciones, e incorpora un estudio de mercado para estimar costos, conocer la oferta disponible y definir la estrategia de adquisición. Estas decisiones determinan el procedimiento de selección, los requisitos de participación y los criterios con los que se evaluarán las ofertas, conforme a los artículos 6, 9, 10, 13 y 25–28 de la Ley N.º 7021/2022 (Congreso de la Nación Paraguaya, 2022).

Dentro de la gestión de la contratación, la convocante elabora y aprueba el PBC antes de publicar la convocatoria. Desde ese momento, los potenciales oferentes pueden consultar el documento y solicitar aclaraciones; la convocante puede emitir modificaciones, que pasan a integrar las bases del llamado. Luego se presentan y abren las ofertas técnicas y económicas. Un comité verifica su conformidad con el PBC, analiza los criterios técnicos y económicos y emite un informe que sirve de fundamento para adjudicar, declarar desierto o cancelar el procedimiento. La adjudicación selecciona al oferente con quien se formalizará el contrato, pero todavía no equivale a la ejecución ni al cierre de la contratación. Esta secuencia se encuentra regulada en los artículos 45–55 de la misma ley (Congreso de la Nación Paraguaya, 2022).

Después de la adjudicación se formaliza el contrato y se designa a quien controlará su cumplimiento. Durante la ejecución se registran avances, pagos, garantías, modificaciones e incumplimientos. En obras públicas, además, se realizan mediciones, certificaciones, fiscalización y recepciones parciales o definitivas. El ciclo concluye, según corresponda, con la recepción, la liquidación y la evaluación de si la contratación contribuyó a las metas institucionales, de acuerdo con los artículos 58–83 (Congreso de la Nación Paraguaya, 2022). Por tanto, el resultado estudiado en este trabajo se ubica dentro de un proceso administrativo más amplio y no representa por sí solo una evaluación integral del contrato ni de la obra.

La temporalidad es central para un problema predictivo. Los datos de planificación y convocatoria están disponibles antes del resultado; los datos de adjudicación y contrato aparecen después. Si el propósito es estimar un desenlace antes de que ocurra, las variables deben limitarse a información accesible en ese momento. Utilizar campos posteriores aumentaría artificialmente el desempeño y constituiría fuga de información. Por ello, esta investigación utiliza texto de PBC y excluye del vector de entrada la adjudicación, la evaluación posterior y el estado final que define la etiqueta.

El SICP es el soporte informático donde se registran y publican actuaciones del proceso paraguayo. La DNCP expone una API de servicios para datos actuales y archivos estáticos para reconstrucción histórica desde 2010 (Dirección Nacional de Contrataciones Públicas, 2026c). La propia DNCP advierte que los conjuntos publicados reproducen la información remitida por las entidades convocantes y que la responsabilidad sobre su veracidad recae en ellas (Dirección Nacional de Contrataciones Públicas, 2026a). Esta

característica importa metodológicamente: un registro abierto es una fuente oficial de publicación, pero no garantiza por sí solo ausencia de errores, campos faltantes o diferencias de calidad entre instituciones.

2.1.2. Datos abiertos y Estándar de Datos para las Contrataciones Abiertas

El Estándar de Datos para las Contrataciones Abiertas (OCDS) propone un modelo común para divulgar información y documentos durante todo el proceso de contratación. Organiza la información en etapas de licitación, adjudicación, contrato e implementación, y permite registrar sucesivas publicaciones de un mismo proceso (Open Contracting Partnership, 2026a, 2026c). La estandarización facilita combinar fuentes, reconstruir cambios y reutilizar herramientas analíticas; no reemplaza, sin embargo, al sistema transaccional que origina los datos (Open Contracting Partnership, 2026d).

En OCDS, una publicación o *release* representa información correspondiente a un evento del ciclo. Varias publicaciones pueden compilarse en un registro que resume el proceso. Entidades compradoras, proveedores, valores, períodos, artículos, documentos y estados se expresan mediante estructuras y listas controladas. Paraguay adopta este estándar con extensiones locales y ofrece endpoints de consulta sobre procesos completos (Dirección Nacional de Contrataciones Públicas, 2026a, 2026c).

Para este trabajo son relevantes 3 niveles de información:

1. **Metadatos del proceso**: identificador de contratación, OCID, estado y clasificación del objeto.
2. **Metadatos documentales**: título, tipo, formato y URL de los adjuntos asociados a la convocatoria.
3. **Contenido no estructurado**: texto interno del PBC descargado, que no está reducido a los campos del esquema.

La clasificación de catálogo `72131701` delimita los procesos de construcción de rutas. El código se utiliza como filtro técnico de la consulta y no como una inferencia posterior. La elección reduce heterogeneidad temática, dado que compara documentos de un mismo ámbito, pero también restringe la validez externa a otras obras, bienes o servicios.

2.1.3. El PBC como objeto de análisis

El PBC comunica a potenciales oferentes las condiciones del procedimiento. OCDS define los documentos de licitación como documentación que describe el objeto y el proceso de presentación de ofertas; separa además las especificaciones técnicas y los criterios de evaluación (Open Contracting Partnership, 2026b). En la práctica, un archivo paraguayo puede integrar varias de estas funciones, junto con formularios y anexos.

Desde la perspectiva del procesamiento del lenguaje natural, el PBC presenta varias propiedades:

- **Longitud**: puede superar ampliamente el límite de entrada de un codificador convencional.
- **Estructura semiformateada**: alterna párrafos, títulos, listas y tablas.
- **Redundancia**: reutiliza cláusulas y plantillas institucionales.
- **Especialización**: incluye terminología jurídica, administrativa y de ingeniería vial.
- **Variabilidad**: cambia según convocante, año, modalidad, complejidad y anexos.

Estas propiedades explican por qué no existe una representación obviamente superior. La repetición puede favorecer n-gramas; la equivalencia semántica entre formulaciones puede favorecer embeddings; y la dispersión de información a lo largo del documento puede justificar modelos jerárquicos.

2.2. Clasificación supervisada y resultado que se busca predecir

El estudio busca anticipar el estado con el que cada contratación queda registrada a partir del texto de su PBC. Para ello se utilizan únicamente procesos que cuentan con un documento aprovechable y con uno de los estados finales considerados. Los estados se agrupan en dos resultados:

- Se considera exitoso el proceso registrado como `complete`.
- Se considera no exitoso el proceso registrado como `unsuccessful`, `cancelled` o `canceled`.

Los términos `cancelled` y `canceled` expresan el mismo estado, "cancelado", con las grafías británica y estadounidense del inglés; ambos aparecen en los datos de origen y por eso se normalizan dentro del mismo grupo. Reducir los estados a estas dos alternativas convierte el problema en una clasificación binaria: para cada PBC, el modelo estima la probabilidad de que el proceso pertenezca al primer grupo.

Los registros con otros estados se excluyen del entrenamiento y de la evaluación. Esta agrupación es una decisión operativa basada en la fuente disponible. Un proceso `complete` no implica necesariamente máximo valor público, y una cancelación puede responder a causas legítimas; por tanto, la etiqueta no constituye una evaluación integral de éxito, eficiencia o integridad.

Formalmente, cada ejemplo se representa mediante un par (x_i, y_i), donde x_i es el texto del PBC y $y_i \in \{0, 1\}$ es la etiqueta: se asigna $y_i = 1$ al resultado exitoso y $y_i = 0$ al no exitoso. El modelo aprende una función que produce la probabilidad estimada de pertenecer al primer grupo:

$$f(x_i) = \hat{p}_i \approx P(y_i = 1 \mid x_i). \tag{2.1}$$

Así, $\hat{p}_i$ no expresa una certeza ni una valoración jurídica del proceso, sino la probabilidad que el modelo asigna al estado operacionalizado como exitoso a partir del texto disponible.

2.3. Del PDF a fragmentos

Un PBC no entra al modelo como archivo. Debe extraerse texto, segmentarse en unidades del vocabulario del modelo y partirse en fragmentos que respeten el límite de contexto. Las decisiones de esta etapa condicionan tanto a TF–IDF como a los embeddings.

2.3.1. Extracción de texto desde PDF

PDF describe la disposición visual de una página y no necesariamente conserva una secuencia textual limpia. La extracción debe reconstruir palabras y líneas a partir de objetos posicionados. El repositorio utiliza `pdfplumber` para texto y contempla `Camelot` para tablas. Los documentos compuestos únicamente por imágenes requieren reconocimiento óptico de caracteres, capacidad que no forma parte de la ejecución documentada. Por eso, 3 PDF escaneados no generaron texto y quedaron fuera de etapas posteriores.

Los errores de extracción pueden alterar saltos, orden de columnas, caracteres y tablas. En un modelo léxico, estas alteraciones modifican términos y n-gramas; en un tokenizador subléxico, cambian la segmentación. Documentar las pérdidas evita atribuir al modelo limitaciones originadas en la digitalización.

2.3.2. Tokenización y fragmentación

Un tokenizador transforma texto en identificadores del vocabulario del modelo. Los modelos preentrenados suelen usar unidades subléxicas: una palabra puede corresponder a uno o varios tokens. Esto permite representar vocabulario abierto, pero significa que el número de palabras no coincide con la longitud computacional. La configuración del proyecto tokeniza sin truncamiento inicial, conserva la secuencia en CPU y transfiere a GPU únicamente microlotes de fragmentos.

Sea T la longitud total del documento en tokens, L el tamaño máximo de cada fragmento y S el desplazamiento entre comienzos consecutivos. Los comienzos se ubican en $0, S, 2S, \ldots$ hasta cubrir el documento. Cuando $S < L$, fragmentos consecutivos comparten $L - S$ tokens. En este estudio se adoptan $L = 4096$ y $S = 2048$, de modo que el solapamiento nominal es del 50 %. Estos valores se toman como configuración de base de trabajos previos sobre documentos extensos: Longformer opera con ventanas de hasta 4096 tokens (Beltagy et al., 2020), y los esquemas jerárquicos que dividen el texto en fragmentos con solapamiento han mostrado buen desempeño al recuperar más contexto que el truncamiento simple (Dai et al., 2022; Mamakas et al., 2022). El solapamiento del 50 % reduce la probabilidad de cortar una relación justo en una frontera, aunque incrementa la cantidad de cómputo y introduce contenido repetido. La cantidad aproximada de fragmentos N para $T > L$ es:

$$N \approx 1 + \left\lceil \frac{T - L}{S} \right\rceil . \tag{2.2}$$

La implementación no impone por defecto un máximo documental adicional. En consecuencia, documentos muy extensos producen secuencias de muchos embeddings y demandan más memoria tanto en codificación como en la agregación posterior.

2.4. Representación léxica

La vía léxica representa el documento completo como un vector disperso de términos y n-gramas, sin fragmentarlo para respetar un límite de contexto. Esta sección presenta el esquema TF–IDF y el clasificador lineal que se le asocia.

2.4.1. Espacio vectorial y ponderación TF–IDF

Una representación de bolsa de palabras describe un documento mediante la presencia o frecuencia de términos y omite el orden global. Si el vocabulario contiene V términos, cada documento se transforma en $x \in \mathbb{R}^V$. La matriz resultante es dispersa porque cada documento utiliza solo una fracción del vocabulario.

La frecuencia de término $tf(t, d)$ mide cuántas veces aparece el término t en el documento d. La frecuencia inversa de documento reduce el peso de términos presentes en muchos documentos. Una forma habitual es:

$$idf(t) = \log\left(\frac{M+1}{df(t)+1}\right) + 1, \tag{2.3}$$

donde M es la cantidad de documentos y $df(t)$ la cantidad que contiene t. El peso combinado es:

$$tfidf(t, d) = tf(t, d)\, idf(t). \tag{2.4}$$

La ponderación TF–IDF pertenece a una familia de esquemas de importancia de términos estudiada en recuperación de información; Salton y Buckley (1988) mostraron que la elección del esquema de ponderación es decisiva para el desempeño de representaciones de términos individuales. En clasificación, unigramas capturan vocabulario y bigramas preservan patrones locales como expresiones administrativas frecuentes.

2.4.2. Regresión logística sobre características léxicas

La regresión logística convierte un vector de características en una probabilidad entre 0 y 1. Sea $x \in \mathbb{R}^V$ el vector TF–IDF del documento, $w \in \mathbb{R}^V$ el vector de coeficientes aprendidos y $b \in \mathbb{R}$ el sesgo (término independiente). El modelo construye primero una puntuación lineal o *logit*

$$z = w^\top x + b, \tag{2.5}$$

donde $w^\top x$ es el producto punto entre coeficientes y características. Cada componente w_j indica cuánto aporta la característica j a favor (si es positiva) o en contra (si es negativa) de la clase positiva. La puntuación z se transforma con la función sigmoide σ, que comprime cualquier número real al intervalo $(0, 1)$:

$$\hat{p}(y = 1 \mid x) = \sigma(z) = \frac{1}{1 + e^{-z}}. \tag{2.6}$$

Aquí $y \in \{0, 1\}$ es la etiqueta verdadera del ejemplo y $\hat{p}(y = 1 \mid x)$ es la probabilidad estimada de que el documento pertenezca a la clase positiva dado x. Cuando z crece, $\hat{p}$ se acerca a 1; cuando z decrece, se acerca a 0.

Los coeficientes w asocian dimensiones léxicas con el logaritmo de las razones de probabilidades. Esta linealidad facilita inspeccionar términos con pesos altos o bajos, aunque la interpretación requiere cautela ante correlaciones, n-gramas redundantes y regularización.

El modelo del proyecto limita el vocabulario a 50.000 características, incluye unigramas y bigramas, descarta términos con frecuencia documental inferior a 5 y usa pesos balanceados por clase. La frecuencia documental cuenta en cuántos documentos distintos aparece un término, con independencia de la cantidad de veces que se repita dentro de cada uno. El umbral de 5 se fijó como un criterio conservador de filtrado: elimina términos presentes únicamente en unos pocos documentos, más susceptibles a corresponder a errores de extracción, identificadores únicos o asociaciones espurias, pero conserva expresiones recurrentes incluso cuando aparecen en una proporción pequeña del corpus. En cada pliegue, con aproximadamente 930 documentos de entrenamiento, este requisito representa cerca del 0,54 % y constituye, por tanto, un filtro poco restrictivo. El valor se estableció como un hiperparámetro del diseño experimental y no se optimizó sobre los pliegues externos de evaluación. Los pesos balanceados modifican la contribución de cada clase a la función de pérdida, sin cambiar la prevalencia real del conjunto de evaluación.

2.5. Representación densa y modelado de documentos

La vía densa no representa términos individuales, sino vectores aprendidos durante el preentrenamiento. Como el PBC supera el contexto del codificador, primero se obtienen embeddings por fragmento y después se decide cómo agregarlos en una representación documental.

2.5.1. Codificador congelado

Una representación densa asigna el texto a un vector de dimensión fija cuyo contenido se aprende durante el preentrenamiento. A diferencia de TF–IDF, las dimensiones no corresponden directamente a términos. El trabajo sobre BERT demostró que representaciones bidireccionales preentrenadas podían adaptarse a múltiples tareas con pocas

capas específicas (Devlin et al., 2019). Trabajos posteriores extendieron el uso de modelos grandes para producir embeddings generales mediante aprendizaje contrastivo o instrucciones (L. Wang et al., 2024a, 2024b).

El proyecto utiliza `openai/gpt-oss-20b`, un modelo causal de pesos abiertos, como codificador congelado (S. Agarwal et al., 2025). Para cada fragmento se extrae el estado oculto del último token válido. Al congelar el codificador, sus parámetros no se actualizan con las etiquetas; el aprendizaje supervisado ocurre únicamente en el agregador o clasificador posterior. Esto reduce el costo de entrenamiento repetido y separa la representación preentrenada del efecto del clasificador.

La salida de un documento es, por tanto, una secuencia de embeddings de fragmentos:

$$\mathbf{E} = [\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_N], \qquad \mathbf{e}_i \in \mathbb{R}^{d_{in}},$$

donde N es la cantidad de fragmentos y d_{in} está determinado por el tamaño oculto del modelo preentrenado. Un embedding útil no garantiza automáticamente el mejor resultado para todos los dominios. La calidad depende del idioma, el tipo documental, el objetivo de preentrenamiento, el método de pooling y la correspondencia entre las tareas de origen y destino. Por ello, el valor de la representación debe medirse empíricamente frente a líneas base apropiadas.

2.5.2. Atención y arquitectura transformer

El transformer reemplaza recurrencia por atención y capas prealimentadas (Vaswani et al., 2017). A partir de una secuencia de entrada, el mecanismo construye 3 matrices: las consultas Q, que representan la información buscada por cada posición; las claves K, contra las cuales se comparan las consultas; y los valores V, cuyo contenido se combina para producir la salida. Si d_k es la dimensión de cada clave, la atención de producto punto escalado se expresa como:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}}\right) V. \tag{2.7}$$

El producto $QK^\top$ contiene los puntajes de similitud entre consultas y claves. La división por $\sqrt{d_k}$ evita que su magnitud crezca excesivamente al aumentar la dimensión. La función *softmax*, aplicada sobre los puntajes de cada consulta, los transforma en pesos no negativos cuya suma es uno. La multiplicación posterior por V produce, para cada posición, una combinación ponderada de los valores.

La atención multicabeza proyecta las entradas en h subespacios, calcula atenciones paralelas y concatena sus resultados. Para la cabeza i:

$$head_i = \text{Attention}(QW_i^Q, KW_i^K, VW_i^V), \tag{2.8}$$

donde W_i^Q, W_i^K y W_i^V son matrices de proyección aprendidas. Las salidas de las h cabezas se combinan mediante:

$$\text{MultiHead}(Q, K, V) = \text{Concat}(head_1, \ldots, head_h)W^O. \tag{2.9}$$

La matriz aprendida W^O proyecta la concatenación a la dimensión de salida del bloque. Cada cabeza puede enfatizar relaciones diferentes. Sin embargo, la matriz $QK^\top$ tiene tamaño cuadrático respecto de la longitud. Longformer reduce este costo combinando ventanas locales y atención global dispersa (Beltagy et al., 2020). Otra familia de soluciones adopta una jerarquía: codifica fragmentos por separado y modela luego la secuencia de representaciones. Estudios comparativos muestran que la posibilidad de procesar más texto suele ser beneficiosa, aunque el método óptimo depende del dominio y la distribución de longitudes (Dai et al., 2022; Mamakas et al., 2022).

2.5.3. Agregación de fragmentos

Una vez obtenida $\mathbf{E}$, el documento debe resumirse en una entrada para el clasificador. La forma más simple es el promedio:

$$\bar{e} = \frac{1}{N}\sum_{i=1}^{N} e_i. \tag{2.10}$$

El método es económico e invariante al orden. Esta última propiedad es también su limitación: no distingue qué fragmento apareció primero ni modela relaciones entre secciones. Aun así, líneas base de pooling simple han demostrado ser competitivas en múltiples tareas, por lo que omitirlas puede exagerar el valor de arquitecturas más complejas (Shen et al., 2018). Sobre este vector pueden ajustarse una regresión logística o un perceptrón multicapa; ambas variantes aíslan el contenido de la representación congelada sin introducir una red sobre la secuencia de fragmentos.

La alternativa secuencial es un transformer liviano entre fragmentos. El predictor proyecta cada $e_i \in \mathbb{R}^{2880}$ a $d_{model} = 128$, inserta un vector `[CLS]` entrenable y aplica una capa de codificador con 4 cabezas, dimensión interna 512 y dropout 0,3. En síntesis, el modelo:

1. proyecta linealmente d_{in} a d_{model};
2. inserta el token aprendido `[CLS]` al comienzo de la secuencia;
3. aplica un codificador transformer sobre los vectores de fragmentos;
4. clasifica con una cabeza multicapa sobre la representación final de `[CLS]`.

El vector `[CLS]` produce un logit z por documento, convertido en probabilidad mediante $\hat{p}(y = 1 \mid \mathbf{E}) = \sigma(z)$. El entrenamiento utiliza entropía cruzada binaria con logits. A diferencia del promedio, este mecanismo puede asignar pesos contextuales y modelar interacciones; a diferencia de aplicar el LLM completo durante cada pliegue, reutiliza embeddings congelados.

Las máscaras de relleno distinguen fragmentos reales de posiciones añadidas para formar lotes. Sin ellas, el modelo podría atender a valores de relleno y aprender artefactos asociados a la longitud. La arquitectura implementada utiliza normalización previa y activación GELU, conforme a la capa `TransformerEncoderLayer` disponible en PyTorch.

2.6. Evaluación predictiva

Comparar representaciones exige separar qué pregunta responde cada métrica: si se ordenan bien los casos, si una clase se predice a un umbral dado, si las probabilidades son confiables y si la evaluación es externa al ajuste.

2.6.1. Desbalance, umbral y ordenamiento

Un conjunto está desbalanceado cuando las clases tienen frecuencias distintas. La exactitud simple puede ser engañosa: un clasificador que predice siempre la mayoría obtiene una exactitud igual a su prevalencia sin separar casos. La exactitud balanceada promedia la sensibilidad de cada clase. Sean TP los verdaderos positivos, TN los verdaderos negativos, FP los falsos positivos y FN los falsos negativos:

$$BA = \frac{1}{2}\left(\frac{TP}{TP + FN} + \frac{TN}{TN + FP}\right). \tag{2.11}$$

El puntaje F1 combina precisión y exhaustividad de la clase positiva. La precisión es $Precision = TP/(TP + FP)$ (de lo marcado como positivo, cuánto acierta) y la exhaustividad es $Recall = TP/(TP + FN)$ (de todos los positivos reales, cuántos encuentra):

$$F1 = 2\frac{Precision \cdot Recall}{Precision + Recall}. \tag{2.12}$$

F1 depende de cuál clase se declara positiva y del umbral. En este estudio la clase positiva es además la mayoritaria del subconjunto procesado, por lo que PR AUC debe compararse con la prevalencia y no con cero. Richardson et al. (2024) subrayan que ROC y PR responden de manera distinta al balance y que su interpretación debe ajustarse a la pregunta de evaluación.

Para obtener una clase se aplica un umbral τ. Sea $\hat{p}$ la probabilidad estimada del ejemplo y $\hat{y}$ la etiqueta predicha; $\mathbb{I}(\cdot)$ vale 1 si la condición se cumple y 0 en caso contrario:

$$\hat{y} = \mathbb{I}(\hat{p} \geq \tau). \tag{2.13}$$

El valor 0,5 es convencional, pero no universalmente óptimo. La selección debe realizarse con datos distintos del conjunto donde se informa el resultado, pues elegir τ sobre el pliegue de prueba sobreajustaría la métrica. El protocolo usa una partición interna de validación y aplica el umbral elegido al pliegue externo sin modificarlo.

ROC AUC estima la probabilidad de que un ejemplo positivo reciba un puntaje mayor que uno negativo. No requiere fijar un umbral. PR AUC resume precisión y exhaustividad al variar el umbral, y su referencia sin habilidad se relaciona con la prevalencia positiva. Ambas evalúan ordenamiento; no garantizan probabilidades calibradas.

2.6.2. Calibración probabilística

Un clasificador está calibrado si, entre casos con probabilidad predicha cercana a p, la frecuencia observada del evento es aproximadamente p. Guo et al. (2017) mostraron que redes modernas pueden lograr buena exactitud y, al mismo tiempo, producir confianzas mal calibradas. Por ello, ordenamiento y calibración son propiedades distintas.

Sea M la cantidad de ejemplos evaluados, $y_i \in \{0, 1\}$ la etiqueta verdadera del ejemplo i y $\hat{p}_i \in (0, 1)$ la probabilidad que el modelo asigna a la clase positiva para ese ejemplo. El puntaje de Brier binario es el error cuadrático medio entre esas probabilidades y las etiquetas:

$$BS = \frac{1}{M}\sum_{i=1}^{M}(\hat{p}_i - y_i)^2. \tag{2.14}$$

Un BS cercano a 0 indica que las probabilidades se acercan a las etiquetas observadas; un valor cercano a 1 corresponde a predicciones sistemáticamente erróneas.

La pérdida logarítmica (o entropía cruzada binaria) penaliza con más fuerza las probabilidades confiadas pero incorrectas:

$$LL = -\frac{1}{M}\sum_{i=1}^{M}\left[y_i \log \hat{p}_i + (1-y_i)\log(1-\hat{p}_i)\right]. \tag{2.15}$$

Cuando $y_i = 1$, solo el término $\log \hat{p}_i$ contribuye; cuando $y_i = 0$, solo $\log(1-\hat{p}_i)$. En ambos casos, cuanto más cerca de la etiqueta esté $\hat{p}_i$, menor es la pérdida.

Ambas son reglas propias: favorecen probabilidades honestas bajo sus supuestos. Sin embargo, el Brier combina componentes de confiabilidad y resolución; un valor menor no debe interpretarse como medida pura de calibración sin considerar discriminación y curvas de confiabilidad (Silva Filho et al., 2023). En consecuencia, este estudio acompaña los puntajes con diagramas de calibración.

2.6.3. Validación cruzada y reproducibilidad

La validación cruzada de K pliegues divide los datos en K subconjuntos. En cada ronda se entrena con $K-1$ y se evalúa con el restante. La estratificación conserva aproximadamente la proporción de clases. Al agregar predicciones externas de todas las rondas, cada ejemplo es evaluado por un modelo que no lo utilizó para ajustarse.

El código fija semilla global y semillas independientes por pliegue, activa comportamiento determinista de cuDNN, inicializa cargadores de datos con generadores controlados y restaura el mejor punto de control mediante detención temprana. AdamW desacopla el decaimiento de pesos del paso adaptativo de optimización (Loshchilov & Hutter, 2019). MLflow registra parámetros, métricas y artefactos; la trazabilidad permite verificar que comparaciones distintas utilizaron las mismas particiones y reglas de etiqueta.

La reproducibilidad no elimina toda variación. Diferencias de hardware, bibliotecas, kernels o implementaciones pueden producir cambios numéricos. El propósito de las medidas adoptadas es reducir fuentes evitables y hacer explícita la configuración, no prometer identidad absoluta bajo cualquier plataforma.

Capítulo 3

Trabajos relacionados

Este capítulo revisa cronológicamente la evolución de los trabajos que sustentan la propuesta. El recorrido parte de líneas base para clasificación textual, continúa con el uso de datos abiertos para supervisar contrataciones públicas y llega a los métodos recientes para representar documentos extensos mediante transformers y embeddings. La cronología permite observar dos desplazamientos: desde variables administrativas estructuradas hacia el contenido textual disponible antes del desenlace, y desde representaciones léxicas hacia modelos densos capaces de procesar contexto. El capítulo concluye con la oportunidad de la propuesta y su diferencia respecto de los antecedentes.

3.1. Antecedentes fundacionales: representaciones simples y calibración (2012–2018)

S. Wang y Manning (2012) mostraron que clasificadores lineales con unigramas y bigramas podían competir con arquitecturas más complejas en tareas de sentimiento y clasificación temática. Este resultado consolidó a las representaciones léxicas como una referencia que no debe omitirse al evaluar métodos neuronales. Para documentos extensos, su interés permanece: TF–IDF puede incorporar vocabulario de todo el documento sin ajustarse al límite de contexto de un transformer y permite inspeccionar los coeficientes aprendidos.

Guo et al. (2017) documentaron que una red con buen desempeño de clasificación podía producir probabilidades mal calibradas y evaluaron métodos de posprocesamiento, como el escalamiento de temperatura. Este antecedente amplió el criterio de comparación: ordenar correctamente los casos no garantiza que los puntajes puedan interpretarse como probabilidades confiables.

Shen et al. (2018) mostraron que mecanismos simples de agregación de embeddings podían competir con redes más complejas en diferentes conjuntos de clasificación textual. La combinación de estos trabajos motiva dos referencias del presente estudio: una representación léxica de documento completo y el promedio de embeddings como agregador sencillo. Una arquitectura de mayor complejidad debe demostrar una ventaja frente a ambas, no solamente frente a controles triviales.

3.2. Datos abiertos y advertencias tempranas en contratación (2019–2021)

En Paraguay, Kehler et al. (2019) utilizaron datos estructurados publicados conforme a OCDS y un bosque de aislamiento para asignar puntajes de anomalía a procesos de contratación. Al contrastar el modelo con procesos que presentaban protestas resueltas a favor del protestante o denuncias ciudadanas, informaron que más del 45 % de los casos potencialmente anómalos fueron identificados como tales. El trabajo demostró la viabilidad de reutilizar los datos abiertos de la DNCP para priorizar revisiones. Sin embargo, su objetivo fue detectar anomalías mediante campos estructurados de diferentes etapas, no anticipar el estado final a partir del texto previo de un PBC.

Gallego et al. (2021) desarrollaron un modelo de advertencia temprana de irregularidades en contratación pública. Su enfoque enfatizó la prevención y la asignación de recursos limitados de control. Esta orientación es relevante para la interpretación de cualquier predicción en el dominio: el puntaje apoya la priorización de casos, pero no sustituye la revisión institucional ni constituye por sí mismo evidencia de irregularidad.

Hasta esta etapa, la evolución principal ocurrió en el uso analítico de registros administrativos y en la formulación preventiva del problema. Los modelos se apoyaban principalmente en variables estructuradas. El contenido completo de los documentos de convocatoria y las dificultades computacionales asociadas con su longitud todavía no ocupaban el centro de la comparación.

3.3. Documentos extensos, relaciones y embeddings transferibles (2020–2022)

En paralelo, la clasificación de documentos extensos comenzó a reemplazar el truncamiento por arquitecturas diseñadas para cubrir más texto. Beltagy et al. (2020) presentaron

Longformer, que redujo el costo de la autoatención mediante ventanas locales y posiciones de atención global. Este trabajo mostró una vía para ampliar el contexto, aunque el costo y el límite de entrada continuaron siendo decisiones relevantes.

Dai et al. (2022) compararon transformers de atención dispersa con enfoques jerárquicos en 4 conjuntos de clasificación de documentos extensos. Encontraron beneficios al procesar una mayor proporción del texto y mostraron que el tamaño de ventana, la atención global y la estrategia de división afectan el desempeño. En el mismo año, Mamakas et al. (2022) estudiaron documentos jurídicos que podían superar incluso los límites de modelos de atención dispersa. Compararon variantes de Longformer, codificadores jurídicos jerárquicos y TF–IDF, y observaron una relación entre desempeño y costo en la que las líneas base dispersas conservaron utilidad. Los PBC comparten con esos documentos la extensión, la estructura formal y el lenguaje especializado, aunque cumplen una función institucional distinta.

Aldana et al. (2022) propusieron para México un ensamble de bosques aleatorios dirigido a identificar contratos asociados con corrupción. Encontraron que las relaciones entre compradores y proveedores podían ser más informativas que los rasgos individuales del contrato. El trabajo amplió la unidad de análisis desde cada registro aislado hacia su estructura relacional, pero empleó información y etiquetas diferentes de las utilizadas en esta investigación.

L. Wang et al. (2022) presentaron E5, un esquema de preentrenamiento contrastivo débilmente supervisado para producir embeddings transferibles a recuperación y clasificación. Esta línea hizo más viable representar textos mediante vectores densos reutilizables sin entrenar desde cero un codificador para cada tarea. En conjunto, los trabajos de 2020–2022 establecieron 3 alternativas para documentos largos: atención dispersa, procesamiento jerárquico de fragmentos y representaciones densas transferibles; al mismo tiempo, confirmaron que las referencias léxicas seguían siendo competitivas.

3.4. Consolidación de métodos para textos largos (2023)

Tuteja y González Juclà (2023) evaluaron transformers y estrategias de selección de párrafos en 6 conjuntos jurídicos de textos extensos, e incluyeron TF–IDF como línea base. Su diseño mostró que seleccionar qué partes procesar es una decisión metodológica y que los modelos neuronales deben compararse con referencias capaces de utilizar el documento completo.

Lu et al. (2023) exploraron modelos de espacio de estados como alternativa de complejidad favorable para la clasificación de documentos extensos. Esta propuesta amplió el

conjunto de arquitecturas disponibles más allá de la atención dispersa y los esquemas jerárquicos, sin establecer un método universalmente dominante.

Por otra parte, Silva Filho et al. (2023) publicaron una revisión de métodos y métricas de calibración. Los autores destacaron que medidas como el puntaje de Brier combinan distintos aspectos de calidad predictiva. Su aporte refuerza la necesidad de separar, al informar resultados, la capacidad de ordenamiento, el desempeño con un umbral fijo y la calidad de las probabilidades.

3.5. Predicción textual y modelos recientes (2024–2026)

Han et al. (2024) estudiaron cómo la variación de longitud afecta la generalización y propusieron kernels sensibles a la longitud para clasificar documentos extensos. En el ámbito de las representaciones densas, el reporte de E5 multilingüe extendió la cobertura a varios idiomas (L. Wang et al., 2024b), mientras que L. Wang et al. (2024a) exploraron el uso de modelos grandes de lenguaje, datos sintéticos y entrenamiento contrastivo para mejorar embeddings. Estos trabajos fortalecieron la hipótesis de que un codificador preentrenado puede aportar información contextual útil, pero no eliminaron la necesidad de evaluar el costo, la cobertura documental y el método de agregación.

En contratación pública, Acikalin et al. (2024) estudiaron si las descripciones de convocatorias permitían predecir resultados vinculados con competencia y costo-efectividad. Este es el antecedente más cercano por el momento de disponibilidad y el tipo de información: aporta evidencia de que el lenguaje publicado antes del desenlace contiene señal predictiva. No obstante, una descripción breve de convocatoria no equivale a un PBC completo. Este último incorpora condiciones, criterios, formularios, especificaciones y anexos, por lo que añade información potencial, pero también ruido, longitud y costo computacional.

También en 2024, VigIA combinó índices de riesgo y modelos de aprendizaje automático para anticipar sobrecostos, demoras e irregularidades en Bogotá (Salazar et al., 2024). Sus variables más importantes incluyeron valor, tiempos contractuales, antigüedad del proveedor y sector. El sistema representa una evolución hacia herramientas construidas junto con organismos de supervisión y orientadas a priorizar casos, aunque sus entradas son metadatos estructurados y su disponibilidad temporal es mixta.

Finalmente, Alva Principe et al. (2025) sistematizaron los desafíos, avances y problemas abiertos de la clasificación de documentos largos en la era de los transformers. La trayectoria conjunta no conduce a una arquitectura única: muestra que la extensión cubierta,

la estrategia de fragmentación, el agregador, la eficiencia y la comparación con líneas base siguen condicionando los resultados.

En el contexto paraguayo, Cabrera Medina et al. (2026) propusieron una metodología para integrar datos abiertos de contrataciones, declaraciones juradas, candidaturas electorales y autoridades electas en un grafo de conocimiento multifuente. El enfoque conecta indicadores de posible manipulación de ofertas a nivel de licitación, comunidades de proveedores que concurren conjuntamente y concentración de adjudicaciones durante transiciones políticas subnacionales. Los productos planteados son comunidades de proveedores ordenadas por riesgo, clasificaciones de concentración por autoridad y período, y una canalización reproducible para monitoreo de integridad. Como el artículo formula una metodología y resultados esperados, debe entenderse como una propuesta para supervisión auditable, no como evidencia de que las relaciones identificadas demuestren colusión.

3.6. Síntesis cronológica de los antecedentes

La Tabla 3.1 ordena los antecedentes más próximos según su año y permite observar la transición desde la analítica estructurada de contrataciones hacia el uso de texto previo al resultado, junto con la evolución de técnicas para documentos extensos.

Tabla 3.1: Evolución de trabajos relacionados seleccionados.

Año	**Trabajo**	**Contexto**	**Entrada o técnica**	**Objetivo principal**
2019	Kehler et al.	Paraguay	Datos OCDS estructurados	Detección de anomalías
2021	Gallego et al.	Contratación pública	Variables administrativas	Advertencia temprana
2022	Dai et al.	Multidominio	Atención dispersa y jerarquías	Clasificación extensa
2022	Aldana et al.	México	Contratos y relaciones	Identificación de corrupción
2024	Acikalin et al.	Convocatorias públicas	Descripciones previas	Competencia y costo-efectividad
2024	VigIA (Salazar et al.)	Colombia	Metadatos e índices	Sobrecostos y demoras
2026	Cabrera Medina et al.	Paraguay	Grafo multifuente y redes	Riesgo de colusión y vínculos políticos

La cronología evidencia que los avances se produjeron en dimensiones complementarias. La literatura de contratación incorporó detección de anomalías, relaciones entre actores, advertencias tempranas, grafos multifuente y texto de convocatorias. La literatura de procesamiento de lenguaje amplió la cobertura de documentos largos y desarrolló embeddings transferibles. Sin embargo, la similitud metodológica no implica equivalencia institucional: las etiquetas, las normas, la calidad de los datos y las prevalencias varían entre países y tareas.

3.7. Oportunidad de la propuesta

Los antecedentes dejan una oportunidad empírica en la intersección de ambas líneas. Entre las fuentes revisadas no se identificó una comparación publicada que reúna simultáneamente PBC completos de Paraguay, predicción del estado final con información disponible antes del desenlace, una línea base TF–IDF, embeddings congelados de un LLM y agregadores de distinta complejidad. Esta formulación delimita la brecha respecto del corpus consultado y no pretende demostrar la inexistencia absoluta de trabajos no indexados.

La propuesta se diferencia de los trabajos paraguayos previos porque no busca anomalías en metadatos estructurados ni construye redes de proveedores y vínculos político-empresariales, sino que mide señal predictiva en el texto del PBC. Se diferencia de los sistemas de advertencia de otros países porque restringe la entrada a información documental disponible durante la convocatoria y porque la etiqueta es el estado final operacionalizado del proceso, no corrupción, sobrecosto o demora. Frente al antecedente textual de Acikalin et al., utiliza documentos completos de construcción vial en lugar de descripciones breves, lo que exige resolver explícitamente la fragmentación y la agregación.

El aporte metodológico no consiste en presentar una nueva arquitectura general. Consiste en realizar una comparación controlada sobre el mismo conjunto y las mismas particiones: TF–IDF con regresión logística; promedio de embeddings con regresión logística; promedio de embeddings con un perceptrón multicapa; y un transformer liviano entre fragmentos. Al mantener fijos los embeddings en los modelos densos, la comparación permite analizar si modelar relaciones entre fragmentos aporta una ventaja respecto de agregarlos por promedio.

El aporte empírico se completa al evaluar por separado ordenamiento, desempeño a umbral fijo, calibración y sensibilidad al umbral, y al documentar el embudo de recuperación de PBC, extracción de texto y generación de embeddings. De este modo, la propuesta

no solo contrasta representaciones léxicas y densas en un contexto paraguayo poco estudiado, sino que también explicita cuánto del universo original puede ser procesado y bajo qué limitaciones deben interpretarse los resultados.

Capítulo 4

Propuesta de experimentación numérica

En este capítulo se describirá el diseño experimental empleado para comparar representaciones textuales en la predicción de resultados de licitaciones públicas paraguayas. Primero se presentarán la procedencia de los datos y la construcción del conjunto supervisado, desde la recuperación de los PBC hasta la definición de la etiqueta. Luego se detallarán los modelos que se evaluarán y el ambiente de software que los implementa. Finalmente se establecerán la partición, el entrenamiento, las métricas y las reglas de reproducibilidad utilizadas para comparar cada alternativa.

La descripción se fundamenta en el código versionado del proyecto y en el embudo de artefactos observado. El hardware empleado durante la ejecución se documentará en el capítulo de resultados, donde puede relacionarse con los costos y fallos efectivamente observados.

4.1. Fuente y procedencia de los datos

4.1.1. API de la DNCP

Los procesos provienen del servicio de datos abiertos de la DNCP. El script `fetch_ids_by_status.py` consulta el endpoint:

https://www.contrataciones.gov.py/datos/api/v3/doc/search/processes

La consulta utiliza `items_per_page=100`, el código de clasificación `72131701`, el estado de la licitación y el número de página. El endpoint forma parte de la publicación paraguaya

basada en Open Contracting (Dirección Nacional de Contrataciones Públicas, 2026a, 2026c). Se recorrieron las páginas disponibles para `unsuccessful` y `cancelled`; cada respuesta se normalizó añadiendo el estado utilizado en la consulta.

De cada registro se recuperaron, cuando estaban disponibles, el OCID, el `tender.id` y los identificadores de adjudicaciones. Si no aparecía `tender.id`, el código utilizó el OCID como alternativa. El identificador de tender se mantuvo como clave para unir etapas posteriores.

4.1.2. Conjunto inicial

El conjunto inicial reunió 3 fuentes almacenadas en DigitalOcean Spaces:

1. `procurements.json`, con 10.000 procesos materializados como `complete` desde una instantánea previa de la DNCP;
2. `ids_unsuccessful.json`, con 257 procesos recuperados de las 3 páginas disponibles;
3. `ids_cancelled.json`, con 371 procesos recuperados de las 4 páginas disponibles.

La unión produjo 10.628 filas. El orden de combinación fue no exitosos, cancelados y completos. Ante identificadores duplicados, la primera capa conservó prioridad y las siguientes rellenaron campos ausentes. El mismo orden definió la cola de descarga, con el propósito de procesar primero la clase minoritaria.

4.2. Conjunto de datos

La instantánea de metadatos utilizada en este trabajo se construyó a partir de registros de contratación pública publicados por la Dirección Nacional de Contrataciones Públicas (DNCP) de Paraguay y recuperados mediante el endpoint oficial de datos abiertos `v3/doc/search/processes`. El conjunto inicial contiene 10.628 contrataciones de construcción vial bajo el código de catálogo `72131701`: 10.000 procesos completados materializados por una canalización previa de extracción de la DNCP y 628 procesos adicionales no exitosos recolectados según su estado. Para reducir el desbalance de clases, la recuperación y el procesamiento priorizaron las contrataciones no exitosas antes que las completadas.

El subconjunto supervisado es menor porque se requieren varios pasos de filtrado. La mayor reducción ocurre antes del procesamiento textual: solo se recuperaron 1.845 PDF

de PBC, principalmente porque los límites de solicitudes de la DNCP impidieron realizar una búsqueda y descarga exhaustivas dentro del tiempo disponible. Luego, la canalización extrajo texto de 1.842 PDF y generó embeddings congelados del LLM para 1.162 documentos. Los 3 fallos de extracción correspondieron a documentos escaneados no compatibles con el extractor sin OCR, mientras que la mayoría de los fallos de generación de embeddings fueron errores por falta de memoria en la GPU, después de una única ejecución limitada por el costo de infraestructura. Por ello, las conclusiones se aplican a este subconjunto procesado y no automáticamente a toda la población de contrataciones.

La distribución de clases del subconjunto procesado presenta un desbalance moderado: 844 contrataciones (72,63 %) están etiquetadas como exitosas (`complete`) y 318 (27,37 %) como no exitosas (`unsuccessful`/`cancelled`/`canceled`). La longitud media representada es de 7,46 fragmentos por contratación, con una desviación estándar de 13,52, una mediana de 3 fragmentos y un máximo de 245. Estos valores indican una distribución de longitudes muy asimétrica, con numerosos documentos cortos y una cantidad menor de documentos considerablemente más largos. La dimensión de los embeddings heredada del LLM base congelado es 2880.

El subconjunto procesado también está menos desbalanceado que la población general de contrataciones. En la instantánea completa, los resultados exitosos son mucho más frecuentes: aproximadamente 10.000 contrataciones exitosas frente a unas 650 no exitosas. Por consiguiente, las métricas dependientes del umbral y las interpretaciones sensibles a la prevalencia deben considerarse válidas para el subconjunto procesado, no como puntos operativos directamente desplegables.

4.3. Tratamiento de la fuga de información

El modelo opera exclusivamente con información disponible en el momento de la inferencia. Todas las entradas se derivan de documentos de licitación producidos y publicados durante la etapa de convocatoria, antes de que se conozca el resultado final de la contratación. Esto hace que la configuración predictiva sea operativamente realista y reduce sustancialmente el riesgo de fuga directa a partir de contenido explícito sobre el estado final.

En consecuencia, la principal amenaza restante para la validez no es una fuga evidente y posterior de la variable objetivo, sino las correlaciones predictivas indirectas y la representatividad limitada. Los documentos de licitación pueden codificar regularidades estructurales, institucionales o estilísticas que predicen el resultado sin ser causales. Estas

regularidades son legítimas para generar señales predictivas tempranas porque están disponibles en el momento de la decisión, pero no deben interpretarse como causas directas del éxito o fracaso de una contratación.

4.4. Protocolo de evaluación

El modelo se evalúa mediante validación cruzada estratificada de 5 pliegues. El subconjunto procesado de 1.162 ejemplos se divide en 5 pliegues que preservan las etiquetas, de modo que cada ronda utiliza aproximadamente cuatro quintas partes de los datos para ajustar el modelo y una quinta parte como partición de evaluación fuera de pliegue. En términos concretos, cada ronda entrena con unas 930 contrataciones y evalúa aproximadamente 232 que no se utilizaron para ajustar el modelo de esa ronda.

La estratificación es importante porque la clase positiva no está balanceada: cerca del 72,6 % del subconjunto procesado corresponde a resultados exitosos. Conservar esta prevalencia entre pliegues reduce variaciones evitables en F1, exactitud balanceada y PR AUC. Los valores finales informados son la media y la desviación estándar de los 5 pliegues reservados. Para el análisis de sensibilidad al umbral, los 4 pliegues de entrenamiento de cada ronda se dividen nuevamente en una porción interna de entrenamiento y otra de validación; el umbral que maximiza F1 en la validación interna se aplica después al pliegue de evaluación externo de esa ronda.

4.5. Métricas

La evaluación utiliza las siguientes métricas:

- **ROC AUC**, para medir la calidad del ordenamiento con independencia del umbral de decisión.
- **PR AUC** (precisión promedio), para evaluar el ordenamiento con atención explícita a la clase positiva.
- **Puntaje F1**, con un umbral de probabilidad de 0,5.
- **Exactitud balanceada**, también con un umbral de 0,5.
- **Puntaje de Brier**, para medir la calidad de la calibración probabilística.
- **Pérdida logarítmica**, como regla de puntuación propia sobre las probabilidades predichas.

La elección de métricas ante el desbalance depende del objetivo operativo: los resúmenes basados en PR enfatizan la recuperación de la clase positiva, mientras que ROC AUC y PR AUC responden de manera distinta a la prevalencia y deben interpretarse en contexto (Richardson et al., 2024). Debido a que PR AUC puede inducir a error cuando la clase positiva es frecuente, se interpreta junto con la prevalencia positiva π en los pliegues reservados. La implementación también registra `positive_prevalence` y `pr_auc_excess_over_prevalence`; esta última se define como PR AUC menos π. La cantidad ofrece una estimación compacta de cuánto mejora el modelo sobre la frecuencia de la clase positiva, utilizada habitualmente como referencia al discutir el comportamiento PR sin capacidad predictiva en contextos desbalanceados.

4.6. Recuperación de documentos PBC

Para cada proceso, `merge_and_download_pbcs.py` consultará la información documental asociada e intentará localizar un PBC o carta de invitación. La ejecución documentada aceptó PDF como artefacto final. El código inspecciona título, URL y formato; también contiene rutas auxiliares para archivos comprimidos o documentos de oficina, pero el conjunto final observado está compuesto por PDF.

Los archivos se almacenan bajo la clave lógica:

```
outcome-predictor/pbcs/pdf/{tenderId}.pdf
```

El proceso es reanudable: antes de descargar, puede comprobar si el objeto existe. El conjunto JSON enriquecido conserva indicadores de descarga, clave remota y, cuando se registró, motivo de omisión o error. Una reconciliación final compara las filas con el listado real de objetos en Spaces para evitar que el JSON declare un PDF inexistente.

Se obtuvieron 1.845 PDF. Esta cifra representa los archivos recuperados por la canalización, no todos los PBC existentes en la DNCP. Para 42 procesos se conservó un motivo de fallo; 8.741 filas no contienen evidencia de intento o causa final y se documentan como no procesadas dentro del tiempo disponible, principalmente por limitación de solicitudes. Esta diferencia exige evitar tasas de disponibilidad calculadas como si toda la población hubiese sido consultada exhaustivamente.

4.7. Extracción y normalización del texto

Los PDF descargados se procesaron con `PDFReader`. La etapa utiliza `pdfplumber` para texto y puede utilizar Camelot en modos *lattice* y *stream* para tablas. Cada resultado se almacenó en:

`outcome-predictor/pbcs/txt/{tenderId}.txt`

De 1.845 PDF se obtuvieron 1.842 textos. Los 3 fallos correspondieron a documentos escaneados para los que el extractor no incorporaba OCR. No se imputó texto vacío ni se reemplazaron esos documentos por contenido de otra fuente; quedaron excluidos.

La extracción puede conservar ruido de paginación o alterar tablas. El experimento tratará el texto obtenido como entrada efectiva del modelo y no como transcripción perfecta del PBC. Una extensión con OCR deberá evaluarse por separado porque cambiaría la población incluida y la calidad de la entrada.

4.8. Generación de embeddings

4.8.1. Codificador congelado

El script `embed_pbcs.py` cargará `openai/gpt-oss-20b` mediante Hugging Face Transformers y congelará todos sus parámetros. La configuración seleccionará `bfloat16` en CUDA, desactivará la caché de claves y valores y utilizará el backbone que devuelve el último estado oculto.

La secuencia completa se tokenizará sin truncamiento. Se dividirá en fragmentos de 4096 tokens con desplazamiento de 2048. Cada fragmento se completará hasta la longitud máxima para formar microlotes. El embedding corresponderá al estado oculto del último token válido, no al relleno.

4.8.2. Control de memoria

El tamaño inicial del microlote será 4. Ante un error de memoria CUDA, el código vaciará la caché, reducirá el tamaño por mitades y reintentará hasta llegar a uno. Si el error persiste, se registrará y el documento quedará sin embedding. Este procedimiento evita que un fallo detenga toda la colección, aunque induce una selección técnica por longitud y demanda de memoria.

Cada archivo `.pt` conserva `tender_id`, matriz de embeddings, identificador del modelo, longitud, desplazamiento, tamaño de microlote y eventual etiqueta. Se produjeron 1.162 archivos. Entre los 680 textos sin embedding se observaron 671 errores de memoria y 9 `ValueError`.

4.9. Embudo de construcción del conjunto supervisado

La Tabla 4.1 presenta el recorrido completo. Los conteos provienen de objetos observados y del JSON consolidado.

Tabla 4.1: Embudo de datos desde procesos DNCP hasta el conjunto supervisado.

Etapa	**Universo**	**Resultado válido**	**Pérdida**
Procesos unificados	10.628	10.628	0
PBC PDF recuperados	10.628	1.845	8.783
Texto extraído	1.845	1.842	3
Embeddings generados	1.842	1.162	680
Ejemplos supervisados	1.162	1.162	0

La Tabla 4.2 desagrega etapas por estado. La priorización elevó la proporción de no exitosos respecto de la instantánea completa.

Tabla 4.2: Conteos por estado en etapas principales.

Estado	**Inicial**	**PDF**	**Texto**	**Embedding**
`complete`	10.000	1.273	1.270	844
`unsuccessful`	257	246	246	204
`cancelled`	371	326	326	114
Total	10.628	1.845	1.842	1.162

La pérdida no es aleatoria. Se priorizaron estados minoritarios y los errores de embedding afectaron principalmente documentos costosos. Por ello, el subconjunto final no debe presentarse como muestra representativa del universo paraguayo. El protocolo medirá desempeño interno sobre los 1.162 casos procesados.

4.10. Definición de la instancia y etiqueta

El estudio busca anticipar el estado con el que cada contratación queda registrada a partir del texto de su PBC. Para ello se utilizan únicamente procesos que cuentan con un documento aprovechable y con uno de los estados finales considerados. Los estados se agrupan en dos resultados:

- Se considera exitoso el proceso registrado como `complete`.
- Se considera no exitoso el proceso registrado como `unsuccessful`, `cancelled` o `canceled`.

Los términos `cancelled` y `canceled` expresan el mismo estado, "cancelado", con las grafías británica y estadounidense del inglés; ambos aparecen en los datos de origen y por eso se normalizan dentro del mismo grupo. Reducir los estados a estas dos alternativas convierte el problema en una clasificación binaria: para cada PBC, el modelo estima la probabilidad de que el proceso pertenezca al primer grupo.

Los registros con otros estados se excluyen del entrenamiento y de la evaluación. Esta agrupación es una decisión operativa basada en la fuente disponible. Un proceso `complete` no implica necesariamente máximo valor público, y una cancelación puede responder a causas legítimas; por tanto, la etiqueta no constituye una evaluación integral de éxito, eficiencia o integridad.

El mapeo se implementa en `src/data/procurement_target.py` y se alinea mediante `tenderId`. Registros sin uno de los estados admitidos se excluirán. La etiqueta no se extraerá del PBC y no se suministrará al codificador.

4.11. Modelos que se evaluarán

4.11.1. Representación documental

Cada documento PBC se convierte primero de PDF a texto mediante la canalización de extracción previa. El texto resultante se tokeniza y divide en fragmentos superpuestos. En la implementación actual, cada fragmento tiene una longitud de 4096 tokens y un desplazamiento de 2048 tokens. Se utiliza el modelo de lenguaje causal preentrenado `openai/gpt-oss-20b` como codificador documental congelado (S. Agarwal et al., 2025). Este modelo se seleccionó como un LLM práctico de pesos abiertos para extraer representaciones densas de textos de contratación en español y, a la vez, mantener reproducible

la canalización experimental. Congelar el codificador también evita ajustar un modelo grande sobre un conjunto de datos modesto y permite que la comparación se concentre en cuánta señal existe en las representaciones preentrenadas y cómo se agrega posteriormente, en consonancia con trabajos recientes sobre embeddings textuales basados en LLM (L. Wang et al., 2024a). Los fragmentos se procesan en microlotes para reducir la presión sobre la memoria de la GPU.

Para cada fragmento, el sistema extrae la representación oculta asociada al último token válido. La salida correspondiente a un documento de contratación es, por tanto, una secuencia de embeddings de fragmentos:

$$\mathbf{E} = [\mathbf{e}_1, \mathbf{e}_2, \ldots, \mathbf{e}_N], \qquad \mathbf{e}_i \in \mathbb{R}^{d_{in}},$$

donde N es la cantidad de fragmentos del documento y d_{in} está determinado por el tamaño oculto del modelo preentrenado. Esta configuración permite comparar dos estrategias de representación basadas en LLM: un vector documental simple obtenido mediante el promedio de los fragmentos y un modelo secuencial que aprende las interacciones entre ellos.

4.11.2. Arquitectura del predictor

El clasificador principal, `TenderSuccessPredictor`, es un transformer liviano aplicado sobre los embeddings de los fragmentos. Sea $\mathbf{E} \in \mathbb{R}^{N \times d_{in}}$ la secuencia de fragmentos de un documento. El modelo aplica:

1. Una proyección lineal de d_{in} a una dimensión latente entrenable d_{model}.
2. La inserción de un token aprendido `[CLS]` al comienzo de la secuencia.
3. Un codificador transformer sobre la secuencia completa de vectores de fragmentos.
4. Una pequeña cabeza de clasificación multicapa sobre la representación final de `[CLS]`.

En los experimentos actuales, los hiperparámetros posteriores son: $d_{model} = 128$, $n_{heads} = 4$, dimensión de la red prealimentada $= 512$, dropout $= 0{,}3$ y una capa de codificación. Se emplean máscaras de relleno para agrupar de forma segura documentos con diferentes cantidades de fragmentos.

El modelo produce un único logit por documento. Una transformación sigmoide convierte este logit en una probabilidad de éxito:

$$\hat{p}(y = 1 \mid \mathbf{E}) = \sigma(z).$$

El entrenamiento utiliza entropía cruzada binaria con logits.

4.11.3. Líneas base

Para interpretar los resultados basados en LLM, se evalúan 3 clases de líneas base.

En primer lugar, se emplean dos referencias triviales: un clasificador de clase mayoritaria y un clasificador aleatorio cuya tasa positiva coincide con la prevalencia empírica. Estas líneas base establecen la región esperada sin capacidad predictiva, donde ROC AUC debería situarse cerca de 0,5 y PR AUC cerca de la prevalencia positiva.

En segundo lugar, se utiliza una línea base léxica con características TF–IDF de hasta 50.000 unigramas y bigramas, frecuencia documental mínima de 5 y un clasificador de regresión logística con pesos de clase balanceados. Se utiliza TF–IDF en lugar de embeddings densos estáticos como Word2Vec porque proporciona una referencia sólida e interpretable de bolsa de palabras que sigue siendo competitiva en documentos extensos (Alva Principe et al., 2025; S. Wang & Manning, 2012). Además, permite aislar la comparación con representaciones congeladas de LLM sin añadir otra etapa entrenable de embeddings bajo supervisión limitada. Las líneas base lineales de bolsa de palabras son referencias habituales en clasificación de textos (S. Wang & Manning, 2012), y la evidencia reciente sobre documentos extensos indica que las representaciones léxicas aún son competitivas en algunos escenarios (Alva Principe et al., 2025).

En tercer lugar, se definen dos líneas base intermedias basadas en LLM que utilizan los mismos embeddings preentrenados de fragmentos que el sistema principal, pero sustituyen el transformer entre fragmentos por una agregación documental más simple. En la primera variante, se promedian los embeddings de los fragmentos y se suministran a una regresión logística. En la segunda, la misma representación promedio alimenta un pequeño perceptrón multicapa con una capa oculta. Estas líneas base aíslan el valor de la representación del valor aportado por el modelado explícito de las interacciones entre fragmentos.

4.12. Entrenamiento y reproducibilidad

El entrenamiento utiliza AdamW, una tasa de aprendizaje de 10^{-4}, decaimiento de pesos de 0,01, lotes de tamaño 8 y hasta 50 épocas. Dentro de cada ronda de validación cruzada, una época corresponde a un recorrido completo por la porción de entrenamiento de esa ronda. Después de cada época se calcula la pérdida de validación sobre la porción reservada; si no mejora durante 5 épocas consecutivas, el entrenamiento se detiene y se restaura el mejor punto de control. La reproducibilidad se controla mediante semillas fijas, comportamiento determinista de cuDNN, cargadores de datos con semilla y reinicios independientes del estado aleatorio al comienzo de cada pliegue.

4.12.1. Líneas base triviales

Se incluirá un clasificador de clase mayoritaria y uno aleatorio cuya tasa positiva coincida con la prevalencia. Servirán como control del pipeline: ROC AUC deberá situarse cerca de 0,5 y PR AUC cerca de la prevalencia, dentro de la variación esperable.

4.12.2. TF–IDF con regresión logística

El vectorizador se ajustará exclusivamente con textos de entrenamiento de cada pliegue. Se usarán 50.000 características como máximo, unigramas y bigramas, y frecuencia documental mínima de 5. La regresión logística utilizará `class_weight=balanced`. Transformar el pliegue externo con un vocabulario aprendido solo en entrenamiento evitará fuga por frecuencia documental.

4.12.3. Promedio con regresión logística

Se calculará el promedio de embeddings por documento y se ajustará una regresión logística. Este modelo aislará el contenido de la representación congelada sin introducir una red secuencial.

4.12.4. Promedio con MLP

El mismo promedio alimentará una red con una capa oculta. En el análisis de sensibilidad se utilizó dimensión oculta 256, ReLU, dropout 0,2, AdamW, lotes de 64 y detención temprana. La comparación con regresión logística permitirá observar si una transformación no lineal del promedio aporta valor.

4.12.5. Transformer entre fragmentos

La matriz variable de embeddings se rellenará dentro de cada lote y se acompañará con una máscara. La arquitectura proyectará de 2880 a 128 dimensiones, añadirá `[CLS]`, utilizará 4 cabezas, dimensión prealimentada 512, dropout 0,3 y una capa. La cabeza final producirá un logit.

4.13. Ambiente de software

El proyecto requiere Python 3.10 o superior y declara sus dependencias en `pyproject.toml`; `uv.lock` conserva resoluciones concretas por plataforma. La Tabla 4.3 presenta los componentes principales observados en el archivo de bloqueo actual. Las versiones efectivamente usadas en la corrida original deben verificarse contra el entorno archivado si se dispone de él, porque el archivo puede actualizarse después de una ejecución.

Tabla 4.3: Componentes principales del ambiente de software versionado.

Componente	**Uso**	**Versión resuelta observada**
Python	ETL y entrenamiento	$\geq$ 3,10
PyTorch	Embeddings y redes	2.11.0
Transformers	Carga del LLM/tokenizador	5.4.0
scikit-learn	TF–IDF, CV y métricas	1.7.2/1.8.0 según plataforma
MLflow	Seguimiento experimental	3.10.1
pdfplumber	Extracción de texto PDF	0.11.9
Camelot	Extracción de tablas	1.0.9
pandas	Manipulación tabular	2.3.3

4.14. Partición y protocolo de evaluación

Se utilizará validación cruzada estratificada de 5 pliegues con semilla 42. Cada pliegue conservará aproximadamente la prevalencia. Los modelos comparados emplearán los mismos índices externos. El vectorizador y los clasificadores se ajustarán nuevamente en cada ronda.

Para las métricas a umbral fijo se utilizará $\tau = 0{,}5$. Para el experimento de sensibilidad, los 4 pliegues externos de entrenamiento se dividirán en entrenamiento interno y validación interna, con una proporción de validación de 0,2. Se seleccionará el umbral que maximice F1 en la partición interna; ante empates se preferirá el más cercano a 0,5 y luego el menor. El umbral se aplicará una sola vez al pliegue externo.

Este anidamiento separará selección y evaluación. No se utilizará el pliegue externo para elegir hiperparámetros, vocabulario o umbral.

4.15. Entrenamiento

El transformer se entrenará con AdamW, tasa 10^{-4}, decaimiento 0,01, lotes de 8 y hasta 50 épocas. Después de cada época se calculará la pérdida de validación. Si no mejora durante 5 épocas consecutivas, se detendrá el entrenamiento y se restaurará el mejor estado.

La pérdida será entropía cruzada binaria con logits. El uso directo de logits evita aplicar sigmoide antes de una función que implementa de forma estable ambas operaciones. Durante evaluación, la sigmoide transformará logits en probabilidades.

4.16. Métricas de evaluación

Se informarán ROC AUC, PR AUC, F1, exactitud balanceada, Brier y pérdida logarítmica. ROC AUC y PR AUC evaluarán ranking; F1 y exactitud balanceada dependerán del umbral; Brier y pérdida logarítmica evaluarán probabilidades. También se registrará la prevalencia positiva y $PR\ AUC - \pi$.

Las curvas de precisión-exhaustividad se construirán agregando predicciones externas. Las curvas de calibración agruparán probabilidades y compararán predicción media con frecuencia observada. Dado el tamaño limitado, los puntos de bins extremos se interpretarán con cautela.

4.17. Trazabilidad y reproducibilidad

La semilla global será 42 y cada pliegue recibirá una semilla derivada independiente. El código configurará cuDNN determinista, generadores de `DataLoader` y reinicios de estados aleatorios. MLflow conservará hiperparámetros y métricas. Los objetos pesados residirán en Spaces y los metadatos de seguimiento, por defecto, en SQLite local.

Los artefactos públicos archivados en Zenodo incluyen el código y los 1.162 archivos `.pt` de embeddings congelados empleados en los experimentos (doi:10.5281/zenodo.20128768). El paquete de embeddings incorpora un manifiesto con el identificador de cada archivo, sus dimensiones y su suma de verificación SHA–256, además de metadatos agregados y documentación de uso. Esto permite reproducir el entrenamiento y la evaluación de los modelos basados en LLM sin volver a ejecutar la costosa etapa de codificación documental.

El depósito excluye credenciales y los datos fuente locales. Por tanto, reproducir los experimentos a partir de los embeddings publicados no requiere acceso a la infraestructura original, pero reconstruir toda la canalización desde los PDF exige obtener legítimamente los documentos desde la DNCP y disponer del modelo base. Esta distinción delimita el grado de reproducibilidad alcanzado.

4.18. Amenazas a la validez previstas

Se considerarán 4 grupos:

1. **Validez de constructo**: el estado final es una aproximación operacional al éxito.
2. **Validez interna**: podrían existir duplicados documentales, regularidades institucionales o señales indirectas; el protocolo evita datos posteriores, pero no convierte correlaciones en causalidad.
3. **Validez externa**: el subconjunto está filtrado por disponibilidad y cómputo, y se limita a construcción vial paraguaya.
4. **Validez de conclusión**: 5 pliegues sobre 1.162 ejemplos producen incertidumbre; diferencias pequeñas no deben presentarse como dominancia universal sin pruebas adicionales.

Estas amenazas guiarán la interpretación del capítulo de resultados y evitarán extrapolar los umbrales del subconjunto a la distribución completa.

Capítulo 5

Pruebas experimentales y análisis de resultados computacionales

Este capítulo presenta primero el hardware y los hiperparámetros utilizados en la ejecución. A continuación expone los resultados obtenidos mediante las particiones y modelos definidos anteriormente. El análisis se organiza en 4 bloques: controles sin capacidad predictiva, comparación de ranking, comportamiento dependiente del umbral y calidad probabilística. Luego se estudia el efecto de la representación y se discuten los resultados en relación con el contexto paraguayo y los antecedentes.

5.1. Ambiente de ejecución

La generación de embeddings se ejecutó en una instancia de cómputo acelerado en la nube, provista por RunPod y equipada con una GPU NVIDIA H200 compatible con CUDA. El proveedor se consigna como información de trazabilidad, pero no constituye un requisito de reproducción: puede utilizarse una infraestructura equivalente si ofrece los recursos y el entorno de software necesarios. El código seleccionó una GPU cuando estuvo disponible, utilizó `bfloat16` en ese caso y conservó los tokens en CPU hasta transferir cada microlote.

La evidencia de ejecución registra 671 fallos `OutOfMemoryError`. La variante y la memoria exacta de la GPU, así como el modelo de procesador y la memoria RAM de la instancia, no se encuentran preservados en los artefactos disponibles; por ello, no se atribuyen especificaciones adicionales no verificables. Esta información faltante limita la reproducción exacta de la etapa de codificación, pues la memoria disponible determina el tamaño de microlote y la posibilidad de procesar los documentos más extensos.

Tabla 5.1: Información de hardware respaldada por los artefactos del proyecto.

Componente	**Evidencia disponible**
Acelerador	GPU NVIDIA H200 compatible con CUDA
Entorno de ejecución	Instancia de cómputo acelerado en la nube provista por RunPod
Precisión del LLM	`bfloat16` cuando CUDA está disponible
Gestión de memoria	Microlotes CPU–GPU, caché KV desactivada y reintentos reduciendo el microlote
Configuración restante	Variante y memoria exacta de la GPU, procesador y memoria RAM no preservados
Almacenamiento de artefactos	DigitalOcean Spaces mediante API compatible con S3

Para futuras reproducciones deberán registrarse el modelo y la memoria de la GPU, la versión del controlador, la versión de CUDA, el procesador, la memoria RAM y el sistema operativo. Los resultados que siguen corresponden al subconjunto que pudo completar la canalización bajo el ambiente descrito.

5.2. Hiperparámetros utilizados

La Tabla 5.2 resume la configuración utilizada para transformar los PBC en entradas de los clasificadores. El codificador permaneció congelado durante toda la generación de embeddings; por tanto, sus parámetros no se actualizaron con las etiquetas del conjunto supervisado.

Tabla 5.2: Hiperparámetros de representación y codificación documental.

Componente	**Configuración utilizada**
Codificador denso	`openai/gpt-oss-20b`, parámetros congelados y precisión `bfloat16` en CUDA
Fragmentación	4.096 tokens por fragmento, desplazamiento de 2.048 tokens y sin truncamiento documental adicional
Embedding de fragmento	Estado oculto del último token válido; dimensión de salida 2.880
Microlote de codificación	Tamaño inicial 4, reducido por mitades ante errores de memoria hasta un mínimo de 1
Representación léxica	TF–IDF, hasta 50.000 características, unigramas y bigramas, y frecuencia documental mínima de 5

Los clasificadores se ejecutaron con los hiperparámetros de la Tabla 5.3. Las dos regresiones logísticas utilizaron pesos de clase balanceados y un máximo de 1.000 iteraciones. El MLP y el transformer se entrenaron con entropía cruzada binaria con logits y detención temprana.

TABLA 5.3: Hiperparámetros de los modelos evaluados.

Modelo	**Configuración utilizada**
TF–IDF + regresión logística	Pesos de clase balanceados; máximo de 1.000 iteraciones
Promedio + regresión logística	Promedio de embeddings de dimensión 2.880; pesos de clase balanceados; máximo de 1.000 iteraciones
Promedio + MLP	Capa oculta de 256 unidades, ReLU, dropout 0,2, lote 64, AdamW, tasa de aprendizaje 10^{-3}, decaimiento 10^{-4} y hasta 50 épocas
Transformer entre fragmentos	Proyección 2,880 $\rightarrow$ 128, 4 cabezas, dimensión prealimentada 512, dropout 0,3, 1 capa, lote 8, AdamW, tasa de aprendizaje 10^{-4}, decaimiento 0,01 y hasta 50 épocas

En los modelos neuronales, la detención temprana empleó una mejora mínima de 0,001 en la pérdida de validación, paciencia de 5 épocas y restauración del mejor punto de control. El protocolo común consistió en validación cruzada estratificada de 5 pliegues, semilla 42 y umbral principal de 0,5. Para el análisis de sensibilidad, el conjunto de entrenamiento de cada pliegue externo reservó un 20 % para seleccionar internamente el umbral que maximizaba F1.

5.3. Comprobaciones previas

Antes de comparar modelos se verificó que todos operaran sobre los mismos 1.162 identificadores y la misma regla de etiqueta. La prevalencia positiva fue aproximadamente 0,726. Por ello, una PR AUC cercana a 0,726 no expresa una mejora sustantiva sobre puntuaciones aleatorias; debe compararse con esa referencia. La ROC AUC de los controles se mantuvo cerca de 0,5, lo que es consistente con un ordenamiento sin habilidad.

Los resultados triviales también sirven para detectar errores. Una ROC AUC muy distinta de 0,5 en el clasificador mayoritario o una PR AUC incompatible con la prevalencia habría requerido revisar etiquetas, particiones o cálculo de métricas. No se observó ese patrón.

5.4. Desempeño de ordenamiento

La Tabla 5.4 resume la comparación de modelos. Las líneas base triviales se comportan como se esperaba: ROC AUC permanece en el nivel del azar y PR AUC se mantiene cerca de la prevalencia positiva de aproximadamente 0,726. Esto proporciona una referencia útil sin capacidad predictiva y respalda la consistencia interna de la evaluación.

Entre los modelos no triviales, TF–IDF más regresión logística obtiene las mejores métricas de ordenamiento, con ROC AUC medio de 0,814 y PR AUC medio de 0,899. El transformer entre fragmentos aplicado a embeddings de LLM alcanza ROC AUC de 0,755 y PR AUC de 0,886. Las líneas base con embeddings promediados se mantienen próximas: el MLP con promedio alcanza ROC AUC de 0,763 y PR AUC de 0,894, mientras que la regresión logística con promedio alcanza ROC AUC de 0,758 y PR AUC de 0,881. La Fig. 5.1 coincide con este panorama: TF–IDF define en general la mejor frontera entre precisión y exhaustividad, mientras que ambas alternativas basadas en LLM permanecen claramente por encima de la prevalencia. Los documentos contienen señal predictiva, pero el mejor ordenamiento en la configuración actual proviene de representaciones léxicas y no densas.

5.5. Sensibilidad al umbral

El comportamiento dependiente del umbral revela un patrón diferente. Con el umbral predeterminado de 0,5, el transformer entre fragmentos alcanza el mayor F1 (0,858 en la evaluación original de 5 pliegues). Sin embargo, el experimento específico muestra que no todos los modelos reaccionan de igual manera a la optimización del umbral. Para TF–IDF más regresión logística, seleccionar en validación el umbral que maximiza F1 incrementa el F1 del pliegue de prueba en 0,103 en promedio, pero no mejora la exactitud balanceada media. La regresión logística con promedio presenta una mejora modesta de F1 (+0,014) y una disminución media de exactitud balanceada (−0,049). En contraste, el transformer cambia poco con el ajuste (media de ΔF1 = +0,002 y media de Δ de exactitud balanceada = +0,002), lo que indica que el umbral predeterminado ya está cerca de un punto operativo estable. El MLP con promedio ocupa una posición intermedia: su F1 apenas cambia, pero su exactitud balanceada mejora en promedio al ajustar el umbral. La Fig. 5.3 resume visualmente el contraste y deja claro que la optimización beneficia principalmente el F1 del modelo léxico, no a todos los modelos de manera uniforme.

5.6. Calibración

La calibración presenta una historia diferente al ordenamiento. El transformer entre fragmentos consigue el mejor puntaje de Brier (0,162), seguido por el MLP con promedio (0,165); TF–IDF más regresión logística obtiene un resultado inferior (0,179) y la regresión logística con promedio es considerablemente peor (0,201). Este patrón indica que las características léxicas pueden ser muy eficaces para ordenar ejemplos, mientras que las representaciones densas basadas en LLM proporcionan probabilidades más confiables. La Fig. 5.2 concuerda con esta interpretación: entre las 3 familias más informativas, el transformer permanece más próximo a la diagonal en gran parte del intervalo de probabilidades, mientras que TF–IDF es mejor en ordenamiento que en calibración. Esto importa porque la selección de modelos para monitorear contrataciones puede depender no solo del ordenamiento, sino también de si las probabilidades permiten sustentar la priorización posterior o una puntuación de riesgo (Silva Filho et al., 2023).

5.7. Comparación de representaciones

La comparación entre embeddings promediados y el transformer entre fragmentos es informativa por sí misma. Si el valor principal de la representación del LLM proviniera únicamente de las interacciones entre fragmentos, cabría esperar que el transformer dominara las líneas base con promedio. Esto no sucede. El MLP con promedio supera ligeramente al transformer en ROC AUC y PR AUC, mientras que la regresión logística con promedio logra una exactitud balanceada considerablemente mayor. Los resultados sugieren que gran parte de la información predictiva ya está codificada en los propios embeddings congelados y que el modelado explícito entre fragmentos ofrece ganancias limitadas en la configuración actual. La principal ventaja del transformer parece ser la calibración y la estabilidad del umbral, no un ordenamiento claramente superior.

5.8. Lectura comparativa por criterio

5.8.1. Ranking

TF–IDF más regresión logística alcanzó ROC AUC 0,814 y PR AUC 0,899, los mayores valores medios informados. La diferencia con los modelos densos indica que, en el subconjunto procesado, el vocabulario y los bigramas contienen una señal especialmente útil para ordenar procesos exitosos y no exitosos.

TABLA 5.4: Comparación de modelos mediante validación cruzada de 5 pliegues (media ± desviación estándar). Un valor menor es mejor para Brier; un valor mayor es mejor para las demás métricas.

Métrica	Valor
Mayoría: ROC AUC / PR AUC	0.500 / 0.726
Aleatorio: ROC AUC / PR AUC	0.493 / 0.724
TF–IDF + Reg. Log.: ROC AUC / PR AUC	0.814 / 0.899
TF–IDF + Reg. Log.: F1 / Exact. Bal. / Brier	0.790 / 0.728 / 0.179
Promedio + Reg. Log.: ROC AUC / PR AUC	0.758 / 0.881
Promedio + Reg. Log.: F1 / Exact. Bal. / Brier	0.843 / 0.704 / 0.201
Promedio + MLP: ROC AUC / PR AUC	0.763 / 0.894
Promedio + MLP: F1 / Exact. Bal. / Brier	0.849 / 0.604 / 0.165
Transformer entre fragmentos: ROC AUC / PR AUC	0.755 / 0.886
Transformer entre fragmentos: F1 / Exact. Bal. / Brier	0.858 / 0.636 / 0.162

TABLA 5.5: Ajuste del umbral en una partición interna de validación y evaluación en el pliegue externo de prueba. Se informan las medias de todos los pliegues.

Métrica	Valor
TF–IDF + Reg. Log.: ΔF1 / Δ Exact. Bal.	$+0{,}103/-0{,}008$
Promedio + Reg. Log.: ΔF1 / Δ Exact. Bal.	$+0{,}014/-0{,}049$
Promedio + MLP: ΔF1 / Δ Exact. Bal.	$+0{,}002/+0{,}053$
Transformer entre fragmentos: ΔF1 / Δ Exact. Bal.	$+0{,}002/+0{,}002$

Este resultado es compatible con la naturaleza de los PBC. Al pertenecer todos a construcción vial, las variaciones léxicas pueden reflejar plantillas, requisitos o estilos institucionales dentro de un dominio relativamente homogéneo. La explicación es una hipótesis interpretativa, no una atribución causal: el experimento no identifica qué cláusulas producen un desenlace.

El transformer entre fragmentos no superó al promedio con MLP en ranking. Por tanto, los resultados no apoyan la afirmación de que modelar explícitamente relaciones entre fragmentos sea necesario para extraer la mayor parte de la señal densa en esta configuración.

5.8.2. Desempeño con umbral 0,5

El mayor F1 a umbral fijo correspondió al transformer entre fragmentos, con 0,858. Sin embargo, su exactitud balanceada fue 0,636, inferior a la regresión logística con promedio y a TF–IDF. La diferencia revela el efecto de una clase positiva frecuente: un modelo

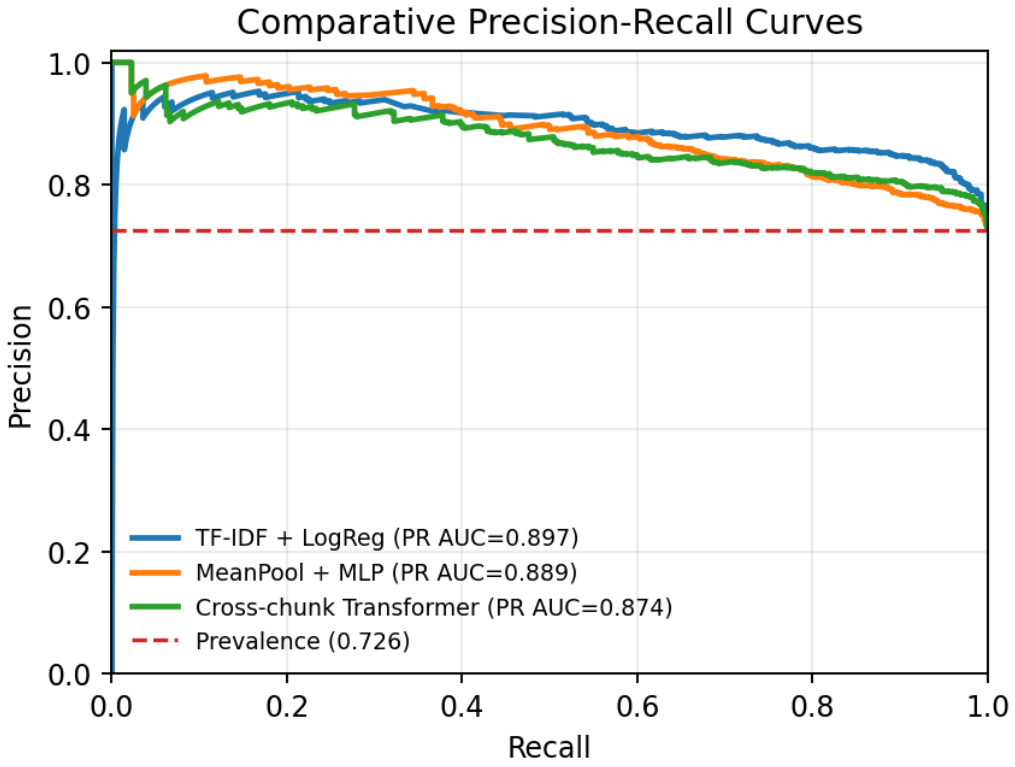


FIGURA 5.1: Curvas comparativas de precisión-exhaustividad a partir de predicciones agregadas fuera de pliegue para la línea base léxica más sólida (TF–IDF + regresión logística), la mejor línea base densa con promedio (Promedio + MLP) y el transformer entre fragmentos. La línea horizontal discontinua marca la prevalencia positiva ($\pi \approx 0{,}726$). TF–IDF muestra en general el mejor compromiso entre precisión y exhaustividad, mientras que ambos modelos basados en LLM permanecen sustancialmente por encima de la referencia sin capacidad predictiva.

puede obtener F1 alto favoreciendo predicciones positivas y, al mismo tiempo, distinguir peor la clase negativa.

La exactitud balanceada de 0,728 de TF–IDF fue la mayor de la tabla principal. Como promedia la sensibilidad de ambas clases, ofrece una lectura complementaria al F1. Ninguna de las dos métricas debe interpretarse sin especificar la clase positiva y el umbral.

5.8.3. Calibración

El transformer obtuvo el menor Brier, 0,162, seguido por el MLP con promedio, 0,165. TF–IDF, pese a su mejor ranking, obtuvo 0,179. Esta divergencia es esperable: una transformación monótona puede conservar el orden de los ejemplos y cambiar la correspondencia entre puntajes y probabilidades.

La curva de calibración permite observar el comportamiento por intervalos, pero sus puntos no poseen igual cantidad de datos ni intervalos de confianza en la figura actual. La

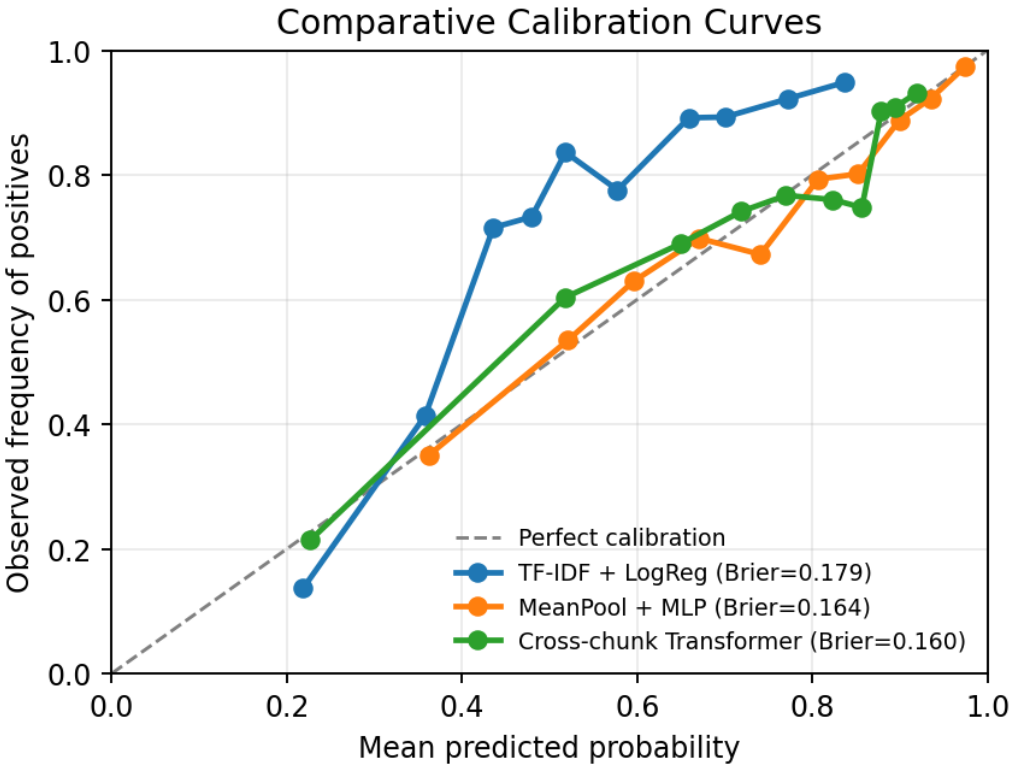


FIGURA 5.2: Curvas comparativas de calibración a partir de predicciones agregadas fuera de pliegue para TF–IDF + regresión logística, Promedio + MLP y el transformer entre fragmentos. La diagonal representa la calibración perfecta. El ordenamiento y la calibración no coinciden: el transformer se mantiene más próximo a una señal probabilística útil y calibrada, mientras que TF–IDF es más sólido como modelo de ordenamiento que como estimador de probabilidades.

conclusión se restringe a que el transformer produjo la mejor combinación observada bajo Brier y la curva agregada; no se afirma calibración perfecta ni transferencia automática a otra prevalencia.

5.9. Análisis de sensibilidad al umbral

La selección interna del umbral modificó principalmente el F1 de TF–IDF: el incremento medio fue 0,103. Su exactitud balanceada no aumentó en promedio. Esto muestra que maximizar una métrica en validación no garantiza mejorar otra; el objetivo de selección determina el punto operativo.

Para el transformer, las variaciones medias de F1 y exactitud balanceada fueron 0,002. El resultado sugiere estabilidad alrededor de 0,5 en estas particiones. No demuestra que 0,5 vaya a mantenerse como umbral adecuado si cambia la prevalencia de positivos, el costo relativo de falsos positivos y negativos o la institución de origen.

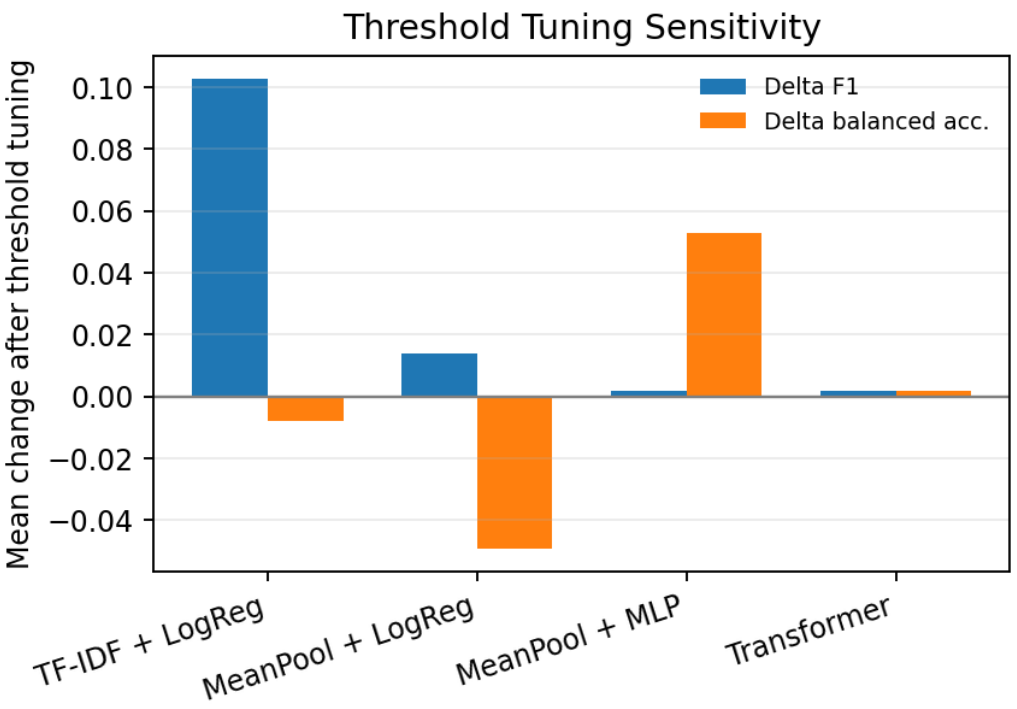


FIGURA 5.3: Cambio medio en F1 y exactitud balanceada del pliegue de prueba después de sustituir el umbral predeterminado de 0,5 por el umbral que maximiza F1 en una partición interna de validación. El ajuste mejora considerablemente el F1 de TF–IDF + regresión logística, presenta efectos mixtos en los modelos con promedio y apenas modifica el transformer entre fragmentos, lo que indica una mayor estabilidad del punto operativo.

La regresión logística con promedio mejoró ligeramente F1 y redujo exactitud balanceada. El MLP con promedio mantuvo F1 y mejoró exactitud balanceada. Estos patrones justifican presentar deltas por modelo en lugar de una recomendación general de "ajustar siempre" el umbral.

5.10. Comparación entre hipótesis experimentales

5.10.1. Señal textual frente a controles

Todos los modelos no triviales superaron a los controles en ROC AUC y PR AUC. Esta evidencia responde afirmativamente, dentro del subconjunto, a la primera pregunta: los PBC contienen señal predictiva sobre la etiqueta operacionalizada.

La evidencia no permite conocer cuánto proviene de contenido técnico, fórmulas administrativas, organismo convocante o año. Un análisis de ablación por secciones y una validación agrupada por institución serían necesarios para separar estas fuentes.

5.10.2. Representación léxica frente a densa

La representación léxica fue superior en ranking, mientras que las densas fueron competitivas y dos de ellas obtuvieron menor Brier. No existe un ganador único para todos los criterios. La selección dependerá del uso: priorización ordenada, clasificación binaria o puntuación probabilística.

Este hallazgo coincide con trabajos de documentos extensos que recomiendan mantener líneas base TF–IDF y evaluar costo además de desempeño (Mamakas et al., 2022; Tuteja & González Juclà, 2023). El resultado local es particularmente relevante porque el LLM utilizado tiene una escala muy superior a la regresión logística, pero esa escala no produjo el mayor AUC.

5.10.3. Interacciones entre fragmentos

El transformer mejoró calibración respecto de los otros agregadores, pero no ranking. La hipótesis de que las interacciones entre fragmentos aportarían una ventaja general no queda respaldada. Una explicación posible es que el embedding de cada fragmento ya condense suficiente información y el conjunto sea pequeño para aprender interacciones adicionales. Otra posibilidad es que el último token válido no sea el pooling óptimo. Ambas explicaciones requieren experimentos y se formulan como líneas futuras, no como hechos demostrados.

5.11. Costo y complejidad experimental

La comparación de desempeño debe considerar el costo de obtener cada entrada. TF–IDF utiliza el texto extraído y se ajusta con operaciones dispersas. Los modelos densos requieren ejecutar una vez un LLM de 20 mil millones de parámetros sobre fragmentos de hasta 4096 tokens. Esa etapa produjo la principal pérdida técnica del embudo: 680 documentos sin embedding, 671 de ellos por memoria.

Después de generar embeddings, el entrenamiento de agregadores es comparativamente liviano y puede reutilizar los archivos `.pt`. Sin embargo, una evaluación de extremo a extremo debe contabilizar la codificación inicial y la selección que induce. El mejor Brier del transformer se obtuvo sobre documentos que sí pudieron codificarse; no hay evidencia de su desempeño en los 680 excluidos.

5.12. Discusión de resultados

El hallazgo principal no es que una representación domine universalmente a las demás, sino que diferentes representaciones parecen capturar distintos aspectos de la tarea. TF–IDF más regresión logística ofrece el mejor ordenamiento, lo que sugiere que la señal léxica es muy informativa en este dominio. Esto es plausible porque los documentos de licitación suelen contener fórmulas administrativas repetidas, requisitos estandarizados, terminología específica y expresiones procedimentales que pueden correlacionarse fuertemente con los resultados posteriores. En este contexto, características léxicas dispersas pueden recuperar gran parte de la señal predictiva mediante un modelo lineal relativamente simple.

Esto no debe interpretarse como evidencia contraria a las representaciones basadas en LLM. Todos los modelos no triviales de esta familia permanecen claramente por encima de las líneas base y los embeddings promediados se mantienen próximos al transformer. Ello indica que los embeddings congelados de los fragmentos ya codifican información densa útil. En otras palabras, buena parte del valor del LLM puede residir en la propia representación, más que en la complejidad del mecanismo posterior de agregación.

La comparación entre el promedio y el transformer resulta especialmente informativa. Si las interacciones detalladas entre fragmentos fueran la principal fuente de capacidad predictiva, el transformer debería dominar claramente las líneas base agregadas. Eso no ocurre en los experimentos actuales. El MLP con promedio se aproxima al transformer en ordenamiento y la regresión logística con promedio incluso lo supera en exactitud balanceada. Esto sugiere que el modelado explícito de interacciones aún no proporciona una ventaja clara de ordenamiento bajo el régimen de datos y la señal de supervisión actuales.

No obstante, el transformer conserva una ventaja importante: la calibración y la estabilidad del umbral. Obtiene el mejor puntaje de Brier y muestra muy poca sensibilidad al ajuste del umbral, mientras que TF–IDF más regresión logística se beneficia considerablemente de dicho ajuste en F1. Desde una perspectiva aplicada, esto importa porque el modelo preferido para ordenar no necesariamente es el mismo que se prefiere para priorizar mediante probabilidades o para lograr un comportamiento estable en producción. La naturaleza relativamente estandarizada de los documentos de construcción vial también puede contribuir al buen desempeño de las líneas base léxicas.

Parte de la señal predictiva puede reflejar la complejidad documental, las prácticas institucionales de redacción, la estandarización de procedimientos u otras regularidades textuales latentes. Estas señales son legítimas para la predicción temprana porque están

disponibles cuando se emite el documento, antes de conocerse el resultado. Sin embargo, no deben interpretarse como causas de los resultados de una contratación.

En conjunto, la comparación resulta informativa incluso sin un único ganador dominante. Para aplicaciones de gobierno y democracia electrónicos, este es precisamente el punto: los sistemas de monitoreo de contrataciones requieren más que un puntaje alto de ordenamiento. También necesitan probabilidades calibradas, líneas base transparentes y umbrales cuyo comportamiento pueda explicarse antes de utilizarlos para priorizar la atención humana. Los resultados muestran que los modelos léxicos son muy competitivos, que los embeddings congelados de LLM ya capturan gran parte de la señal densa útil y que la principal ventaja comparativa del transformer reside en su calibración y estabilidad ante el umbral, no en su desempeño bruto de ordenamiento.

5.12.1. Implicaciones para Paraguay

El resultado más inmediato es metodológico: en PBC paraguayos de construcción vial, una línea base léxica bien configurada debe preceder a modelos más costosos. Esto no implica descartar LLM. Indica que cualquier propuesta basada en ellos debe demostrar una ventaja vinculada al objetivo operativo, como calibración, transferencia o análisis semántico, y no apoyarse únicamente en su complejidad.

Un sistema de apoyo a la DNCP o a un organismo de control podría usar ranking para ordenar expedientes y revisión humana para interpretar causas. Antes de ello sería necesario validar sobre períodos posteriores, incluir organismos no vistos, recuperar PBC faltantes y definir el evento que realmente se desea anticipar. La etiqueta `complete` frente a estados no exitosos es útil para investigación, pero una política pública puede requerir objetivos más específicos.

La Ley N.º 7021/2022 enfatiza eficiencia, competencia, transparencia e integridad (Dirección Nacional de Contrataciones Públicas, 2026b). Una predicción de estado no mide por sí sola esos principios. Cualquier integración institucional debería mantener separadas la señal estadística, la evaluación normativa y la decisión administrativa.

5.12.2. Comparación con otros países

Acikalin et al. (2024) encontraron señal predictiva en descripciones de convocatorias; este estudio encuentra señal en PBC paraguayos completos. La coincidencia apoya la idea general de que el lenguaje disponible durante la convocatoria permite anticipar desenlaces, pero no permite equiparar variables objetivo ni magnitudes.

VigIA utiliza metadatos e índices orientados a sobrecostos, demoras e irregularidades en Colombia (Salazar et al., 2024). El presente trabajo usa texto y un estado final más amplio. Los enfoques podrían complementarse en el futuro, pero su unión requeriría un conjunto paraguayo donde ambos tipos de variables estén disponibles en el mismo momento.

Los modelos mexicanos centrados en corrupción usan información relacional de compradores y proveedores (Aldana et al., 2022). Como el presente experimento no incorpora redes, no puede evaluar esa dimensión. La comparación confirma que "analítica de contratación" comprende tareas heterogéneas y que las métricas solo son comparables cuando coinciden etiqueta, momento y población.

5.13. Síntesis de hallazgos

Los hallazgos pueden resumirse de la siguiente forma:

1. Los modelos no triviales ordenaron mejor que referencias sin habilidad, lo que evidencia señal textual en el subconjunto.
2. TF–IDF más regresión logística logró el mejor ranking y la mayor exactitud balanceada de la tabla principal.
3. El transformer entre fragmentos logró el mejor Brier y el mayor F1 a umbral 0,5.
4. El promedio de embeddings permaneció cerca del transformer, por lo que no se observó una ventaja general del modelado entre fragmentos.
5. La optimización de umbral benefició métricas y modelos de manera desigual.
6. La pérdida de documentos durante recuperación y embedding limita la extrapolación al universo de la DNCP.

Estas conclusiones se restringen a la evidencia observada y servirán de base para el capítulo final.

Capítulo 6

Conclusiones y trabajos futuros

Este trabajo abordó la predicción de resultados de licitaciones públicas de construcción vial en Paraguay a partir del texto de PBC disponible durante la convocatoria. Para ello construyó un conjunto supervisado mediante datos abiertos de la DNCP, comparó representaciones léxicas y densas, y evaluó por separado ranking, clasificación a umbral fijo, calibración y sensibilidad al umbral.

6.1. Conclusiones finales

La primera conclusión es que los documentos procesados contienen señal predictiva sobre la etiqueta operacionalizada. Los modelos TF–IDF, promedio de embeddings y transformer entre fragmentos superaron a las referencias triviales en métricas de ranking. Esta evidencia se limita al subconjunto de 1.162 procesos que completó descarga, extracción y generación de embeddings.

La segunda conclusión es que la representación más compleja no dominó todos los criterios. TF–IDF más regresión logística produjo el mejor ROC AUC y PR AUC, además de la mayor exactitud balanceada de la comparación principal. El resultado confirma la importancia de incluir líneas base léxicas en documentos estandarizados y extensos.

La tercera conclusión es que los modelos densos aportaron una ventaja diferente. El transformer entre fragmentos obtuvo el menor puntaje de Brier y el mayor F1 con umbral 0,5. El MLP con embeddings promediados se mantuvo próximo en ranking y calibración. Por tanto, buena parte de la información útil ya estaba presente en las representaciones congeladas, mientras que las interacciones entre fragmentos no produjeron una mejora general de ranking.

La cuarta conclusión es que el umbral forma parte del modelo operativo. La selección interna mejoró considerablemente el F1 de TF–IDF, pero no su exactitud balanceada. El transformer cambió poco. Estos resultados muestran que un umbral optimizado para una métrica no debe trasladarse a otra finalidad ni a una población con prevalencia diferente.

La quinta conclusión se refiere a la cobertura. El universo inicial fue de 10.628 procesos, pero solo 1.845 PBC se recuperaron y 1.162 documentos generaron embeddings. La priorización de estados no exitosos y los fallos de memoria alteraron la composición. Por esta razón, las métricas caracterizan el subconjunto procesado, no toda la contratación pública paraguaya.

Varias limitaciones deben matizar la interpretación de los resultados. En primer lugar, el conjunto supervisado es un subconjunto procesado y no una muestra representativa de toda la población de contrataciones. La inclusión exigía disponibilidad documental, extracción exitosa del texto, generación exitosa de embeddings y uno de los dos estados finales definidos. Como el filtrado se debió principalmente a restricciones de tiempo y presupuesto de procesamiento, las conclusiones deben entenderse como aplicables al subconjunto procesado.

En segundo lugar, el subconjunto procesado presenta menos desbalance que la población real. Los datos experimentales contienen alrededor de 73 % de ejemplos positivos, mientras que la población general está mucho más inclinada hacia resultados exitosos, con aproximadamente 94 % de positivos. Esta diferencia importa porque las métricas dependientes del umbral y las interpretaciones sensibles a la prevalencia no son invariantes al balance de clases. Los puntos operativos informados no deben considerarse directamente desplegables sin recalibrarlos en el entorno objetivo.

En tercer lugar, la falta de transferibilidad del umbral es una preocupación práctica. Los umbrales optimizados en validación mejoran algunas métricas de la muestra actual, especialmente para TF–IDF más regresión logística, pero pueden cambiar bajo otras prevalencias, contextos institucionales o supuestos sobre el costo de los errores. Por tanto, el ajuste debe interpretarse como una herramienta de análisis para este conjunto y no como una prescripción universal.

En cuarto lugar, la principal preocupación residual no es una fuga directa de información sobre el resultado final. Como los documentos se producen durante la convocatoria, tal fuga parece poco probable. Los riesgos más relevantes son las correlaciones predictivas indirectas, el aprendizaje de atajos, la representatividad limitada y el desajuste de distribución. Por ejemplo, los modelos podrían aprovechar regularidades institucionales o estilísticas predictivas en este conjunto, pero menos estables entre organismos,

períodos o categorías de contratación. Los hallazgos también pueden ser específicos de la construcción vial y no transferirse sin cambios a otras categorías.

Este trabajo presentó un estudio comparativo de representaciones léxicas y basadas en LLM para predecir resultados de contrataciones públicas a partir de documentos de licitación. Los resultados muestran que estos documentos contienen una señal predictiva considerable, pero también que el modelo con mejor ordenamiento en la configuración actual es una línea base léxica clásica: TF–IDF más regresión logística. Al mismo tiempo, el transformer entre fragmentos sobre embeddings de LLM alcanza la mejor calibración y la mayor estabilidad ante cambios del umbral.

La comparación también indica que gran parte de la señal densa útil ya está presente en los embeddings congelados, dado que las líneas base con promedio se mantienen próximas al transformer. Esto sugiere que el modelado explícito de interacciones entre fragmentos no ofrece actualmente una ventaja clara de ordenamiento, aunque todavía puede aportar valor práctico mediante probabilidades más confiables y un comportamiento de decisión más estable. Los trabajos futuros deberían evaluar otros dominios de contratación y otros codificadores congelados.

La principal contribución del estudio es esta comparación empírica e interpretativa. Demuestra que las características léxicas capturan gran parte de la señal predictiva del dominio, que las representaciones densas preentrenadas continúan siendo útiles y que la calidad del ordenamiento, la calibración y la sensibilidad al umbral deben analizarse por separado. Estos hallazgos conectan la evaluación de aprendizaje automático con las necesidades de la gobernanza pública digital: antes de que las herramientas predictivas puedan respaldar la transparencia, la rendición de cuentas o la supervisión ciudadana de las contrataciones, sus señales, limitaciones y comportamiento operativo deben hacerse explícitos.

6.2. Respuesta a las preguntas de investigación

1. **Señal textual**: sí, dentro del subconjunto procesado, porque todos los modelos no triviales superaron a los controles en ranking.

2. **Léxico frente a denso**: TF–IDF fue superior en ranking; las representaciones densas fueron competitivas y ofrecieron mejores valores de Brier en dos configuraciones.

3. **Interacciones entre fragmentos**: no se observó una ventaja general. El transformer destacó en calibración y estabilidad, no en AUC.

4. **Separación de criterios**: las conclusiones cambiaron según ranking, umbral y calibración, por lo que informar una sola métrica habría ocultado diferencias relevantes.

5. **Transferencia**: la cobertura incompleta, la prevalencia inducida y la especialización en construcción vial impiden tratar los resultados como directamente desplegables.

6.3. Aportes del trabajo

El trabajo deja una canalización auditable que conserva identificadores entre la API de la DNCP, los PBC, el texto y los embeddings. Documenta además los fallos del embudo, condición necesaria para interpretar la selección de datos. En el plano experimental, ofrece una comparación controlada entre 4 familias no triviales y controles sin habilidad. En el plano aplicado, vincula la evaluación con necesidades de transparencia y supervisión sin confundir predicción con causalidad o decisión jurídica.

6.4. Trabajos futuros

6.4.1. Ampliación y representatividad del conjunto

Una primera línea consistirá en completar la recuperación de PBC para reducir el sesgo por tiempo y límites de solicitudes. El proceso deberá respetar las políticas del servicio, utilizar reanudación y registrar motivos de fallo para cada tender. También será necesario incorporar OCR y medir su calidad sobre documentos escaneados.

Los 680 textos sin embedding podrán reprocesarse con más memoria, fragmentos menores, cuantización o un codificador más eficiente. La comparación deberá informar resultados tanto sobre la intersección común como sobre la población ampliada, para no confundir una mejora de modelo con un cambio de casos incluidos.

6.4.2. Validación temporal e institucional

La validación cruzada aleatoria estratificada estima desempeño dentro de la distribución procesada. Una evaluación temporal entrenará con años anteriores y probará en posteriores, reproduciendo mejor un despliegue. Otra evaluación agrupará por organismo convocante para determinar si el modelo generaliza a instituciones no vistas y cuánto depende de plantillas específicas.

Estas particiones podrán reducir el desempeño; precisamente por ello aportarán evidencia sobre robustez. También deberán impedir que versiones casi idénticas de una plantilla aparezcan simultáneamente en entrenamiento y prueba.

6.4.3. Otras categorías de contratación

El código `72131701` delimita construcción vial. Trabajos futuros incorporarán otras obras, bienes y servicios. La ampliación permitirá evaluar si la fortaleza de TF–IDF se debe a estandarización sectorial y si los embeddings densos transfieren mejor entre dominios.

No se mezclará inicialmente toda la contratación en una sola partición. Se informarán resultados por categoría y se analizarán diferencias de prevalencia, longitud y calidad documental.

6.4.4. Análisis explicativo del texto

La regresión logística permite inspeccionar coeficientes, pero los términos más ponderados pueden actuar como sustitutos de institución, fecha o plantilla. Se requerirán análisis de estabilidad por pliegue, eliminación de encabezados, agrupación por organismo y revisión cualitativa de n-gramas antes de atribuir significado sustantivo.

Para modelos densos podrán utilizarse ablaciones por secciones, atención agregada o métodos de perturbación. Tales explicaciones deberán validarse y presentarse como evidencia del comportamiento del modelo, no como causas del resultado administrativo.

6.4.5. Nuevas representaciones y agregadores

Se evaluarán codificadores multilingües especializados en embeddings, modelos de atención dispersa, pooling atento y modelos de espacio de estados. La literatura muestra que estas alternativas responden de forma distinta a longitud y fragmentación (Beltagy et al., 2020; Dai et al., 2022; Lu et al., 2023).

También podrá compararse el último token válido con promedio interno, token especial o pooling aprendido. Para aislar efectos, cada experimento mantendrá constantes las particiones y la cabeza cuando cambie el codificador, y mantendrá fijo el codificador cuando cambie el agregador.

6.4.6. Calibración y decisión

Una aplicación probabilística requerirá calibración sobre datos independientes. Podrán evaluarse escalamiento de temperatura, calibración sigmoide e isotónica, respetando una partición exclusiva para ajustar el calibrador (Guo et al., 2017; Silva Filho et al., 2023). La calidad se medirá por período, organismo y grupo de longitud.

La elección de umbral deberá basarse en costos definidos con usuarios institucionales. Si un falso negativo implica omitir un expediente relevante y un falso positivo consume tiempo de revisión, ambos costos deben expresarse y someterse a análisis de sensibilidad. El umbral no será tratado como propiedad permanente del modelo.

6.4.7. Integración con variables estructuradas

El PBC puede combinarse con metadatos disponibles durante la convocatoria: organismo, modalidad, monto estimado, plazos o clasificación. Trabajos como VigIA muestran el valor de variables estructuradas para supervisión (Salazar et al., 2024). Un modelo multimodal permitirá medir cuánto aporta el texto después de controlar esos factores.

La integración deberá aplicar una regla temporal estricta. Campos publicados después del resultado se excluirán o se utilizarán únicamente en análisis retrospectivo claramente separado.

6.4.8. Gobernanza y uso responsable

Antes de un piloto institucional se elaborará una ficha de modelo con población objetivo, datos, métricas, fallos conocidos, frecuencia de actualización y responsables. Se establecerá revisión humana, registro de decisiones y mecanismos para impugnar interpretaciones. La recomendación de la OCDE vincula contratación electrónica con transparencia, integridad, acceso y evaluación, principios que deberán guiar cualquier uso (Organisation for Economic Co-operation and Development, 2015).

La herramienta no deberá etiquetar corrupción, ilegalidad o responsabilidad sin evidencia y proceso competente. Su rol potencial será ordenar o señalar casos para análisis. El beneficio deberá medirse mediante una evaluación prospectiva: tiempo ahorrado, cobertura de revisión y calidad de hallazgos frente al procedimiento habitual.

6.5. Consideración final

Los PBC paraguayos contienen información aprovechable para análisis predictivo, pero su uso responsable exige conservar el contexto institucional, la temporalidad y las limitaciones de cobertura. La comparación demuestra que métodos simples y complejos pueden sobresalir en dimensiones diferentes. El siguiente paso no consiste únicamente en aumentar la escala del modelo, sino en ampliar y validar los datos, definir una finalidad pública concreta y asegurar que la señal estadística permanezca subordinada a la revisión y a las garantías del proceso de contratación.

Bibliografía

Acikalin, U. U., Tsakalidis, A., Özcan, G., Fazekas, M., & Ifrim, G. (2024). How You Describe Procurement Calls Matters: Predicting Outcome of Public Procurement Using Call Descriptions. *Natural Language Engineering*.

Aldana, A., Falcón-Cortés, A., & Larralde, H. (2022). A Machine Learning Model to Identify Corruption in México's Public Procurement Contracts. https://doi.org/10.48550/arXiv.2211.01478

Alva Principe, R. A., Chiarini, N., & Viviani, M. (2025). Long Document Classification in the Transformer Era: A Survey on Challenges, Advances and Open Issues. *WIREs Data Mining and Knowledge Discovery*, *15*(2), e70019.

Beltagy, I., Peters, M. E., & Cohan, A. (2020). Longformer: The Long-Document Transformer. https://doi.org/10.48550/arXiv.2004.05150

Cabrera Medina, G. A., Duarte Ortiz, R. A., Paciello Coronel, J. M., & Pane Fernandez, J. I. (2026). A Graph-Based Methodology for Detecting Collusion Risk Networks and Political-Business Ties in Public Procurement in Paraguay. *2026 Twelfth International Conference on eDemocracy & eGovernment (ICEDEG)*. https://doi.org/10.1109/ICEDEG70169.2026.11695392

Congreso de la Nación Paraguaya. (2022). Ley N.º 7021/2022 de Suministro y Contrataciones Públicas. Consultado el 23 de julio de 2026, desde https://www.bacn.gov.py/leyes-paraguayas/11220/ley-n-70212022-de-suministro-y-contrataciones-publica

Dai, X., Chalkidis, I., Darkner, S., & Elliott, D. (2022). Revisiting Transformer-based Models for Long Document Classification. *Findings of the Association for Computational Linguistics: EMNLP 2022*, 7212-7230. https://doi.org/10.18653/v1/2022.findings-emnlp.534

Devlin, J., Chang, M.-W., Lee, K., & Toutanova, K. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. *Proceedings of NAACL-HLT*, 4171-4186. https://doi.org/10.18653/v1/N19-1423

Dirección Nacional de Contrataciones Públicas. (2026a). Datos abiertos de contrataciones públicas. Consultado el 23 de julio de 2026, desde https://www.contrataciones.gov.py/datos/data

Dirección Nacional de Contrataciones Públicas. (2026b). Ley 7021 de Suministro y Contrataciones Públicas. Consultado el 23 de julio de 2026, desde https://www.contrataciones.gov.py/dncp/ley-7021/ley-7021-de-suministro-y-contrataciones-publicas/

Dirección Nacional de Contrataciones Públicas. (2026c). Open Contracting. Consultado el 23 de julio de 2026, desde https://www.contrataciones.gov.py/datos/open-contracting-info

Gallego, J., Gonzalo, R., & Martínez, J. (2021). Preventing Rather Than Punishing: An Early Warning Model of Malfeasance in Public Procurement. *International Journal of Forecasting*, *37*(3), 360-377. https://doi.org/10.1016/j.ijforecast.2020.06.006

Guo, C., Pleiss, G., Sun, Y., & Weinberger, K. Q. (2017). On Calibration of Modern Neural Networks. *Proceedings of the 34th International Conference on Machine Learning*, *70*, 1321-1330. https://proceedings.mlr.press/v70/guo17a.html

Han, G., Tsao, J., & Huang, X. (2024). Length-Aware Multi-Kernel Transformer for Long Document Classification. *Proceedings of the 13th Joint Conference on Lexical and Computational Semantics*, 278-290. https://doi.org/10.18653/v1/2024.starsem-1.22

Kehler, E., Paciello, J., & Pane, J. (2019). Anomaly Detection in Public Procurements Using the Open Contracting Data Standard. *Proceedings of the 13th Alberto Mendelzon International Workshop on Foundations of Data Management*, *2369*, 89-95. https://ceur-ws.org/Vol-2369/short09.pdf

Loshchilov, I., & Hutter, F. (2019). Decoupled Weight Decay Regularization. *International Conference on Learning Representations*. https://openreview.net/forum?id=Bkg6RiCqY7

Lu, P., Wang, S., Rezagholizadeh, M., Liu, B., & Kobyzev, I. (2023). Efficient Classification of Long Documents with State-Space Models. *Proceedings of EMNLP 2023*, 6559-6565. https://doi.org/10.18653/v1/2023.emnlp-main.404

Mamakas, D., Tsotsi, P., Androutsopoulos, I., & Chalkidis, I. (2022). Processing Long Legal Documents with Pre-trained Transformers: Modding LegalBERT and Longformer. *Proceedings of the Natural Legal Language Processing Workshop 2022*, 130-142. https://doi.org/10.18653/v1/2022.nllp-1.11

Ministerio de Tecnologías de la Información y Comunicación. (2026). Gobierno electrónico. Consultado el 23 de julio de 2026, desde https://mitic.gov.py/gobierno-electronico/

Open Contracting Partnership. (2026a). How the Open Contracting Data Standard Works. Consultado el 23 de julio de 2026, desde https://standard.open-contracting.org/latest/en/primer/how/

Open Contracting Partnership. (2026b). OCDS Codelists. Consultado el 23 de julio de 2026, desde https://standard.open-contracting.org/latest/en/schema/codelists/

Open Contracting Partnership. (2026c). OCDS Schema Reference. Consultado el 23 de julio de 2026, desde https://standard.open-contracting.org/latest/en/schema/reference/

Open Contracting Partnership. (2026d). Open Contracting Data Standard. Consultado el 23 de julio de 2026, desde https://www.open-contracting.org/data-standard/

Organisation for Economic Co-operation and Development. (2015). Recommendation of the Council on Public Procurement. Consultado el 23 de julio de 2026, desde https://legalinstruments.oecd.org/public/doc/131/131.en.pdf

Richardson, E., Trevizani, R., Greenbaum, J. A., Carter, H., Nielsen, M., & Peters, B. (2024). The Receiver Operating Characteristic Curve Accurately Assesses Imbalanced Datasets. *Patterns*.

S. Agarwal et al. (2025). gpt-oss-120b & gpt-oss-20b Model Card.

Salazar, A., Pérez, J. F., & Gallego, J. (2024). VigIA: Prioritizing Public Procurement Oversight With Machine Learning Models and Risk Indices. *Data & Policy*, *6*, e75. https://doi.org/10.1017/dap.2024.83

Salton, G., & Buckley, C. (1988). Term-Weighting Approaches in Automatic Text Retrieval. *Information Processing & Management*, *24*(5), 513-523. https://doi.org/10.1016/0306-4573(88)90021-0

Shen, D., Wang, G., Wang, W., Min, M. R., Su, Q., Zhang, Y., Li, C., Henao, R., & Carin, L. (2018). Baseline Needs More Love: On Simple Word-Embedding-Based Models and Associated Pooling Mechanisms. https://arxiv.org/abs/1805.09843

Silva Filho, T., Song, H., Perello-Nieto, M., Santos-Rodriguez, R., Kull, M., & Flach, P. (2023). Classifier Calibration: A Survey on How to Assess and Improve Predicted Class Probabilities. *Machine Learning*, *112*, 3211-3260.

Tuteja, M., & González Juclà, D. (2023). Long Text Classification Using Transformers with Paragraph Selection Strategies. *Proceedings of the Natural Legal Language Processing Workshop 2023*, 17-24. https://doi.org/10.18653/v1/2023.nllp-1.3

Vaswani, A., Shazeer, N., Parmar, N., Uszkoreit, J., Jones, L., Gomez, A. N., Kaiser, L., & Polosukhin, I. (2017). Attention Is All You Need. *Advances in Neural Information Processing Systems*, *30*. https://proceedings.neurips.cc/paper_files/paper/2017/hash/3f5ee243547dee91fbd053c1c4a845aa-Abstract.html

Wang, L., Yang, N., Huang, X., Jiao, B., Yang, L., Jiang, D., Majumder, R., & Wei, F. (2022). Text Embeddings by Weakly-Supervised Contrastive Pre-training. https://arxiv.org/abs/2212.03533

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024a). Improving Text Embeddings With Large Language Models. *Proc. 62nd Annu. Meeting Assoc. Comput. Linguist. (ACL)*, 12089-12117.

Wang, L., Yang, N., Huang, X., Yang, L., Majumder, R., & Wei, F. (2024b). Multilingual E5 Text Embeddings: A Technical Report. https://doi.org/10.48550/arXiv.2402.05672

Wang, S., & Manning, C. D. (2012). Baselines and Bigrams: Simple, Good Sentiment and Topic Classification. *Proc. 50th Annu. Meeting Assoc. Comput. Linguist. (ACL)*, 90-94.